In [1]:
```python
import pandas as pd
from dotenv import load_dotenv
import os
load_dotenv()
DF_PATH = os.getenv('DF')
df = pd.read_csv(DF_PATH)
df
```

Out[1]:

	Desc	Yıllık	9 Aylık	6 Aylık	3 Aylık	OriginalFileNa
0	Dönen Varlıklar	9457559.0	12071214.0	15581108.0	8897663.0	EMNIS_2009.x
1	Nakit ve Nakit Benzerleri	1610426.0	23911.0	14434.0	48297.0	EMNIS_2009.x
2	Finansal Yatırımlar	0.0	0.0	0.0	0.0	EMNIS_2009.x
3	Ticari Alacaklar	5026287.0	8501402.0	11668645.0	5436925.0	EMNIS_2009.x
4	Finans Sektörü Faaliyetlerinden Alacaklar	0.0	0.0	0.0	0.0	EMNIS_2009.x
...	...	...	...	...	...	
507207	Diğer Nakit Girişi/Çıkışı	0.0	0.0	0.0	0.0	DGNMO_2022.x
507208	Nakit ve Benzerlerindeki Değişim	380981383.0	78669533.0	89823875.0	-23447193.0	DGNMO_2022.x
507209	Diğer Nakit ve Nakit Benzerlerindeki Artış	0.0	0.0	0.0	0.0	DGNMO_2022.x
507210	Dönem Başı Nakit Değerler	140545109.0	49168829.0	49168829.0	49168829.0	DGNMO_2022.x
507211	Dönem Sonu Nakit	521526492.0	127838362.0	138992704.0	25721636.0	DGNMO_2022.x

507212 rows × 8 columns

In [2]:
```python
df['Desc'].unique()
```

```
Out[2]: array(['Dönen Varlıklar', '  Nakit ve Nakit Benzerleri',
               '  Finansal Yatırımlar', '  Ticari Alacaklar',
               '  Finans Sektörü Faaliyetlerinden Alacaklar', '  Diğer Alacaklar',
               '  Stoklar', '  Canlı Varlıklar', '  Diğer Dönen Varlıklar',
               '    (Ara Toplam)',
               '  Satış Amacıyla Elde Tutulan Duran Varlıklar', 'Duran Varlıklar',
               '  Özkaynak Yöntemiyle Değerlenen Yatırımlar',
               '  Yatırım Amaçlı Gayrimenkuller', '  Maddi Duran Varlıklar',
               '  Şerefiye', '  Maddi Olmayan Duran Varlıklar',
               '  Ertelenmiş Vergi Varlığı', '  Diğer Duran Varlıklar',
               'TOPLAM VARLIKLAR', 'KAYNAKLAR', 'Kısa Vadeli Yükümlülükler',
               '  Finansal Borçlar', '  Diğer Finansal Yükümlülükler',
               '  Ticari Borçlar', '  Diğer Borçlar',
               '  Finans Sektörü Faaliyetlerinden Borçlar',
               '  Devlet Teşvik ve Yardımları', '  Dönem Karı Vergi Yükümlülüğü',
               '  Borç Karşılıkları', '  Diğer Kısa Vadeli Yükümlülükler',
               '  Satış Amaçlı Elde Tutulan Duran Varlıklara İlişkin Yükümlülükler',
               'Uzun Vadeli Yükümlülükler', '    Uzun vadeli karşılıklar',
               '  Çalışanlara Sağlanan Faydalara İliş.Karş.',
               '  Ertelenmiş Vergi Yükümlülüğü',
               '  Diğer Uzun Vadeli Yükümlülükler', 'Özkaynaklar',
               '  Ana Ortaklığa Ait Özkaynaklar', '  Ödenmiş Sermaye',
               '  Karşılıklı İştirak Sermayesi Düzeltmesi (-)',
               '  Hisse Senedi İhraç Primleri', '  Değer Artış Fonları',
               '  Yabancı Para Çevrim Farkları',
               '  Kardan Ayrılan Kısıtlanmış Yedekler',
               '  Geçmiş Yıllar Kar/Zararları', '  Dönem Net Kar/Zararı',
               '  Diğer Özsermaye Kalemleri', '  Azınlık Payları',
               'TOPLAM KAYNAKLAR', 'Sürdürülen Faaliyetler', 'Satış Gelirleri',
               'Satışların Maliyeti (-)',
               'Ticari Faaliyetlerden Diğer Kar (Zarar)',
               'Ticari Faaliyetlerden Brüt Kar (Zarar)',
               'Faiz, Ücret, Prim, Komisyon ve Diğer Gelirler',
               'Faiz, Ücret, Prim, Komisyon ve Diğer Giderler (-)',
               'Finans Sektörü Faaliyetlerinden Diğer Kar (Zarar)',
               'Finans Sektörü Faaliyetlerinden Brüt Kar (Zarar)',
               'Diğer Gelir ve Giderler', 'BRÜT KAR (ZARAR)',
               'Pazarlama, Satış ve Dağıtım Giderleri (-)',
               'Genel Yönetim Giderleri (-)',
               'Araştırma ve Geliştirme Giderleri (-)',
               'Diğer Faaliyet Gelirleri', 'Diğer Faaliyet Giderleri (-)',
               'Faaliyet Karı Öncesi Diğer Gelir ve Giderler',
               'FAALİYET KARI (ZARARI)', 'Net Faaliyet Kar/Zararı',
               'Özkaynak Yöntemiyle Değerlenen Yatırımların Kar/Zararlarındaki Paylar',
               '(Esas Faaliyet Dışı) Finansal Gelirler',
               '(Esas Faaliyet Dışı) Finansal Giderler (-)',
               'Vergi Öncesi Diğer Gelir ve Giderler',
               'SÜRDÜRÜLEN FAALİYETLER VERGİ ÖNCESİ KARI (ZARARI)',
               'Sürdürülen Faaliyetler Vergi Geliri (Gideri)',
               '  Dönem Vergi Geliri (Gideri)',
               '  Ertelenmiş Vergi Geliri (Gideri)',
               '  Diğer Vergi Geliri (Gideri)',
               'SÜRDÜRÜLEN FAALİYETLER DÖNEM KARI/ZARARI',
               'DURDURULAN FAALİYETLER',
               'Durdurulan Faaliyetler Vergi Sonrası Dönem Karı (Zararı)',
               'DÖNEM KARI (ZARARI)', 'Dönem Kar/Zararının Dağılımı',
```

```
       'Azınlık Payları', 'Ana Ortaklık Payları', 'Hisse Başına Kazanç',
       'Seyreltilmiş Hisse Başına Kazanç',
       'Sürdürülen Faaliyetlerden Hisse Başına Kazanç',
       'Sürdürülen Faaliyetlerden Seyreltilmiş Hisse Başına Kazanç',
       'Amortisman Giderleri', 'Kıdem Tazminatı', 'Finansman Giderleri',
       'Yurtiçi Satışlar', 'Yurtdışı Satışlar',
       'Net Yabancı Para Pozisyonu',
       '  Müşteri Sözleşmelerinden Doğan Varlıklar',
       '  Kullanım Hakkı Varlıkları', '  Müşteri Söz. Doğan Yük.',
       '  Ertelenmiş Gelirler (Müşteri Söz. Doğan Yük. Dış.Kal.)',
       '  Müşteri Söz.Doğan Yük.',
       '  Ertelenmiş Gelirler (Müşteri Söz.Doğan Yük. Dış.Kal.)',
       '  Yatırım Faaliyetlerinden Gelirler',
       '  Yatırım Faaliyetlerinden Giderler (-)',
       '  Diğer Gelir ve Giderler',
       'Finansman Gideri Öncesi Faaliyet Karı/Zararı',
       'Parasal net yabancı para varlık/(yükümlülük) pozisyonu',
       'Net YPP (Hedge Dahil)',
       ' İşletme Faaliyetlerinden Kaynaklanan Net Nakit',
       ' Düzeltme Öncesi Kar', ' Düzeltmeler:',
       '  Amortisman & İtfa Payları', '  Karşılıklardaki Değişim',
       '  Diğer Gelir/ Gider',
       ' İşletme Sermayesinde Değişikler Öncesi Faaliyet Karı (+)',
       '  İşletme Sermayesindeki Değişiklikler',
       ' Esas Faaliyet ile İlgili Oluşan Nakit (+)',
       '  Diğer İşletme Faaliyetlerinden Nakit',
       '  Sabit Sermaye Yatırımları',
       '  Diğer Yatırım Faaliyetlerinden Nakit',
       ' Yatırım Faaliyetlerinden Kaynaklanan Nakit',
       'Serbest Nakit Akım', 'Finansal Borçlardaki Değişim',
       'Temettü Ödemeleri', 'Sermaye Artırımı',
       'Diğer Finansman Faaliyetlerinden Nakit',
       'Finansman Faaliyetlerden Kaynaklanan Nakit',
       'Yab. Para Çev. Fark. Etk. Önc.Nak.Ve Nak. Benz. Net Artış/Azalış',
       ' Yab.ı Para Çevrim Fark. Nakit Ve Nakit Benz. Üzerindeki Etkisi',
       ' Diğer Nakit Girişi/Çıkışı', 'Nakit ve Benzerlerindeki Değişim',
       'Diğer Nakit ve Nakit Benzerlerindeki Artış',
       'Dönem Başı Nakit Değerler', 'Dönem Sonu Nakit',
       'Ertelenmiş Vergi Yükümlülüğü',
       'İşletme Faaliyetlerinden Kaynaklanan Net Nakit',
       'Finansal Borçlar', ' Yatırım Faaliyetlerinden Giderler (-)',
       ' Şerefiye', 'Canlı Varlıklar'], dtype=object)
```

Tradução

- Colunas e tipos de documento.
- Utilizei Google Tradutor.

In [3]:
```
colunas_traduzidas = {
    'Desc': 'Descricao',
    'Yıllık': 'Anual',
    '9 Aylık': '9_Meses',
    '6 Aylık': '6_Meses',
    '3 Aylık': '3_Meses',
```

```
    'Year':'Ano'
}

df = df.rename(columns=colunas_traduzidas)
```

In [4]:
```
# Usei o Google Tradutor
traducao_termos_desc = {
    'Dönen Varlıklar': 'Ativos Circulantes',
    '  Nakit ve Nakit Benzerleri': 'Caixa e Equivalentes de Caixa',
    '  Finansal Yatırımlar': 'Investimentos Financeiros',
    '  Ticari Alacaklar': 'Contas a Receber',
    '  Finans Sektörü Faaliyetlerinden Alacaklar': 'Contas a Receber de Atividades
    '  Diğer Alacaklar': 'Outros Recebíveis',
    '  Stoklar': 'Estoques',
    '  Canlı Varlıklar': 'Ativos Biológicos',
    '  Diğer Dönen Varlıklar': 'Outros Ativos Circulantes',
    '    (Ara Toplam)': '(Subtotal)',
    '  Satış Amacıyla Elde Tutulan Duran Varlıklar': 'Ativos Não Circulantes Mantid
    'Duran Varlıklar': 'Ativos Não Circulantes',
    '  Özkaynak Yöntemiyle Değerlenen Yatırımlar': 'Investimentos Avaliados pelo Mé
    '  Yatırım Amaçlı Gayrimenkuller': 'Imóveis de Investimento',
    '  Maddi Duran Varlıklar': 'Ativos Imobilizados',
    '  Şerefiye': 'Goodwill',
    '  Maddi Olmayan Duran Varlıklar': 'Ativos Intangíveis',
    '  Ertelenmiş Vergi Varlığı': 'Ativo Fiscal Diferido',
    '  Diğer Duran Varlıklar': 'Outros Ativos Não Circulantes',
    'TOPLAM VARLIKLAR': 'TOTAL DE ATIVOS',
    'KAYNAKLAR': 'PASSIVO E PATRIMÔNIO LÍQUIDO',
    'Kısa Vadeli Yükümlülükler': 'Passivos Circulantes',
    '  Finansal Borçlar': 'Dívidas Financeiras',
    '  Diğer Finansal Yükümlülükler': 'Outras Obrigações Financeiras',
    '  Ticari Borçlar': 'Contas a Pagar',
    '  Diğer Borçlar': 'Outras Dívidas',
    '  Finans Sektörü Faaliyetlerinden Borçlar': 'Dívidas de Atividades do Setor Fi
    '  Devlet Teşvik ve Yardımları': 'Incentivos e Ajuda Governamental',
    '  Dönem Karı Vergi Yükümlülüğü': 'Obrigações Fiscais sobre o Lucro do Período'
    '  Borç Karşılıkları': 'Provisões para Dívidas',
    '  Diğer Kısa Vadeli Yükümlülükler': 'Outros Passivos Circulantes',
    '  Satış Amaçlı Elde Tutulan Duran Varlıklara İlişkin Yükümlülükler': 'Passivos
    'Uzun Vadeli Yükümlülükler': 'Passivos Não Circulantes',
    '    Uzun vadeli karşılıklar': 'Provisões de Longo Prazo',
    '  Çalışanlara Sağlanan Faydalara İliş.Karş.': 'Provisões para Benefícios a Emp
    '  Ertelenmiş Vergi Yükümlülüğü': 'Passivo Fiscal Diferido',
    '  Diğer Uzun Vadeli Yükümlülükler': 'Outros Passivos Não Circulantes',
    'Özkaynaklar': 'Patrimônio Líquido',
    '  Ana Ortaklığa Ait Özkaynaklar': 'Patrimônio Líquido Atribuível aos Acionista
    '  Ödenmiş Sermaye': 'Capital Social Integralizado',
    '  Karşılıklı İştirak Sermayesi Düzeltmesi (-)': 'Ajuste de Capital de Particip
    '  Hisse Senedi İhraç Primleri': 'Reservas de Capital de Emissão de Ações',
    '  Değer Artış Fonları': 'Fundos de Reavaliação / Valorização',
    '  Yabancı Para Çevrim Farkları': 'Diferenças de Conversão de Moeda Estrangeira
    '  Kardan Ayrılan Kısıtlanmış Yedekler': 'Reservas Restritas Separadas do Lucro
    '  Geçmiş Yıllar Kar/Zararları': 'Lucros/Prejuízos Acumulados',
    '  Dönem Net Kar/Zararı': 'Lucro/Prejuízo Líquido do Período',
    '  Diğer Özsermaye Kalemleri': 'Outros Itens do Patrimônio Líquido',
    '  Azınlık Payları': 'Participações de Não Controladores',
```

```
    'TOPLAM KAYNAKLAR': 'TOTAL DO PASSIVO E PATRIMÔNICO LÍQUIDO',
    'Sürdürülen Faaliyetler': 'Operações Continuadas',
    'Satış Gelirleri': 'Receita de Vendas',
    'Satışların Maliyeti (-)': 'Custo dos Produtos/Serviços Vendidos (-)',
    'Ticari Faaliyetlerden Diğer Kar (Zarar)': 'Outros Ganhos (Perdas) de Atividade
    'Ticari Faaliyetlerden Brüt Kar (Zarar)': 'Lucro Bruto (Prejuízo) de Atividades
    'Faiz, Ücret, Prim, Komisyon ve Diğer Gelirler': 'Receitas de Juros, Taxas, Prê
    'Faiz, Ücret, Prim, Komisyon ve Diğer Giderler (-)': 'Despesas de Juros, Taxas,
    'Finans Sektörü Faaliyetlerinden Diğer Kar (Zarar)': 'Outros Ganhos (Perdas) de
    'Finans Sektörü Faaliyetlerinden Brüt Kar (Zarar)': 'Lucro Bruto (Prejuízo) de
    'Diğer Gelir ve Giderler': 'Outras Receitas e Despesas',
    'BRÜT KAR (ZARAR)': 'LUCRO BRUTO (PREJUÍZO)',
    'Pazarlama, Satış ve Dağıtım Giderleri (-)': 'Despesas de Marketing, Vendas e D
    'Genel Yönetim Giderleri (-)': 'Despesas Gerais e Administrativas (-)',
    'Araştırma ve Geliştirme Giderleri (-)': 'Despesas de Pesquisa e Desenvolviment
    'Diğer Faaliyet Gelirleri': 'Outras Receitas Operacionais',
    'Diğer Faaliyet Giderleri (-)': 'Outras Despesas Operacionais (-)',
    'Faaliyet Karı Öncesi Diğer Gelir ve Giderler': 'Outras Receitas e Despesas Ant
    'FAALİYET KARI (ZARARI)': 'LUCRO OPERACIONAL (PREJUÍZO)',
    'Net Faaliyet Kar/Zararı': 'Lucro/Prejuízo Operacional Líquido',
    'Özkaynak Yöntemiyle Değerlenen Yatırımların Kar/Zararlarındaki Paylar': 'Parti
    '(Esas Faaliyet Dışı) Finansal Gelirler': 'Receitas Financeiras (Não Operaciona
    '(Esas Faaliyet Dışı) Finansal Giderler (-)': 'Despesas Financeiras (Não Operac
    'Vergi Öncesi Diğer Gelir ve Giderler': 'Outras Receitas e Despesas Antes do Im
    'SÜRDÜRÜLEN FAaliyetLER VERGİ ÖNCESİ KARI (ZARARI)': 'LUCRO (PREJUÍZO) ANTES DO
    'Sürdürülen Faaliyetler Vergi Geliri (Gideri)': 'Receita (Despesa) de Imposto d
    '  Dönem Vergi Geliri (Gideri)': 'Receita (Despesa) de Imposto do Período',
    '  Ertelenmiş Vergi Geliri (Gideri)': 'Receita (Despesa) de Imposto Diferido',
    '  Diğer Vergi Geliri (Gideri)': 'Outra Receita (Despesa) de Imposto',
    'SÜRDÜRÜLEN FAALİYETLER DÖNEM KARI/ZARARI': 'LUCRO/PREJUÍZO LÍQUIDO DO PERÍODO
    'DURDURULAN FAALİYETLER': 'OPERAÇÕES DESCONTINUADAS',
    'Durdurulan Faaliyetler Vergi Sonrası Dönem Karı (Zararı)': 'Lucro (Prejuízo) d
    'DÖNEM KARI (ZARARI)': 'LUCRO (PREJUÍZO) DO PERÍODO',
    'Dönem Kar/Zararının Dağılımı': 'Distribuição do Lucro/Prejuízo do Período',
    'Azınlık Payları': 'Participações de Não Controladores',
    'Ana Ortaklık Payları': 'Participações da Controladora',
    'Hisse Başına Kazanç': 'Lucro por Ação',
    'Seyreltilmiş Hisse Başına Kazanç': 'Lucro por Ação Diluído',
    'Sürdürülen Faaliyetlerden Hisse Başına Kazanç': 'Lucro por Ação de Operações C
    'Sürdürülen Faaliyetlerden Seyreltilmiş Hisse Başına Kazanç': 'Lucro por Ação D
    'Amortisman Giderleri': 'Despesas de Amortização',
    'Kıdem Tazminatı': 'Indenização por Antiguidade',
    'Finansman Giderleri': 'Despesas Financeiras',
    'Yurtiçi Satışlar': 'Vendas Domésticas',
    'Yurtdışı Satışlar': 'Vendas Internacionais',
    'Net Yabancı Para Pozisyonu': 'Posição Cambial Líquida',
    '  Müşteri Sözleşmelerinden Doğan Varlıklar': 'Ativos de Contratos com Clientes
    '  Kullanım Hakkı Varlıkları': 'Ativos de Direito de Uso',
    '  Müşteri Söz. Doğan Yük.': 'Passivos de Contratos com Clientes',
    '  Ertelenmiş Gelirler (Müşteri Söz. Doğan Yük. Dış.Kal.)': 'Receitas Diferidas
    '  Müşteri Söz.Doğan Yük.': '  Passivos de Contratos com Clientes',
    '  Ertelenmiş Gelirler (Müşteri Söz.Doğan Yük. Dış.Kal.)': 'Receitas Diferidas
    '  Yatırım Faaliyetlerinden Gelirler': 'Receitas de Atividades de Investimento'
    '  Yatırım Faaliyetlerinden Giderler (-)': 'Despesas de Atividades de Investime
    '  Diğer Gelir ve Giderler': 'Outras Receitas e Despesas',
    'Finansman Gideri Öncesi Faaliyet Karı/Zararı': 'Lucro/Prejuízo Operacional Ant
```

```
    'Parasal net yabancı para varlık/(yükümlülük) pozisyonu': 'Posição Líquida (Ati
    'Net YPP (Hedge Dahil)': 'Posição Cambial Líquida (Incluindo Hedge)',
    ' İşletme Faaliyetlerinden Kaynaklanan Net Nakit': 'Fluxo de Caixa Líquido das
    ' Düzeltme Öncesi Kar': 'Lucro Antes dos Ajustes',
    ' Düzeltmeler:': 'Ajustes:',
    '  Amortisman & İtfa Payları': 'Amortização e Quotas de Exaustão',
    '  Karşılıklardaki Değişim': 'Mudança nas Provisões',
    '  Diğer Gelir/ Gider': 'Outras Receitas/Despesas',
    ' İşletme Sermayesinde Değişikler Öncesi Faaliyet Karı (+)': 'Lucro Operacional
    '  İşletme Sermayesindeki Değişiklikler': 'Mudanças no Capital de Giro',
    ' Esas Faaliyet ile İlgili Oluşan Nakit (+)': 'Caixa Gerado por Atividades Prin
    '  Diğer İşletme Faaliyetlerinden Nakit': 'Fluxo de Caixa de Outras Atividades
    '  Sabit Sermaye Yatırımları': '  Investimentos em Capital Fixo',
    '  Diğer Yatırım Faaliyetlerinden Nakit': 'Fluxo de Caixa de Outras Atividades
    ' Yatırım Faaliyetlerinden Kaynaklanan Nakit': 'Fluxo de Caixa das Atividades d
    'Serbest Nakit Akım': 'Fluxo de Caixa Livre',
    'Finansal Borçlardaki Değişim': 'Variação nas Dívidas Financeiras',
    'Temettü Ödemeleri': 'Pagamento de Dividendos',
    'Sermaye Artırımı': 'Aumento de Capital',
    'Diğer Finansman Faaliyetlerinden Nakit': 'Fluxo de Caixa de Outras Atividades
    'Finansman Faaliyetlerden Kaynaklanan Nakit': 'Fluxo de Caixa das Atividades de
    'Yab. Para Çev. Fark. Etk. Önc.Nak.Ve Nak. Benz. Net Artış/Azalış': 'Aumento/Di
    ' Yab.ı Para Çevrim Fark. Nakit Ve Nakit Benz. Üzerindeki Etkisi': 'Efeito das
    ' Diğer Nakit Girişi/Çıkışı': 'Outras Entradas/Saídas de Caixa',
    'Nakit ve Benzerlerindeki Değişim': 'Variação no Caixa e Equivalentes',
    'Diğer Nakit ve Nakit Benzerlerindeki Artış': 'Aumento em Outros Caixas e Equiv
    'Dönem Başı Nakit Değerler': 'Valores de Caixa no Início do Período',
    'Dönem Sonu Nakit': 'Caixa no Final do Período',
    ' Ertelenmiş Vergi Geliri (Gideri)': 'Receita (Despesa) de Imposto Diferido'
}

df['Descricao'] = df['Descricao'].map(traducao_termos_desc)

print(df['Descricao'].unique())
```

```
['Ativos Circulantes' 'Caixa e Equivalentes de Caixa'
 'Investimentos Financeiros' 'Contas a Receber'
 'Contas a Receber de Atividades do Setor Financeiro' 'Outros Recebíveis'
 'Estoques' 'Ativos Biológicos' 'Outros Ativos Circulantes' '(Subtotal)'
 'Ativos Não Circulantes Mantidos para Venda' 'Ativos Não Circulantes'
 'Investimentos Avaliados pelo Método da Equivalência Patrimonial'
 'Imóveis de Investimento' 'Ativos Imobilizados' 'Goodwill'
 'Ativos Intangíveis' 'Ativo Fiscal Diferido'
 'Outros Ativos Não Circulantes' 'TOTAL DE ATIVOS'
 'PASSIVO E PATRIMÔNIO LÍQUIDO' 'Passivos Circulantes'
 'Dívidas Financeiras' 'Outras Obrigações Financeiras' 'Contas a Pagar'
 'Outras Dívidas' 'Dívidas de Atividades do Setor Financeiro'
 'Incentivos e Ajuda Governamental'
 'Obrigações Fiscais sobre o Lucro do Período' 'Provisões para Dívidas'
 'Outros Passivos Circulantes'
 'Passivos Relacionados a Ativos Não Circulantes Mantidos para Venda'
 'Passivos Não Circulantes' 'Provisões de Longo Prazo'
 'Provisões para Benefícios a Empregados' 'Passivo Fiscal Diferido'
 'Outros Passivos Não Circulantes' 'Patrimônio Líquido'
 'Patrimônio Líquido Atribuível aos Acionistas da Controladora'
 'Capital Social Integralizado'
 'Ajuste de Capital de Participação Mútua (-)'
 'Reservas de Capital de Emissão de Ações'
 'Fundos de Reavaliação / Valorização'
 'Diferenças de Conversão de Moeda Estrangeira'
 'Reservas Restritas Separadas do Lucro' 'Lucros/Prejuízos Acumulados'
 'Lucro/Prejuízo Líquido do Período' 'Outros Itens do Patrimônio Líquido'
 'Participações de Não Controladores'
 'TOTAL DO PASSIVO E PATRIMÔNICO LÍQUIDO' 'Operações Continuadas'
 'Receita de Vendas' 'Custo dos Produtos/Serviços Vendidos (-)'
 'Outros Ganhos (Perdas) de Atividades Comerciais'
 'Lucro Bruto (Prejuízo) de Atividades Comerciais'
 'Receitas de Juros, Taxas, Prêmios, Comissões e Outras'
 'Despesas de Juros, Taxas, Prêmios, Comissões e Outras (-)'
 'Outros Ganhos (Perdas) de Atividades do Setor Financeiro'
 'Lucro Bruto (Prejuízo) de Atividades do Setor Financeiro'
 'Outras Receitas e Despesas' 'LUCRO BRUTO (PREJUÍZO)'
 'Despesas de Marketing, Vendas e Distribuição (-)'
 'Despesas Gerais e Administrativas (-)'
 'Despesas de Pesquisa e Desenvolvimento (-)'
 'Outras Receitas Operacionais' 'Outras Despesas Operacionais (-)'
 'Outras Receitas e Despesas Antes do Lucro Operacional'
 'LUCRO OPERACIONAL (PREJUÍZO)' 'Lucro/Prejuízo Operacional Líquido'
 'Participação nos Lucros/Prejuízos de Investimentos Avaliados pelo Método da Equiva
lência Patrimonial'
 'Receitas Financeiras (Não Operacionais)'
 'Despesas Financeiras (Não Operacionais) (-)'
 'Outras Receitas e Despesas Antes do Imposto' nan
 'Receita (Despesa) de Imposto das Operações Continuadas'
 'Receita (Despesa) de Imposto do Período'
 'Receita (Despesa) de Imposto Diferido'
 'Outra Receita (Despesa) de Imposto'
 'LUCRO/PREJUÍZO LÍQUIDO DO PERÍODO DAS OPERAÇÕES CONTINUADAS'
 'OPERAÇÕES DESCONTINUADAS'
 'Lucro (Prejuízo) do Período Após Imposto das Operações Descontinuadas'
 'LUCRO (PREJUÍZO) DO PERÍODO' 'Distribuição do Lucro/Prejuízo do Período'
```

```
 'Participações da Controladora' 'Lucro por Ação' 'Lucro por Ação Diluído'
 'Lucro por Ação de Operações Continuadas'
 'Lucro por Ação Diluído de Operações Continuadas'
 'Despesas de Amortização' 'Indenização por Antiguidade'
 'Despesas Financeiras' 'Vendas Domésticas' 'Vendas Internacionais'
 'Posição Cambial Líquida' 'Ativos de Contratos com Clientes'
 'Ativos de Direito de Uso' 'Passivos de Contratos com Clientes'
 'Receitas Diferidas (Exceto Passivos de Contratos com Clientes)'
 '  Passivos de Contratos com Clientes'
 'Receitas de Atividades de Investimento'
 'Despesas de Atividades de Investimento (-)'
 'Lucro/Prejuízo Operacional Antes das Despesas Financeiras'
 'Posição Líquida (Ativo/Passivo) Monetária em Moeda Estrangeira'
 'Posição Cambial Líquida (Incluindo Hedge)'
 'Fluxo de Caixa Líquido das Atividades Operacionais'
 'Lucro Antes dos Ajustes' 'Ajustes:' 'Amortização e Quotas de Exaustão'
 'Mudança nas Provisões' 'Outras Receitas/Despesas'
 'Lucro Operacional Antes das Mudanças no Capital de Giro (+)'
 'Mudanças no Capital de Giro'
 'Caixa Gerado por Atividades Principais (+)'
 'Fluxo de Caixa de Outras Atividades Operacionais'
 '  Investimentos em Capital Fixo'
 'Fluxo de Caixa de Outras Atividades de Investimento'
 'Fluxo de Caixa das Atividades de Investimento' 'Fluxo de Caixa Livre'
 'Variação nas Dívidas Financeiras' 'Pagamento de Dividendos'
 'Aumento de Capital'
 'Fluxo de Caixa de Outras Atividades de Financiamento'
 'Fluxo de Caixa das Atividades de Financiamento'
 'Aumento/Diminuição Líquido de Caixa e Equivalentes de Caixa Antes do Efeito das Di
ferenças de Conversão de Moeda Estrangeira'
 'Efeito das Diferenças de Conversão de Moeda Estrangeira sobre o Caixa e Equivalent
es de Caixa'
 'Outras Entradas/Saídas de Caixa' 'Variação no Caixa e Equivalentes'
 'Aumento em Outros Caixas e Equivalentes de Caixa'
 'Valores de Caixa no Início do Período' 'Caixa no Final do Período']
```

In [5]:
```
df.head()
```

Out[5]:

	Descricao	Anual	9_Meses	6_Meses	3_Meses	OriginalFileName	Company
0	Ativos Circulantes	9457559.0	12071214.0	15581108.0	8897663.0	EMNIS_2009.xlsx	E
1	Caixa e Equivalentes de Caixa	1610426.0	23911.0	14434.0	48297.0	EMNIS_2009.xlsx	E
2	Investimentos Financeiros	0.0	0.0	0.0	0.0	EMNIS_2009.xlsx	E
3	Contas a Receber	5026287.0	8501402.0	11668645.0	5436925.0	EMNIS_2009.xlsx	E
4	Contas a Receber de Atividades do Setor Financ...	0.0	0.0	0.0	0.0	EMNIS_2009.xlsx	E

Tratativa de Valores Nulos

In [6]:
```
df.isnull().sum()
```

Out[6]:
```
Descricao            3875
Anual               10349
9_Meses             10920
6_Meses              9799
3_Meses              9304
OriginalFileName        0
CompanyCode             0
Ano                     0
dtype: int64
```

In [7]:
```
(df.isnull().sum() / len(df)) * 100
```

Out[7]:
```
Descricao           0.763980
Anual               2.040370
9_Meses             2.152946
6_Meses             1.931934
3_Meses             1.834341
OriginalFileName    0.000000
CompanyCode         0.000000
Ano                 0.000000
dtype: float64
```

In [8]:
```
# Count duplicates
df.duplicated().sum()
```

Out[8]:
```
np.int64(26566)
```

- Após identificar muitos valores duplicados zerados, vou tratar primeiro dos zerados e nulos depois volto neles, pois boa parte deles se trata de indicadores zerados e seria

interressante analisar isso ...

In [9]:
```
df[df.duplicated()]
```

Out[9]:

	Descricao	Anual	9_Meses	6_Meses	3_Meses	OriginalFileName	CompanyCo
13	Contas a Receber de Atividades do Setor Financ...	0.0	0.0	0.0	0.0	EMNIS_2009.xlsx	EMN
17	Ativos Biológicos	0.0	0.0	0.0	0.0	EMNIS_2009.xlsx	EMN
41	Outras Obrigações Financeiras	0.0	0.0	0.0	0.0	EMNIS_2009.xlsx	EMN
44	Dívidas de Atividades do Setor Financeiro	0.0	0.0	0.0	0.0	EMNIS_2009.xlsx	EMN
45	Incentivos e Ajuda Governamental	0.0	0.0	0.0	0.0	EMNIS_2009.xlsx	EMN
...	...	...	...	...	...	...	
507084	Ativos Biológicos	0.0	0.0	0.0	0.0	DGNMO_2022.xlsx	DGNM
507111	Outras Obrigações Financeiras	0.0	0.0	0.0	0.0	DGNMO_2022.xlsx	DGNM
507115	Dívidas de Atividades do Setor Financeiro	0.0	0.0	0.0	0.0	DGNMO_2022.xlsx	DGNM
507116	Incentivos e Ajuda Governamental	0.0	0.0	0.0	0.0	DGNMO_2022.xlsx	DGNM
507156	Outras Receitas e Despesas	0.0	0.0	0.0	0.0	DGNMO_2022.xlsx	DGNM

26566 rows × 8 columns

In [10]:
```
df[df.duplicated()].describe()
```

Out[10]:

	Anual	9_Meses	6_Meses	3_Meses	Ano
count	2.624600e+04	26133.000000	26157.000000	26214.000000	26566.000000
mean	6.449332e+02	-28.230972	-26.489773	-10.141260	2016.615900
std	8.100873e+04	3650.989428	3210.996528	1426.798161	4.867708
min	-1.247865e+06	-566628.000000	-491498.000000	-227805.000000	2008.000000
25%	0.000000e+00	0.000000	0.000000	0.000000	2012.000000
50%	0.000000e+00	0.000000	0.000000	0.000000	2017.000000
75%	0.000000e+00	0.000000	0.000000	0.000000	2021.000000
max	9.237000e+06	13385.000000	115.000000	156.000000	2024.000000

- Muitos Valores Nulos ao longo do DF.

In [11]:

```
# Checar quantos tipos diferentes de indicadores existem.
doc_count = df["Descricao"].nunique()
doc_types = df["Descricao"].unique()

print("Quantidade de Indicadores:", doc_count)
print("Indicadores:")
print(doc_types)
```

Quantidade de Indicadores: 129
Indicadores:
['Ativos Circulantes' 'Caixa e Equivalentes de Caixa'
 'Investimentos Financeiros' 'Contas a Receber'
 'Contas a Receber de Atividades do Setor Financeiro' 'Outros Recebíveis'
 'Estoques' 'Ativos Biológicos' 'Outros Ativos Circulantes' '(Subtotal)'
 'Ativos Não Circulantes Mantidos para Venda' 'Ativos Não Circulantes'
 'Investimentos Avaliados pelo Método da Equivalência Patrimonial'
 'Imóveis de Investimento' 'Ativos Imobilizados' 'Goodwill'
 'Ativos Intangíveis' 'Ativo Fiscal Diferido'
 'Outros Ativos Não Circulantes' 'TOTAL DE ATIVOS'
 'PASSIVO E PATRIMÔNIO LÍQUIDO' 'Passivos Circulantes'
 'Dívidas Financeiras' 'Outras Obrigações Financeiras' 'Contas a Pagar'
 'Outras Dívidas' 'Dívidas de Atividades do Setor Financeiro'
 'Incentivos e Ajuda Governamental'
 'Obrigações Fiscais sobre o Lucro do Período' 'Provisões para Dívidas'
 'Outros Passivos Circulantes'
 'Passivos Relacionados a Ativos Não Circulantes Mantidos para Venda'
 'Passivos Não Circulantes' 'Provisões de Longo Prazo'
 'Provisões para Benefícios a Empregados' 'Passivo Fiscal Diferido'
 'Outros Passivos Não Circulantes' 'Patrimônio Líquido'
 'Patrimônio Líquido Atribuível aos Acionistas da Controladora'
 'Capital Social Integralizado'
 'Ajuste de Capital de Participação Mútua (-)'
 'Reservas de Capital de Emissão de Ações'
 'Fundos de Reavaliação / Valorização'
 'Diferenças de Conversão de Moeda Estrangeira'
 'Reservas Restritas Separadas do Lucro' 'Lucros/Prejuízos Acumulados'
 'Lucro/Prejuízo Líquido do Período' 'Outros Itens do Patrimônio Líquido'
 'Participações de Não Controladores'
 'TOTAL DO PASSIVO E PATRIMÔNICO LÍQUIDO' 'Operações Continuadas'
 'Receita de Vendas' 'Custo dos Produtos/Serviços Vendidos (-)'
 'Outros Ganhos (Perdas) de Atividades Comerciais'
 'Lucro Bruto (Prejuízo) de Atividades Comerciais'
 'Receitas de Juros, Taxas, Prêmios, Comissões e Outras'
 'Despesas de Juros, Taxas, Prêmios, Comissões e Outras (-)'
 'Outros Ganhos (Perdas) de Atividades do Setor Financeiro'
 'Lucro Bruto (Prejuízo) de Atividades do Setor Financeiro'
 'Outras Receitas e Despesas' 'LUCRO BRUTO (PREJUÍZO)'
 'Despesas de Marketing, Vendas e Distribuição (-)'
 'Despesas Gerais e Administrativas (-)'
 'Despesas de Pesquisa e Desenvolvimento (-)'
 'Outras Receitas Operacionais' 'Outras Despesas Operacionais (-)'
 'Outras Receitas e Despesas Antes do Lucro Operacional'
 'LUCRO OPERACIONAL (PREJUÍZO)' 'Lucro/Prejuízo Operacional Líquido'
 'Participação nos Lucros/Prejuízos de Investimentos Avaliados pelo Método da Equiva
lência Patrimonial'
 'Receitas Financeiras (Não Operacionais)'
 'Despesas Financeiras (Não Operacionais) (-)'
 'Outras Receitas e Despesas Antes do Imposto' nan
 'Receita (Despesa) de Imposto das Operações Continuadas'
 'Receita (Despesa) de Imposto do Período'
 'Receita (Despesa) de Imposto Diferido'
 'Outra Receita (Despesa) de Imposto'
 'LUCRO/PREJUÍZO LÍQUIDO DO PERÍODO DAS OPERAÇÕES CONTINUADAS'
 'OPERAÇÕES DESCONTINUADAS'

```
 'Lucro (Prejuízo) do Período Após Imposto das Operações Descontinuadas'
 'LUCRO (PREJUÍZO) DO PERÍODO' 'Distribuição do Lucro/Prejuízo do Período'
 'Participações da Controladora' 'Lucro por Ação' 'Lucro por Ação Diluído'
 'Lucro por Ação de Operações Continuadas'
 'Lucro por Ação Diluído de Operações Continuadas'
 'Despesas de Amortização' 'Indenização por Antiguidade'
 'Despesas Financeiras' 'Vendas Domésticas' 'Vendas Internacionais'
 'Posição Cambial Líquida' 'Ativos de Contratos com Clientes'
 'Ativos de Direito de Uso' 'Passivos de Contratos com Clientes'
 'Receitas Diferidas (Exceto Passivos de Contratos com Clientes)'
 '  Passivos de Contratos com Clientes'
 'Receitas de Atividades de Investimento'
 'Despesas de Atividades de Investimento (-)'
 'Lucro/Prejuízo Operacional Antes das Despesas Financeiras'
 'Posição Líquida (Ativo/Passivo) Monetária em Moeda Estrangeira'
 'Posição Cambial Líquida (Incluindo Hedge)'
 'Fluxo de Caixa Líquido das Atividades Operacionais'
 'Lucro Antes dos Ajustes' 'Ajustes:' 'Amortização e Quotas de Exaustão'
 'Mudança nas Provisões' 'Outras Receitas/Despesas'
 'Lucro Operacional Antes das Mudanças no Capital de Giro (+)'
 'Mudanças no Capital de Giro'
 'Caixa Gerado por Atividades Principais (+)'
 'Fluxo de Caixa de Outras Atividades Operacionais'
 '  Investimentos em Capital Fixo'
 'Fluxo de Caixa de Outras Atividades de Investimento'
 'Fluxo de Caixa das Atividades de Investimento' 'Fluxo de Caixa Livre'
 'Variação nas Dívidas Financeiras' 'Pagamento de Dividendos'
 'Aumento de Capital'
 'Fluxo de Caixa de Outras Atividades de Financiamento'
 'Fluxo de Caixa das Atividades de Financiamento'
 'Aumento/Diminuição Líquido de Caixa e Equivalentes de Caixa Antes do Efeito das Di
ferenças de Conversão de Moeda Estrangeira'
 'Efeito das Diferenças de Conversão de Moeda Estrangeira sobre o Caixa e Equivalent
es de Caixa'
 'Outras Entradas/Saídas de Caixa' 'Variação no Caixa e Equivalentes'
 'Aumento em Outros Caixas e Equivalentes de Caixa'
 'Valores de Caixa no Início do Período' 'Caixa no Final do Período']
```

In [12]:

```python
# Checar valores nulos em todos os periodos de tempo
null_counts = df[["Anual", "9_Meses", "6_Meses", "3_Meses"]].isnull().sum()
print("\nNull counts por coluna:")
print(null_counts)
```

```
Null counts por coluna:
Anual      10349
9_Meses    10920
6_Meses     9799
3_Meses     9304
dtype: int64
```

In [13]:

```python
# 3. Checar quantidade de colunas com dados completos em todos os periodos de tempo
rows_with_complete_data = df.dropna(subset=["Anual", "9_Meses", "6_Meses", "3_Meses
print("\nTotal rows:", len(df))
print("Linhas com os 4 periodos de tempo nao nulos:", len(rows_with_complete_data))
```

```
Total rows: 507212
Linhas com os 4 periodos de tempo nao nulos: 487591
```

In [14]:
```
rows_with_complete_data
```

Out[14]:

	Descricao	Anual	9_Meses	6_Meses	3_Meses	OriginalFileNa
0	Ativos Circulantes	9457559.0	12071214.0	15581108.0	8897663.0	EMNIS_2009.x
1	Caixa e Equivalentes de Caixa	1610426.0	23911.0	14434.0	48297.0	EMNIS_2009.x
2	Investimentos Financeiros	0.0	0.0	0.0	0.0	EMNIS_2009.x
3	Contas a Receber	5026287.0	8501402.0	11668645.0	5436925.0	EMNIS_2009.x
4	Contas a Receber de Atividades do Setor Financ...	0.0	0.0	0.0	0.0	EMNIS_2009.x
...	...	...	...	...	...	
507207	Outras Entradas/Saídas de Caixa	0.0	0.0	0.0	0.0	DGNMO_2022.x
507208	Variação no Caixa e Equivalentes	380981383.0	78669533.0	89823875.0	-23447193.0	DGNMO_2022.x
507209	Aumento em Outros Caixas e Equivalentes de Caixa	0.0	0.0	0.0	0.0	DGNMO_2022.x
507210	Valores de Caixa no Início do Período	140545109.0	49168829.0	49168829.0	49168829.0	DGNMO_2022.x
507211	Caixa no Final do Período	521526492.0	127838362.0	138992704.0	25721636.0	DGNMO_2022.x

487591 rows × 8 columns

In [15]:
```
# Pivotagem para cada periodo do ano
periods = ['Anual', '9_Meses', '6_Meses', '3_Meses']
dfs = []

for period in periods:
    df_temp = rows_with_complete_data.pivot_table(
        index=['CompanyCode', 'Ano'],
        columns='Descricao',
        values=period,
        aggfunc='first'
    )
```

```
    # criação de uma coluna periodo para diferenciar o periodo de cada linha
    df_temp.columns = [f"{col}_{period}" for col in df_temp.columns]
    dfs.append(df_temp)
df_wide = pd.concat(dfs, axis=1).reset_index()
```

In [16]:
```
df_wide
```

Out[16]:

	CompanyCode	Ano	Investimentos em Capital Fixo_Anual	Passivos de Contratos com Clientes_Anual	(Subtotal)_Anual	Ajuste de Capital de Participação Mútua (-)_Anual
0	ADEL	2008	NaN	NaN	4.558265e+07	0.0
1	ADEL	2009	NaN	NaN	4.558265e+07	0.0
2	ADEL	2010	NaN	NaN	5.862145e+07	0.0
3	ADEL	2011	NaN	NaN	7.555084e+07	0.0
4	ADEL	2012	NaN	NaN	9.348416e+07	0.0
...	...	...	...	...	...	...
3823	ZOREN	2020	-1.881500e+08	0.0	4.047594e+09	0.0
3824	ZOREN	2021	-3.353620e+08	0.0	6.471306e+09	0.0
3825	ZOREN	2022	-9.923150e+08	0.0	2.259070e+10	0.0
3826	ZOREN	2023	-1.219082e+09	0.0	1.853404e+10	0.0
3827	ZOREN	2024	-1.202219e+09	0.0	1.341005e+10	0.0

3828 rows × 518 columns

In [17]:
```
import matplotlib.pyplot as plt
import seaborn as sns
'''
sample_cols = df_wide.select_dtypes('number').columns[:6]

fig, axes = plt.subplots(2, 3, figsize=(12, 6))
for col, ax in zip(sample_cols, axes.flatten()):
    sns.histplot(df_wide[col], kde=True, ax=ax, bins=30)
    ax.set_title(col)
plt.tight_layout()
plt.show()
'''
```

Out[17]:
```
"\nsample_cols = df_wide.select_dtypes('number').columns[:6]\n\nfig, axes = plt.su
bplots(2, 3, figsize=(12, 6))\nfor col, ax in zip(sample_cols, axes.flatten()):\n
sns.histplot(df_wide[col], kde=True, ax=ax, bins=30)\n    ax.set_title(col)\nplt.t
ight_layout()\nplt.show()\n"
```

In [18]:
```
# Each period becomes a separate observation
df_long = []
```

```
for period in ['3_Meses', '6_Meses', '9_Meses', 'Anual']:
    df_temp = rows_with_complete_data.pivot_table(
        index=['CompanyCode', 'Ano'],
        columns='Descricao',
        values=period,
        aggfunc='first'
    ).reset_index()

    df_temp['Periodo'] = period  # Add period identifier
    df_long.append(df_temp)

df_ml = pd.concat(df_long, ignore_index=True)

print(f"New shape: {df_ml.shape}")
# Expected: ~15,000 rows with your financial indicators as columns
```

```
New shape: (15312, 132)
```

In [19]:

```
# LIMPEZA DOS NOMES DAS COLUNAS
def clean_col_name(col_name):
    name = col_name.strip()
    name = name.replace(' ', '_').replace('(-)', '').replace('(PREJUÍZO)', '').repl
    name = ''.join(e for e in name if e.isalnum() or e == '_')
    name = name.lower()
    name = name.strip('_')
    return name

df_ml.columns = [clean_col_name(col) for col in df_ml.columns]
df_ml
```

Out[19]:

	companycode	ano	investimentos_em_capital_fixo	passivos_de_contratos_com_client
0	ADEL	2008	NaN	Na
1	ADEL	2009	NaN	Na
2	ADEL	2010	NaN	Na
3	ADEL	2011	NaN	Na
4	ADEL	2012	NaN	Na
...	...	...	...	
15307	ZOREN	2020	-1.881500e+08	(
15308	ZOREN	2021	-3.353620e+08	(
15309	ZOREN	2022	-9.923150e+08	(
15310	ZOREN	2023	-1.219082e+09	(
15311	ZOREN	2024	-1.202219e+09	(

15312 rows × 132 columns

In [20]:
```
df_ml.columns.tolist()
```

Out[20]:
```
['companycode',
 'ano',
 'investimentos_em_capital_fixo',
 'passivos_de_contratos_com_clientes',
 'subtotal',
 'ajuste_de_capital_de_participação_mútua',
 'ajustes',
 'amortização_e_quotas_de_exaustão',
 'ativo_fiscal_diferido',
 'ativos_biológicos',
 'ativos_circulantes',
 'ativos_imobilizados',
 'ativos_intangíveis',
 'ativos_não_circulantes',
 'ativos_não_circulantes_mantidos_para_venda',
 'ativos_de_contratos_com_clientes',
 'ativos_de_direito_de_uso',
 'aumento_de_capital',
 'aumento_em_outros_caixas_e_equivalentes_de_caixa',
 'aumento_diminuição_líquido_de_caixa_e_equivalentes_de_caixa_antes_do_efeito_das_
diferenças_de_conversão_de_moeda_estrangeira',
 'caixa_gerado_por_atividades_principais',
 'caixa_e_equivalentes_de_caixa',
 'caixa_no_final_do_período',
 'capital_social_integralizado',
 'contas_a_pagar',
 'contas_a_receber',
 'contas_a_receber_de_atividades_do_setor_financeiro',
 'custo_dos_produtos_serviços_vendidos',
 'despesas_financeiras',
 'despesas_financeiras_não_operacionais',
 'despesas_gerais_e_administrativas',
 'despesas_de_amortização',
 'despesas_de_atividades_de_investimento',
 'despesas_de_juros_taxas_prêmios_comissões_e_outras',
 'despesas_de_marketing_vendas_e_distribuição',
 'despesas_de_pesquisa_e_desenvolvimento',
 'diferenças_de_conversão_de_moeda_estrangeira',
 'distribuição_do_lucro_prejuízo_do_período',
 'dívidas_financeiras',
 'dívidas_de_atividades_do_setor_financeiro',
 'efeito_das_diferenças_de_conversão_de_moeda_estrangeira_sobre_o_caixa_e_equivale
ntes_de_caixa',
 'estoques',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'fluxo_de_caixa_de_outras_atividades_operacionais',
 'fluxo_de_caixa_de_outras_atividades_de_financiamento',
 'fluxo_de_caixa_de_outras_atividades_de_investimento',
 'fundos_de_reavaliação___valorização',
 'goodwill',
 'imóveis_de_investimento',
 'incentivos_e_ajuda_governamental',
 'indenização_por_antiguidade',
```

```
 'investimentos_avaliados_pelo_método_da_equivalência_patrimonial',
 'investimentos_financeiros',
 'lucro__do_período',
 'lucro_bruto',
 'lucro_operacional',
 'lucro_prejuízo_líquido_do_período_das_operações_continuadas',
 'lucro_prejuízo_do_período_após_imposto_das_operações_descontinuadas',
 'lucro_antes_dos_ajustes',
 'lucro_bruto_prejuízo_de_atividades_comerciais',
 'lucro_bruto_prejuízo_de_atividades_do_setor_financeiro',
 'lucro_operacional_antes_das_mudanças_no_capital_de_giro',
 'lucro_por_ação',
 'lucro_por_ação_diluído',
 'lucro_por_ação_diluído_de_operações_continuadas',
 'lucro_por_ação_de_operações_continuadas',
 'lucro_prejuízo_líquido_do_período',
 'lucro_prejuízo_operacional_antes_das_despesas_financeiras',
 'lucro_prejuízo_operacional_líquido',
 'lucros_prejuízos_acumulados',
 'mudança_nas_provisões',
 'mudanças_no_capital_de_giro',
 'operações_descontinuadas',
 'obrigações_fiscais_sobre_o_lucro_do_período',
 'operações_continuadas',
 'outra_receita_despesa_de_imposto',
 'outras_despesas_operacionais',
 'outras_dívidas',
 'outras_entradas_saídas_de_caixa',
 'outras_obrigações_financeiras',
 'outras_receitas_operacionais',
 'outras_receitas_e_despesas',
 'outras_receitas_e_despesas_antes_do_imposto',
 'outras_receitas_e_despesas_antes_do_lucro_operacional',
 'outras_receitas_despesas',
 'outros_ativos_circulantes',
 'outros_ativos_não_circulantes',
 'outros_ganhos_perdas_de_atividades_comerciais',
 'outros_ganhos_perdas_de_atividades_do_setor_financeiro',
 'outros_itens_do_patrimônio_líquido',
 'outros_passivos_circulantes',
 'outros_passivos_não_circulantes',
 'outros_recebíveis',
 'passivo_e_patrimônio_líquido',
 'pagamento_de_dividendos',
 'participação_nos_lucros_prejuízos_de_investimentos_avaliados_pelo_método_da_equi
valência_patrimonial',
 'participações_da_controladora',
 'participações_de_não_controladores',
 'passivo_fiscal_diferido',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'passivos_relacionados_a_ativos_não_circulantes_mantidos_para_venda',
 'passivos_de_contratos_com_clientes',
 'patrimônio_líquido',
 'patrimônio_líquido_atribuível_aos_acionistas_da_controladora',
 'posição_cambial_líquida',
```

```
 'posição_cambial_líquida_incluindo_hedge',
 'posição_líquida_ativo_passivo_monetária_em_moeda_estrangeira',
 'provisões_de_longo_prazo',
 'provisões_para_benefícios_a_empregados',
 'provisões_para_dívidas',
 'receita_despesa_de_imposto_diferido',
 'receita_despesa_de_imposto_das_operações_continuadas',
 'receita_despesa_de_imposto_do_período',
 'receita_de_vendas',
 'receitas_diferidas_exceto_passivos_de_contratos_com_clientes',
 'receitas_financeiras_não_operacionais',
 'receitas_de_atividades_de_investimento',
 'receitas_de_juros_taxas_prêmios_comissões_e_outras',
 'reservas_restritas_separadas_do_lucro',
 'reservas_de_capital_de_emissão_de_ações',
 'total_de_ativos',
 'total_do_passivo_e_patrimônico_líquido',
 'valores_de_caixa_no_início_do_período',
 'variação_nas_dívidas_financeiras',
 'variação_no_caixa_e_equivalentes',
 'vendas_domésticas',
 'vendas_internacionais',
 'periodo']
```

In [21]:

```
selected_columns = [
    'companycode',
    'ano',
    'periodo',
    'ativos_circulantes',
    'ativos_não_circulantes',
    'total_de_ativos',
    'passivos_circulantes',
    'passivos_não_circulantes',
    'total_do_passivo_e_patrimônico_líquido',
    'patrimônio_líquido',
    'receita_de_vendas',
    'lucro_bruto',
    'lucro_operacional',
    'lucro__do_período',
    'lucro_prejuízo_líquido_do_período',
    'despesas_financeiras',
    'despesas_gerais_e_administrativas',
    'custo_dos_produtos_serviços_vendidos',
    'fluxo_de_caixa_líquido_das_atividades_operacionais',
    'fluxo_de_caixa_livre',
    'fluxo_de_caixa_das_atividades_de_financiamento',
    'fluxo_de_caixa_das_atividades_de_investimento',
    'estoques',
    'contas_a_receber',
    'contas_a_pagar',
    'dívidas_financeiras',
    'despesas_de_amortização',
    'amortização_e_quotas_de_exaustão',
    'lucro_operacional_antes_das_mudanças_no_capital_de_giro',
]
```

```python
available_columns = []
df_ml_lower = {col.lower(): col for col in df_ml.columns}

for col in selected_columns:
    col_lower = col.lower()
    if col_lower in df_ml_lower:
        available_columns.append(df_ml_lower[col_lower])
    else:
        print(f"Coluna nao encontrada: '{col}'")

print(f"\nEncontramos {len(available_columns)} de {len(selected_columns)} colunas."
print(f"Colunas disponiveis: {available_columns}\n")
df_clean = df_ml[available_columns].copy()
```

```
Encontramos 29 de 29 colunas.
Colunas disponiveis: ['companycode', 'ano', 'periodo', 'ativos_circulantes', 'ativos
_não_circulantes', 'total_de_ativos', 'passivos_circulantes', 'passivos_não_circulan
tes', 'total_do_passivo_e_patrimônico_líquido', 'patrimônio_líquido', 'receita_de_ve
ndas', 'lucro_bruto', 'lucro_operacional', 'lucro__do_período', 'lucro_prejuízo_líqu
ido_do_período', 'despesas_financeiras', 'despesas_gerais_e_administrativas', 'custo
_dos_produtos_serviços_vendidos', 'fluxo_de_caixa_líquido_das_atividades_operacionai
s', 'fluxo_de_caixa_livre', 'fluxo_de_caixa_das_atividades_de_financiamento', 'fluxo
_de_caixa_das_atividades_de_investimento', 'estoques', 'contas_a_receber', 'contas_a
_pagar', 'dívidas_financeiras', 'despesas_de_amortização', 'amortização_e_quotas_de_
exaustão', 'lucro_operacional_antes_das_mudanças_no_capital_de_giro']
```

In [22]:
```python
df_clean.columns.tolist()
```

Out[22]:
```
['companycode',
 'ano',
 'periodo',
 'ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'lucro_operacional',
 'lucro__do_período',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'custo_dos_produtos_serviços_vendidos',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortização_e_quotas_de_exaustão',
 'lucro_operacional_antes_das_mudanças_no_capital_de_giro']
```

In [23]:
```python
# Mostra todas as colunas e quantas vezes cada uma aparece
print(df_clean.columns)

# Contar duplicadas
print("\nColunas duplicadas:")
print(df_clean.columns[df_clean.columns.duplicated(keep=False)])
```

```
Index(['companycode', 'ano', 'periodo', 'ativos_circulantes',
       'ativos_não_circulantes', 'total_de_ativos', 'passivos_circulantes',
       'passivos_não_circulantes', 'total_do_passivo_e_patrimônico_líquido',
       'patrimônio_líquido', 'receita_de_vendas', 'lucro_bruto',
       'lucro_operacional', 'lucro__do_período',
       'lucro_prejuízo_líquido_do_período', 'despesas_financeiras',
       'despesas_gerais_e_administrativas',
       'custo_dos_produtos_serviços_vendidos',
       'fluxo_de_caixa_líquido_das_atividades_operacionais',
       'fluxo_de_caixa_livre',
       'fluxo_de_caixa_das_atividades_de_financiamento',
       'fluxo_de_caixa_das_atividades_de_investimento', 'estoques',
       'contas_a_receber', 'contas_a_pagar', 'dívidas_financeiras',
       'despesas_de_amortização', 'amortização_e_quotas_de_exaustão',
       'lucro_operacional_antes_das_mudanças_no_capital_de_giro'],
      dtype='object')

Colunas duplicadas:
Index([], dtype='object')
```

In [24]:
```
df_clean.rename(columns={
    "lucro_operacional_antes_das_mudanças_no_capital_de_giro": "ebitda",
    "lucro_operacional": "ebit",
    "amortização_e_quotas_de_exaustão": "amortization"
}, inplace=True)
```

In [25]:
```
df_clean.columns.tolist()
```

Out[25]:
```
['companycode',
 'ano',
 'periodo',
 'ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'ebit',
 'lucro__do_período',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'custo_dos_produtos_serviços_vendidos',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortization',
 'ebitda']
```

In [26]:
```
df_clean.isnull().sum()
```

Out[26]:

```
companycode                                                 0
ano                                                         0
periodo                                                     0
ativos_circulantes                                          0
ativos_não_circulantes                                      0
total_de_ativos                                             0
passivos_circulantes                                        0
passivos_não_circulantes                                    0
total_do_passivo_e_patrimônico_líquido                      0
patrimônio_líquido                                          0
receita_de_vendas                                           0
lucro_bruto                                                 0
ebit                                                        0
lucro__do_período                                           0
lucro_prejuízo_líquido_do_período                           0
despesas_financeiras                                        0
despesas_gerais_e_administrativas                           0
custo_dos_produtos_serviços_vendidos                        0
fluxo_de_caixa_líquido_das_atividades_operacionais       7612
fluxo_de_caixa_livre                                     7608
fluxo_de_caixa_das_atividades_de_financiamento           7608
fluxo_de_caixa_das_atividades_de_investimento            7608
estoques                                                    0
contas_a_receber                                            0
contas_a_pagar                                              0
dívidas_financeiras                                         0
despesas_de_amortização                                     0
amortization                                             7608
ebitda                                                   7608
dtype: int64
```

In [27]:

```python
import numpy as np

print("ANTES DO CALCULO EBITDA")
print(f"\nVALORES FALTANTES:")
print(f"  EBIT: {df_clean['ebit'].isnull().sum()} ({df_clean['ebit'].isnull().sum()
print(f"  Amortization: {df_clean['amortization'].isnull().sum()} ({df_clean['amort
print(f"  EBITDA (original): {df_clean['ebitda'].isnull().sum()} ({df_clean['ebitda
```

```
ANTES DO CALCULO EBITDA

VALORES FALTANTES:
  EBIT: 0 (0.00%)
  Amortization: 7608 (49.69%)
  EBITDA (original): 7608 (49.69%)
```

In [28]:

```python
df_clean['amortization_filled'] = df_clean['amortization'].copy()
df_clean.head()
```

Out[28]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ativos
0	ADEL	2008	3_Meses	82082356.0	16000553.0	98082909.0
1	ADEL	2009	3_Meses	82082356.0	16000553.0	98082909.0
2	ADEL	2010	3_Meses	95518997.0	15304474.0	110823471.0
3	ADEL	2011	3_Meses	121815959.0	15542465.0	137358424.0
4	ADEL	2012	3_Meses	159584974.0	17071125.0	176656099.0

5 rows × 30 columns

In [29]:

```
# Only fill missing amortization with 5% of revenue
missing_amort_mask = df_clean['amortization'].isnull()
df_clean.loc[missing_amort_mask, 'amortization_filled'] = (
    df_clean.loc[missing_amort_mask, 'receita_de_vendas'] * 0.05
)

print(f"\n✅ Estimated {missing_amort_mask.sum()} missing amortization values as 5%
```

```
✅ Estimated 7608 missing amortization values as 5% of revenue
```

In [30]:

```
# Only calculate EBITDA where it's missing
# EBITDA = EBIT + Amortization (only for missing EBITDA values)
missing_ebitda_mask = df_clean['ebitda'].isnull()
has_ebit = df_clean['ebit'].notnull()

# Calculate missing EBITDA only where we have EBIT
can_calculate = missing_ebitda_mask & has_ebit

df_clean.loc[can_calculate, 'ebitda'] = (
    df_clean.loc[can_calculate, 'ebit'] +
    df_clean.loc[can_calculate, 'amortization_filled']
)

print(f"Calculated {can_calculate.sum()} missing EBITDA values using EBIT + Amortiz
print(f"Still missing: {(missing_ebitda_mask & ~has_ebit).sum()} EBITDA values (mis

# Final validation
print("AFTER EBITDA CALCULATION")
print(f"\nMissing values:")
print(f"  EBIT: {df_clean['ebit'].isnull().sum()} ({df_clean['ebit'].isnull().sum()
print(f"  Amortization (filled): {df_clean['amortization_filled'].isnull().sum()} (
print(f"  EBITDA (final): {df_clean['ebitda'].isnull().sum()} ({df_clean['ebitda'].
```

```
Calculated 7608 missing EBITDA values using EBIT + Amortization
Still missing: 0 EBITDA values (missing EBIT)
AFTER EBITDA CALCULATION

Missing values:
  EBIT: 0 (0.00%)
  Amortization (filled): 0 (0.00%)
  EBITDA (final): 0 (0.00%)
```

In [31]:
```
# Show breakdown of EBITDA sources
original_ebitda = (~missing_ebitda_mask).sum()
calculated_ebitda = can_calculate.sum()
still_missing = df_clean['ebitda'].isnull().sum()

print(f"\nEBITDA Data Sources:")
print(f"  Original values kept: {original_ebitda} ({original_ebitda/len(df_clean)*1
print(f"  Calculated from EBIT+Amort: {calculated_ebitda} ({calculated_ebitda/len(d
print(f"  Still missing: {still_missing} ({still_missing/len(df_clean)*100:.2f}%)")
```

```
EBITDA Data Sources:
  Original values kept: 7704 (50.31%)
  Calculated from EBIT+Amort: 7608 (49.69%)
  Still missing: 0 (0.00%)
```

In [32]:
```
# Sample of calculated values
if can_calculate.sum() > 0:
    print("\n" + "=" * 60)
    print("SAMPLE: Rows where EBITDA was CALCULATED")
    print("=" * 60)
    sample = df_clean[can_calculate].head(5)[
        ['companycode', 'ano', 'ebit', 'amortization',
         'amortization_filled', 'ebitda']
    ]
    print(sample.to_string())
```

```
============================================================
SAMPLE: Rows where EBITDA was CALCULATED
============================================================
  companycode   ano       ebit  amortization  amortization_filled       ebitda
0        ADEL  2008  7763300.0           NaN           1187559.15   8950859.15
1        ADEL  2009  7763300.0           NaN           1187559.15   8950859.15
2        ADEL  2010  7310082.0           NaN           1294831.80   8604913.80
3        ADEL  2011  8638365.0           NaN           1543602.40  10181967.40
4        ADEL  2012  9292049.0           NaN           1863623.75  11155672.75
```

In [33]:
```
# Sample of original values
if original_ebitda > 0:
    print("\n" + "=" * 60)
    print("SAMPLE: Rows where EBITDA was KEPT (original)")
    print("=" * 60)
    sample_orig = df_clean[~missing_ebitda_mask].head(5)[
        ['companycode', 'ano', 'ebit', 'amortization',
         'amortization_filled', 'ebitda']
    ]
    print(sample_orig.to_string())
```

```
============================================================
SAMPLE: Rows where EBITDA was KEPT (original)
============================================================
   companycode   ano        ebit  amortization  amortization_filled      ebitda
8         ADEL  2016  20397000.0     2770000.0            2770000.0  27104000.0
9         ADEL  2017  30558000.0     2976000.0            2976000.0  42210000.0
10        ADEL  2018  28955000.0     3149000.0            3149000.0  44231000.0
11        ADEL  2019  19704000.0     4219000.0            4219000.0  34518000.0
12        ADEL  2020   6713000.0     4314000.0            4314000.0  16862000.0
```

In [34]:
```
# EBITDA statistics
print("\n" + "=" * 60)
print("EBITDA STATISTICS")
print("=" * 60)
print(df_clean['ebitda'].describe())
```

```
============================================================
EBITDA STATISTICS
============================================================
count    1.531200e+04
mean     7.693855e+08
std      7.165359e+09
min     -2.370495e+10
25%      1.382810e+06
50%      1.939937e+07
75%      1.307190e+08
max      4.739620e+11
Name: ebitda, dtype: float64
```

In [35]:
```
df_clean['amortization'] = df_clean['amortization_filled']
df_clean.drop('amortization_filled', axis=1, inplace=True)
df_clean.head()
```

Out[35]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ativos
0	ADEL	2008	3_Meses	82082356.0	16000553.0	98082909.0
1	ADEL	2009	3_Meses	82082356.0	16000553.0	98082909.0
2	ADEL	2010	3_Meses	95518997.0	15304474.0	110823471.0
3	ADEL	2011	3_Meses	121815959.0	15542465.0	137358424.0
4	ADEL	2012	3_Meses	159584974.0	17071125.0	176656099.0

5 rows × 29 columns

In [36]:
```
df_clean.columns.tolist()
```

Out[36]:
```
['companycode',
 'ano',
 'periodo',
 'ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'ebit',
 'lucro__do_período',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'custo_dos_produtos_serviços_vendidos',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortization',
 'ebitda']
```

In [37]:
```
df_clean.isnull().sum()
```

Out[37]:
```
companycode                                                 0
ano                                                         0
periodo                                                     0
ativos_circulantes                                          0
ativos_não_circulantes                                      0
total_de_ativos                                             0
passivos_circulantes                                        0
passivos_não_circulantes                                    0
total_do_passivo_e_patrimônico_líquido                      0
patrimônio_líquido                                          0
receita_de_vendas                                           0
lucro_bruto                                                 0
ebit                                                        0
lucro__do_período                                           0
lucro_prejuízo_líquido_do_período                           0
despesas_financeiras                                        0
despesas_gerais_e_administrativas                           0
custo_dos_produtos_serviços_vendidos                        0
fluxo_de_caixa_líquido_das_atividades_operacionais       7612
fluxo_de_caixa_livre                                     7608
fluxo_de_caixa_das_atividades_de_financiamento           7608
fluxo_de_caixa_das_atividades_de_investimento            7608
estoques                                                    0
contas_a_receber                                            0
contas_a_pagar                                              0
dívidas_financeiras                                         0
despesas_de_amortização                                     0
amortization                                                0
ebitda                                                      0
dtype: int64
```

In [38]:
```
df_clean = df_clean.rename(columns={
    'lucro_prejuízo_líquido_do_período_das_operações_continuadas': 'lucro_liquido_o
    'custo_dos_produtos_serviços_vendidos': 'cogs',
    'lucro__do_período': 'lucro_periodo',
})
```

In [39]:
```
# Selecionar uma empresa com dados faltantes antes da interpolação
empresa_exemplo = df_clean[df_clean['fluxo_de_caixa_líquido_das_atividades_operacio
empresa_exemplo
```

Out[39]:
```
'ADEL'
```

In [40]:
```
df_original = df_clean.copy()
```

In [41]:
```
df_original
```

Out[41]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
1	ADEL	2009	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
2	ADEL	2010	3_Meses	9.551900e+07	1.530447e+07	1.108235e-
3	ADEL	2011	3_Meses	1.218160e+08	1.554246e+07	1.373584e-
4	ADEL	2012	3_Meses	1.595850e+08	1.707112e+07	1.766561e-
...	...	...	...	...	...	
15307	ZOREN	2020	Anual	4.047594e+09	1.735498e+10	2.140257e-
15308	ZOREN	2021	Anual	6.471306e+09	2.895511e+10	3.542642e-
15309	ZOREN	2022	Anual	2.259070e+10	9.515382e+10	1.177445e-
15310	ZOREN	2023	Anual	2.862619e+10	1.136030e+11	1.422292e-
15311	ZOREN	2024	Anual	1.341005e+10	1.053747e+11	1.187847e-

15312 rows × 29 columns

In [42]:

```
# Mapeia os períodos para datas de fim de trimestre
periodo_map = {
    '3_Meses': '-03-31',
    '6_Meses': '-06-30',
    '9_Meses': '-09-30',
    'Anual': '-12-31'
}

# Cria a coluna 'data' com base no ano e no final do período correspondente
df_clean['data'] = df_clean['ano'].astype(str) + df_clean['periodo'].map(periodo_ma

# Converte para datetime
df_clean['data'] = pd.to_datetime(df_clean['data'])
df_clean
```

Out[42]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
1	ADEL	2009	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
2	ADEL	2010	3_Meses	9.551900e+07	1.530447e+07	1.108235e-
3	ADEL	2011	3_Meses	1.218160e+08	1.554246e+07	1.373584e-
4	ADEL	2012	3_Meses	1.595850e+08	1.707112e+07	1.766561e-
...	...	...	...	...	...	
15307	ZOREN	2020	Anual	4.047594e+09	1.735498e+10	2.140257e-
15308	ZOREN	2021	Anual	6.471306e+09	2.895511e+10	3.542642e-
15309	ZOREN	2022	Anual	2.259070e+10	9.515382e+10	1.177445e-
15310	ZOREN	2023	Anual	2.862619e+10	1.136030e+11	1.422292e-
15311	ZOREN	2024	Anual	1.341005e+10	1.053747e+11	1.187847e-

15312 rows × 30 columns

In [43]:
```
df_original = df_clean.copy()
```

In [44]:
```
import matplotlib.pyplot as plt
import seaborn as sns
```

In [45]:
```
# Criar a versão interpolada
df_interpolado = df_clean.copy()
cols_fluxo = [
    'fluxo_de_caixa_líquido_das_atividades_operacionais'
]
df_interpolado[cols_fluxo] = df_interpolado.groupby('companycode')[cols_fluxo].tran
```

In [46]:
```
df_interpolado[cols_fluxo] = df_interpolado.groupby('companycode')[cols_fluxo].tran
```

In [47]:
```
# Selecionar uma empresa com dados faltantes
empresa_exemplo = df_original[df_original['fluxo_de_caixa_líquido_das_atividades_op
empresa_exemplo
```

Out[47]: 'ADEL'

In [48]:
```
# Filtrar essa empresa nas duas versões
df_orig_empresa = df_original[df_original['companycode'] == empresa_exemplo]
df_interp_empresa = df_interpolado[df_interpolado['companycode'] == empresa_exemplo
```

In [49]:
```
# Plotar
plt.figure(figsize=(12, 6))
sns.lineplot(
    data=df_interp_empresa,
    x='data',
    y='fluxo_de_caixa_líquido_das_atividades_operacionais',
    label='Interpolado',
    color='blue'
)

sns.scatterplot(
    data=df_orig_empresa,
    x='data',
    y='fluxo_de_caixa_líquido_das_atividades_operacionais',
    label='Original (com NaN)',
    color='red',
    zorder=5
)

plt.title(f'Fluxo de Caixa Operacional - Empresa {empresa_exemplo}\nAntes (pontos v
plt.xlabel('Data')
plt.ylabel('Fluxo de Caixa Operacional')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

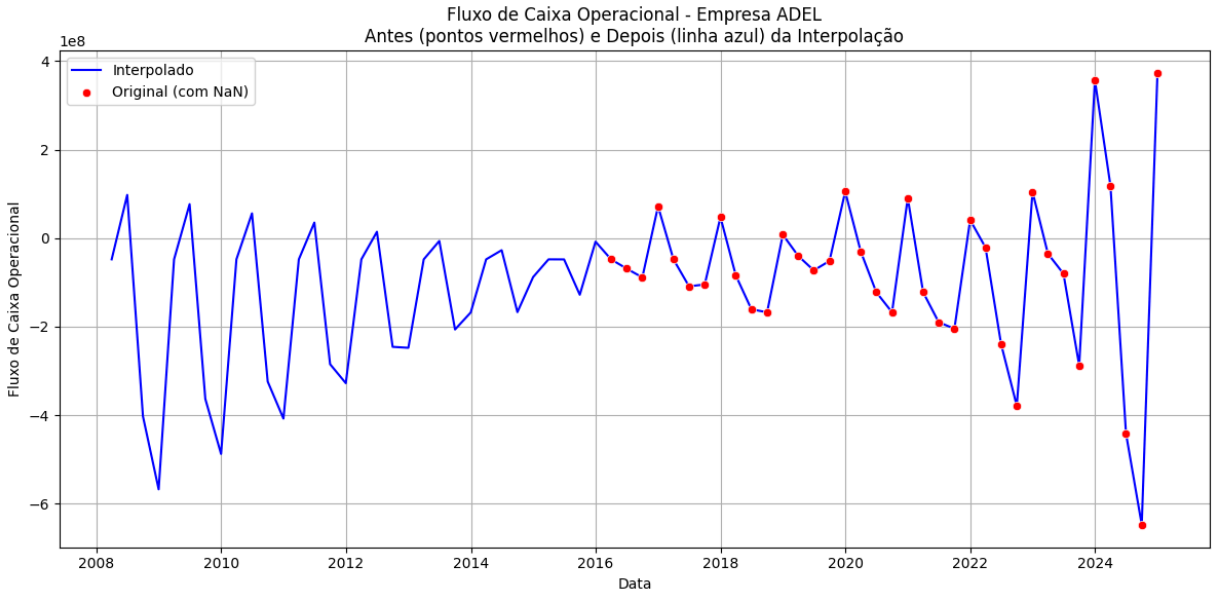

In [50]:
```
df_clean.isnull().sum()
```

Out[50]:

```
companycode                                                 0
ano                                                         0
periodo                                                     0
ativos_circulantes                                          0
ativos_não_circulantes                                      0
total_de_ativos                                             0
passivos_circulantes                                        0
passivos_não_circulantes                                    0
total_do_passivo_e_patrimônico_líquido                      0
patrimônio_líquido                                          0
receita_de_vendas                                           0
lucro_bruto                                                 0
ebit                                                        0
lucro_periodo                                               0
lucro_prejuízo_líquido_do_período                           0
despesas_financeiras                                        0
despesas_gerais_e_administrativas                           0
cogs                                                        0
fluxo_de_caixa_líquido_das_atividades_operacionais       7612
fluxo_de_caixa_livre                                     7608
fluxo_de_caixa_das_atividades_de_financiamento           7608
fluxo_de_caixa_das_atividades_de_investimento            7608
estoques                                                    0
contas_a_receber                                            0
contas_a_pagar                                              0
dívidas_financeiras                                         0
despesas_de_amortização                                     0
amortization                                                0
ebitda                                                      0
data                                                        0
dtype: int64
```

In [51]:

```python
# Ordenar por empresa e data
df_clean.sort_values(by=['companycode', 'data'], inplace=True)

# Interpolar fluxos de caixa por empresa no tempo
cols_fluxo = [
    'fluxo_de_caixa_líquido_das_atividades_operacionais',
    'fluxo_de_caixa_livre',
    'fluxo_de_caixa_das_atividades_de_financiamento',
    'fluxo_de_caixa_das_atividades_de_investimento'
]

df_clean[cols_fluxo] = df_clean.groupby('companycode')[cols_fluxo].transform(lambda
```

In [52]:

```python
df_clean
```

Out[52]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
3828	ADEL	2008	6_Meses	8.860061e+07	1.609915e+07	1.046998e-
7656	ADEL	2008	9_Meses	9.400968e+07	1.555129e+07	1.095610e-
11484	ADEL	2008	Anual	4.558265e+07	1.517075e+07	6.075340e-
1	ADEL	2009	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
...	...	...	...	...	...	
15310	ZOREN	2023	Anual	2.862619e+10	1.136030e+11	1.422292e-
3827	ZOREN	2024	3_Meses	1.561239e+10	8.488922e+10	1.005016e-
7655	ZOREN	2024	6_Meses	1.434187e+10	9.238784e+10	1.067297e-
11483	ZOREN	2024	9_Meses	1.539392e+10	9.982602e+10	1.152199e-
15311	ZOREN	2024	Anual	1.341005e+10	1.053747e+11	1.187847e-

15312 rows × 30 columns

In [53]:
```
df_clean.isnull().sum()
```

Out[53]:
```
companycode                                              0
ano                                                      0
periodo                                                  0
ativos_circulantes                                       0
ativos_não_circulantes                                   0
total_de_ativos                                          0
passivos_circulantes                                     0
passivos_não_circulantes                                 0
total_do_passivo_e_patrimônico_líquido                   0
patrimônio_líquido                                       0
receita_de_vendas                                        0
lucro_bruto                                              0
ebit                                                     0
lucro_periodo                                            0
lucro_prejuízo_líquido_do_período                        0
despesas_financeiras                                     0
despesas_gerais_e_administrativas                        0
cogs                                                     0
fluxo_de_caixa_líquido_das_atividades_operacionais       0
fluxo_de_caixa_livre                                     0
fluxo_de_caixa_das_atividades_de_financiamento           0
fluxo_de_caixa_das_atividades_de_investimento            0
estoques                                                 0
contas_a_receber                                         0
contas_a_pagar                                           0
dívidas_financeiras                                      0
despesas_de_amortização                                  0
amortization                                             0
ebitda                                                   0
data                                                     0
dtype: int64
```

In [54]:
```
df_clean.columns.tolist()
```

Out[54]:
```
['companycode',
 'ano',
 'periodo',
 'ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'ebit',
 'lucro_periodo',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'cogs',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortization',
 'ebitda',
 'data']
```

In [55]:
```
from feature_engineering import criar_indicadores_credito

df_indicadores = criar_indicadores_credito(df_clean)
df_indicadores
```

Out[55]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
3828	ADEL	2008	6_Meses	8.860061e+07	1.609915e+07	1.046998e-
7656	ADEL	2008	9_Meses	9.400968e+07	1.555129e+07	1.095610e-
11484	ADEL	2008	Anual	4.558265e+07	1.517075e+07	6.075340e-
1	ADEL	2009	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
...	...	...	...	...	...	
15310	ZOREN	2023	Anual	2.862619e+10	1.136030e+11	1.422292e-
3827	ZOREN	2024	3_Meses	1.561239e+10	8.488922e+10	1.005016e-
7655	ZOREN	2024	6_Meses	1.434187e+10	9.238784e+10	1.067297e-
11483	ZOREN	2024	9_Meses	1.539392e+10	9.982602e+10	1.152199e-
15311	ZOREN	2024	Anual	1.341005e+10	1.053747e+11	1.187847e-

15312 rows × 49 columns

In [56]:

```
print(df_indicadores.isnull().sum())
```

```
companycode                                                 0
ano                                                         0
periodo                                                     0
ativos_circulantes                                          0
ativos_não_circulantes                                      0
total_de_ativos                                             0
passivos_circulantes                                        0
passivos_não_circulantes                                    0
total_do_passivo_e_patrimônico_líquido                      0
patrimônio_líquido                                          0
receita_de_vendas                                           0
lucro_bruto                                                 0
ebit                                                        0
lucro_periodo                                               0
lucro_prejuízo_líquido_do_período                           0
despesas_financeiras                                        0
despesas_gerais_e_administrativas                           0
cogs                                                        0
fluxo_de_caixa_líquido_das_atividades_operacionais          0
fluxo_de_caixa_livre                                        0
fluxo_de_caixa_das_atividades_de_financiamento              0
fluxo_de_caixa_das_atividades_de_investimento               0
estoques                                                    0
contas_a_receber                                            0
contas_a_pagar                                              0
dívidas_financeiras                                         0
despesas_de_amortização                                     0
amortization                                                0
ebitda                                                      0
data                                                        0
liquidez_corrente                                          27
liquidez_seca                                              27
endividamento_total                                        27
divida_patrimonio                                          27
margem_bruta                                              465
margem_operacional                                        465
margem_liquida                                            465
margem_ebitda                                             465
roa                                                        27
roe                                                        27
fco_divida                                                2366
fcf_divida                                                2366
cobertura_juros                                            952
ebitda_divida                                             2366
giro_ativos                                                27
ciclo_estoques                                            671
ciclo_recebiveis                                          465
ciclo_pagamentos                                          671
ciclo_estoques_dias                                       671
dtype: int64
```

In [57]:
```
df_indicadores.columns.tolist()
```

Out[57]:
```
['companycode',
 'ano',
 'periodo',
 'ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'ebit',
 'lucro_periodo',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'cogs',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortization',
 'ebitda',
 'data',
 'liquidez_corrente',
 'liquidez_seca',
 'endividamento_total',
 'divida_patrimonio',
 'margem_bruta',
 'margem_operacional',
 'margem_liquida',
 'margem_ebitda',
 'roa',
 'roe',
 'fco_divida',
 'fcf_divida',
 'cobertura_juros',
 'ebitda_divida',
 'giro_ativos',
 'ciclo_estoques',
 'ciclo_recebiveis',
 'ciclo_pagamentos',
 'ciclo_estoques_dias']
```

In [58]:
```python
import seaborn as sns
import matplotlib.pyplot as plt

sns.boxplot(data=df_indicadores[['margem_operacional', 'margem_ebitda']])
plt.title('Distribuição das Margens Operacionais e EBITDA')
```

```
plt.grid(True)
plt.show()
```

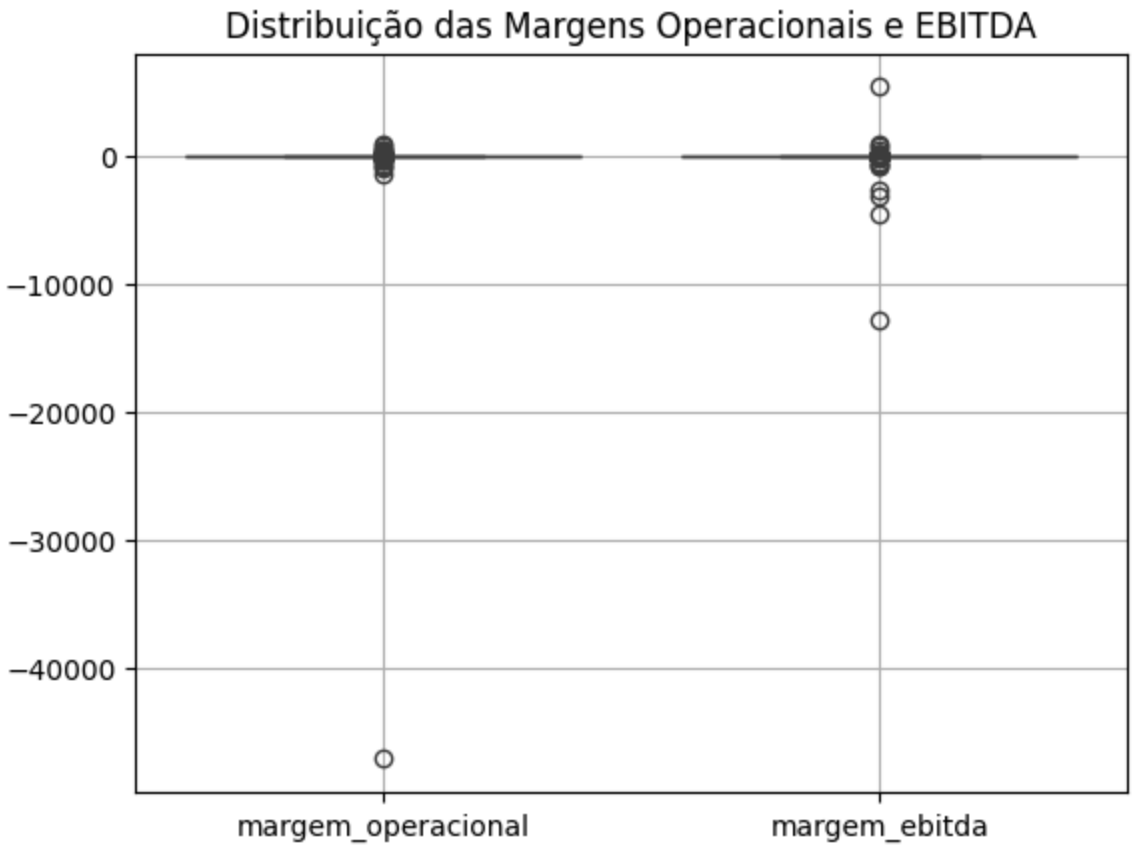

In [59]:
```
from avaliar import avaliar_indicadores_financeiros
df_avaliado = avaliar_indicadores_financeiros(df_indicadores)
```

In [60]:
```
df_avaliado
```

Out[60]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
3828	ADEL	2008	6_Meses	8.860061e+07	1.609915e+07	1.046998e-
7656	ADEL	2008	9_Meses	9.400968e+07	1.555129e+07	1.095610e-
11484	ADEL	2008	Anual	4.558265e+07	1.517075e+07	6.075340e-
1	ADEL	2009	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
...	...	...	...	...	...	
15310	ZOREN	2023	Anual	2.862619e+10	1.136030e+11	1.422292e-
3827	ZOREN	2024	3_Meses	1.561239e+10	8.488922e+10	1.005016e-
7655	ZOREN	2024	6_Meses	1.434187e+10	9.238784e+10	1.067297e-
11483	ZOREN	2024	9_Meses	1.539392e+10	9.982602e+10	1.152199e-
15311	ZOREN	2024	Anual	1.341005e+10	1.053747e+11	1.187847e-

15312 rows × 67 columns

In [61]:

```
print(df_avaliado.isnull().sum().to_string())
```

companycode	0
ano	0
periodo	0
ativos_circulantes	0
ativos_não_circulantes	0
total_de_ativos	0
passivos_circulantes	0
passivos_não_circulantes	0
total_do_passivo_e_patrimônico_líquido	0
patrimônio_líquido	0
receita_de_vendas	0
lucro_bruto	0
ebit	0
lucro_periodo	0
lucro_prejuízo_líquido_do_período	0
despesas_financeiras	0
despesas_gerais_e_administrativas	0
cogs	0
fluxo_de_caixa_líquido_das_atividades_operacionais	0
fluxo_de_caixa_livre	0
fluxo_de_caixa_das_atividades_de_financiamento	0
fluxo_de_caixa_das_atividades_de_investimento	0
estoques	0
contas_a_receber	0
contas_a_pagar	0
dívidas_financeiras	0
despesas_de_amortização	0
amortization	0
ebitda	0
data	0
liquidez_corrente	27
liquidez_seca	27
endividamento_total	27
divida_patrimonio	27
margem_bruta	465
margem_operacional	465
margem_liquida	465
margem_ebitda	465
roa	27
roe	27
fco_divida	2366
fcf_divida	2366
cobertura_juros	952
ebitda_divida	2366
giro_ativos	27
ciclo_estoques	671
ciclo_recebiveis	465
ciclo_pagamentos	671
ciclo_estoques_dias	671
liquidez_corrente_score	0
liquidez_seca_score	0
endividamento_total_score	0
divida_patrimonio_score	0
margem_bruta_score	0
margem_operacional_score	0
margem_ebitda_score	0

```
margem_liquida_score                                    0
roa_score                                               0
roe_score                                               0
fco_divida_score                                        0
fcf_divida_score                                        0
cobertura_juros_score                                   0
ebitda_divida_score                                     0
giro_ativos_score                                       0
ciclo_estoques_score                                    0
ciclo_recebiveis_score                                  0
ciclo_pagamentos_score                                  0
```

In [62]:
```python
from total_score import calcular_score_total
df_scored = calcular_score_total(df_avaliado)
df_scored
```

Out[62]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
3828	ADEL	2008	6_Meses	8.860061e+07	1.609915e+07	1.046998e-
7656	ADEL	2008	9_Meses	9.400968e+07	1.555129e+07	1.095610e-
11484	ADEL	2008	Anual	4.558265e+07	1.517075e+07	6.075340e-
1	ADEL	2009	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
...	...	...	...	...	...	
15310	ZOREN	2023	Anual	2.862619e+10	1.136030e+11	1.422292e-
3827	ZOREN	2024	3_Meses	1.561239e+10	8.488922e+10	1.005016e-
7655	ZOREN	2024	6_Meses	1.434187e+10	9.238784e+10	1.067297e-
11483	ZOREN	2024	9_Meses	1.539392e+10	9.982602e+10	1.152199e-
15311	ZOREN	2024	Anual	1.341005e+10	1.053747e+11	1.187847e-

15312 rows × 74 columns

In [63]:
```python
df_wide = df_scored.copy()
```

In [64]:
```python
df_wide.head()
```

Out[64]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	82082356.0	16000553.0	9808290
3828	ADEL	2008	6_Meses	88600612.0	16099148.0	10469976
7656	ADEL	2008	9_Meses	94009683.0	15551293.0	10956097
11484	ADEL	2008	Anual	45582654.0	15170747.0	6075340
1	ADEL	2009	3_Meses	82082356.0	16000553.0	9808290

5 rows × 74 columns

In [65]:

```
df_wide.columns.tolist()
```

Out[65]:
```
['companycode',
 'ano',
 'periodo',
 'ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'ebit',
 'lucro_periodo',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'cogs',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortization',
 'ebitda',
 'data',
 'liquidez_corrente',
 'liquidez_seca',
 'endividamento_total',
 'divida_patrimonio',
 'margem_bruta',
 'margem_operacional',
 'margem_liquida',
 'margem_ebitda',
 'roa',
 'roe',
 'fco_divida',
 'fcf_divida',
 'cobertura_juros',
 'ebitda_divida',
 'giro_ativos',
 'ciclo_estoques',
 'ciclo_recebiveis',
 'ciclo_pagamentos',
 'ciclo_estoques_dias',
 'liquidez_corrente_score',
 'liquidez_seca_score',
 'endividamento_total_score',
 'divida_patrimonio_score',
 'margem_bruta_score',
 'margem_operacional_score',
 'margem_ebitda_score',
```

```
 'margem_liquida_score',
 'roa_score',
 'roe_score',
 'fco_divida_score',
 'fcf_divida_score',
 'cobertura_juros_score',
 'ebitda_divida_score',
 'giro_ativos_score',
 'ciclo_estoques_score',
 'ciclo_recebiveis_score',
 'ciclo_pagamentos_score',
 'liquidez_media',
 'alavancagem_media',
 'rentabilidade_media',
 'retornos_media',
 'caixa_media',
 'eficiencia_media',
 'score_total']
```

In [66]:
```
df_scored['score_total'].mean()
```

Out[66]:
```
np.float64(1.8607987199582026)
```

In [67]:
```
df_scored['score_total'].max()
```

Out[67]:
```
np.float64(4.4375)
```

In [68]:
```
df_scored['score_total'].min()
```

Out[68]:
```
np.float64(0.4375)
```

In [69]:
```
df_scored['score_total'].nunique()
```

Out[69]:
```
503
```

In [70]:
```python
def checar_scores_validos(df):
    """
    Verifica se todas as colunas *_score possuem valores válidos (0 a 5).
    Retorna dicionário com percentual de valores válidos por coluna.
    """
    import numpy as np

    score_cols = [col for col in df.columns if col.endswith('_score')]
    resultados = {}

    for col in score_cols:
        total = df[col].notnull().sum()
        validos = df[col].isin([0, 1, 2, 3, 4, 5]).sum()
        resultados[col] = {
            'percentual_valido': round(100 * validos / total, 2),
            'total_valores': total,
            'valores_invalidos': total - validos
        }

    return resultados
```

In [71]:
```python
resultados_validacao = checar_scores_validos(df_scored)
import pprint
pprint.pprint(resultados_validacao)
```

```
{'ciclo_estoques_score': {'percentual_valido': np.float64(100.0),
                          'total_valores': np.int64(15312),
                          'valores_invalidos': np.int64(0)},
 'ciclo_pagamentos_score': {'percentual_valido': np.float64(100.0),
                            'total_valores': np.int64(15312),
                            'valores_invalidos': np.int64(0)},
 'ciclo_recebiveis_score': {'percentual_valido': np.float64(100.0),
                            'total_valores': np.int64(15312),
                            'valores_invalidos': np.int64(0)},
 'cobertura_juros_score': {'percentual_valido': np.float64(100.0),
                           'total_valores': np.int64(15312),
                           'valores_invalidos': np.int64(0)},
 'divida_patrimonio_score': {'percentual_valido': np.float64(100.0),
                             'total_valores': np.int64(15312),
                             'valores_invalidos': np.int64(0)},
 'ebitda_divida_score': {'percentual_valido': np.float64(100.0),
                         'total_valores': np.int64(15312),
                         'valores_invalidos': np.int64(0)},
 'endividamento_total_score': {'percentual_valido': np.float64(100.0),
                               'total_valores': np.int64(15312),
                               'valores_invalidos': np.int64(0)},
 'fcf_divida_score': {'percentual_valido': np.float64(100.0),
                      'total_valores': np.int64(15312),
                      'valores_invalidos': np.int64(0)},
 'fco_divida_score': {'percentual_valido': np.float64(100.0),
                      'total_valores': np.int64(15312),
                      'valores_invalidos': np.int64(0)},
 'giro_ativos_score': {'percentual_valido': np.float64(100.0),
                       'total_valores': np.int64(15312),
                       'valores_invalidos': np.int64(0)},
 'liquidez_corrente_score': {'percentual_valido': np.float64(100.0),
                             'total_valores': np.int64(15312),
                             'valores_invalidos': np.int64(0)},
 'liquidez_seca_score': {'percentual_valido': np.float64(100.0),
                         'total_valores': np.int64(15312),
                         'valores_invalidos': np.int64(0)},
 'margem_bruta_score': {'percentual_valido': np.float64(100.0),
                        'total_valores': np.int64(15312),
                        'valores_invalidos': np.int64(0)},
 'margem_ebitda_score': {'percentual_valido': np.float64(100.0),
                         'total_valores': np.int64(15312),
                         'valores_invalidos': np.int64(0)},
 'margem_liquida_score': {'percentual_valido': np.float64(100.0),
                          'total_valores': np.int64(15312),
                          'valores_invalidos': np.int64(0)},
 'margem_operacional_score': {'percentual_valido': np.float64(100.0),
                              'total_valores': np.int64(15312),
                              'valores_invalidos': np.int64(0)},
 'roa_score': {'percentual_valido': np.float64(100.0),
               'total_valores': np.int64(15312),
               'valores_invalidos': np.int64(0)},
 'roe_score': {'percentual_valido': np.float64(100.0),
               'total_valores': np.int64(15312),
               'valores_invalidos': np.int64(0)}}
```

In [72]:
```
# Seleção das empresas desejadas
empresas_destaque = ['THYAO', 'CCOLA', 'ASELS']
df_empresas = df_scored[df_scored['companycode'].isin(empresas_destaque)]
ultimos_scores = {}
for empresa in empresas_destaque:
    ult_score = df_scored[df_scored['companycode'] == empresa].sort_values('data',
    ultimos_scores[empresa] = ult_score
```

In [73]:
```
df_empresas['companycode'].unique()
```

Out[73]:
```
array(['ASELS', 'CCOLA', 'THYAO'], dtype=object)
```

In [74]:
```
# Score médio e mediano geral
media_geral = df_scored['score_total'].mean()
mediana_geral = df_scored['score_total'].median()
print(f'Media geral = {media_geral} e Mediana Geral = {mediana_geral}')
```

```
Media geral = 1.8607987199582026 e Mediana Geral = 1.7625
```

In [75]:
```
# Plot
plt.figure(figsize=(12, 6))
sns.histplot(df_scored['score_total'], kde=True, bins=30, color='lightgray', label=

# Linhas de média e mediana
plt.axvline(media_geral, color='red', linestyle='--', label=f'Média Geral: {media_g
plt.axvline(mediana_geral, color='green', linestyle='--', label=f'Mediana Geral: {m

# Linhas dos scores mais recentes das empresas
for empresa, score in ultimos_scores.items():
    plt.axvline(score, linestyle='-', label=f'{empresa} (Score mais recente): {scor

plt.title('Distribuição do Score Total com Destaque para Últimos Scores de Empresas
plt.xlabel('Score Total (0 a 5)')
plt.ylabel('Frequência')
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

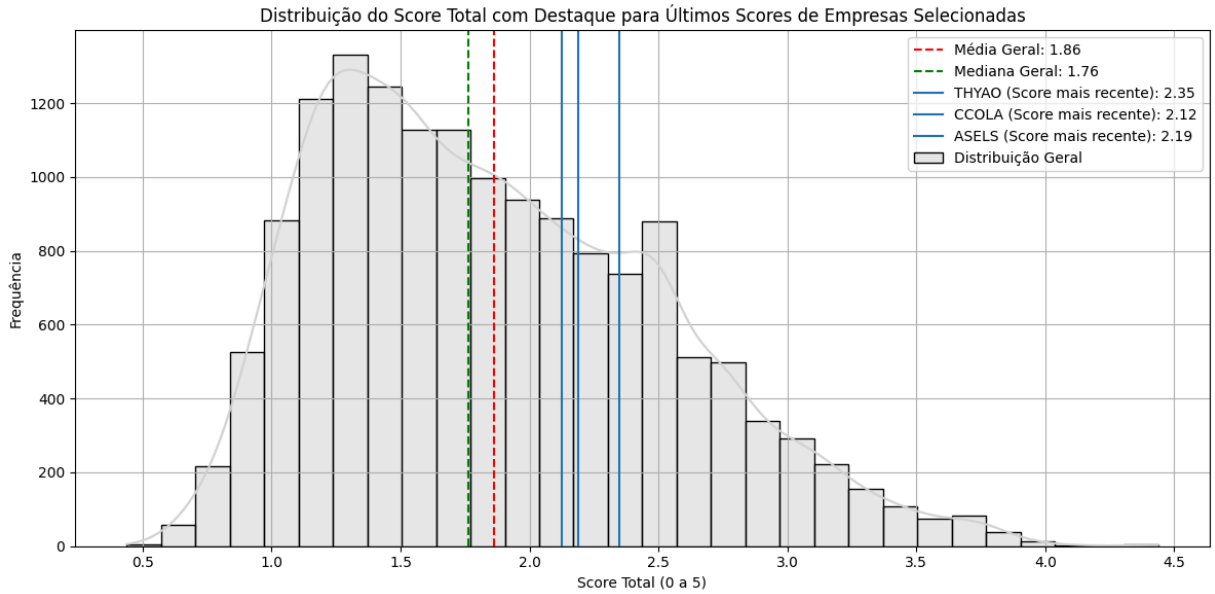

In [76]:
```
# Média de score por data (trimestre)
media_por_periodo = df_scored.groupby('data')['score_total'].mean().sort_values(asc

# Top 10 trimestres com maior média
top_periodos = media_por_periodo.head(10)

print("Top períodos com maior score médio:")
print(top_periodos)
```

```
Top períodos com maior score médio:
data
2022-09-30    2.253249
2021-12-31    2.200826
2022-06-30    2.081498
2020-12-31    2.079405
2021-09-30    2.078910
2019-12-31    2.058425
2018-12-31    2.056773
2023-12-31    2.048678
2023-09-30    2.023348
2022-12-31    2.014703
Name: score_total, dtype: float64
```

In [77]:
```
# Média de score por data (trimestre)
media_por_periodo = df_scored.groupby('data')['score_total'].median().sort_values(a

# Top 10 trimestres com maior média
top_periodos = media_por_periodo.head(10)

print("Top períodos com maior score mediano:")
print(top_periodos)
```

```
Top períodos com maior score mediano:
data
2022-09-30    2.1750
2021-12-31    2.1375
2023-12-31    2.0500
2022-06-30    2.0375
2019-12-31    2.0250
2020-12-31    2.0125
2021-09-30    2.0125
2018-12-31    1.9875
2017-12-31    1.9500
2023-09-30    1.9500
Name: score_total, dtype: float64
```

In [78]:

```
# Último período do dataset
ultimo_periodo = df_scored['data'].max()

# Filtrar pelo último período
df_ultimo = df_scored[df_scored['data'] == ultimo_periodo]

# Top 5 empresas com maior score_total
top_empresas = df_ultimo[['companycode', 'score_total']].sort_values(by='score_tota

print("Top 5 empresas com maior score no período mais recente:")
print(top_empresas)
```

```
Top 5 empresas com maior score no período mais recente:
      companycode  score_total
14084       MARKA       3.6750
11619       AKMGY       3.2875
13086       FMIZP       3.2375
11855       ATAGY       3.1375
12362       CLEBI       3.0250
```

In [79]:

```
# Empresas alvo
empresas_destaque = ['THYAO', 'CCOLA', 'ASELS']

# Filtrar somente essas empresas
df_empresas = df_scored[df_scored['companycode'].isin(empresas_destaque)]

# Ordenar por empresa e data
df_empresas = df_empresas.sort_values(by=['companycode', 'data'])

# Agrupar e pegar os 3 últimos períodos
ultimos_tres = df_empresas.groupby('companycode').tail(4)

# Resultado organizado
print(ultimos_tres[['companycode', 'data', 'score_total']].sort_values(['companycod
```

```
      companycode       data  score_total
337         ASELS 2024-03-31       1.3375
4165        ASELS 2024-06-30       1.3625
7993        ASELS 2024-09-30       1.5125
11821       ASELS 2024-12-31       2.1875
810         CCOLA 2024-03-31       1.6625
4638        CCOLA 2024-06-30       1.9625
8466        CCOLA 2024-09-30       2.2000
12294       CCOLA 2024-12-31       2.1250
3454        THYAO 2024-03-31       1.1625
7282        THYAO 2024-06-30       1.8125
11110       THYAO 2024-09-30       2.2625
14938       THYAO 2024-12-31       2.3500
```

In [80]:

```python
# Identificar os 3 últimos períodos disponíveis
ultimos_tres_periodos = df_scored['data'].drop_duplicates().sort_values(ascending=F

# Filtrar os dados para esses 3 períodos
df_ultimos_tres = df_scored[df_scored['data'].isin(ultimos_tres_periodos)]

# Para cada período, pegar o Top 5 empresas com maior score
for periodo in sorted(ultimos_tres_periodos):
    print(f"\n📅 Período: {periodo.strftime('%Y-%m-%d')}")
    top_empresas = (
        df_ultimos_tres[df_ultimos_tres['data'] == periodo]
        .sort_values(by='score_total', ascending=False)
        .head(5)
    )
    print(top_empresas[['companycode', 'score_total']])
```

```
📅 Período: 2024-03-31
     companycode  score_total
2600       MARKA       3.3375
710        BRYAT       2.9375
2649       METRO       2.8125
3131       RALYH       2.8125
135        AKMGY       2.7875

📅 Período: 2024-06-30
     companycode  score_total
6428       MARKA       3.7250
3963       AKMGY       3.1375
5430       FMIZP       3.0000
6993       RYSAS       2.9000
4386       BANVT       2.7250

📅 Período: 2024-09-30
      companycode  score_total
10256       MARKA       3.6750
10821       RYSAS       3.3500
10719       PKENT       3.1500
7791        AKMGY       3.1375
9258        FMIZP       3.1125

📅 Período: 2024-12-31
      companycode  score_total
14084       MARKA       3.6750
11619       AKMGY       3.2875
13086       FMIZP       3.2375
11855       ATAGY       3.1375
12362       CLEBI       3.0250
```

In [81]:

```python
from collections import Counter

# Lista para guardar todas as aparições no top 5 por trimestre
top5_empresas_ao_longo_do_tempo = []

# Iterar sobre cada trimestre (data)
for periodo in df_scored['data'].drop_duplicates().sort_values():
    top5 = (
        df_scored[df_scored['data'] == periodo]
        .sort_values(by='score_total', ascending=False)
        .head(5)
        ['companycode']
        .tolist()
    )
    top5_empresas_ao_longo_do_tempo.extend(top5)

# Contar quantas vezes cada empresa apareceu no Top 5
contagem_top5 = Counter(top5_empresas_ao_longo_do_tempo)

# Converter para DataFrame e ordenar
df_top5_frequentes = (
    pd.DataFrame.from_dict(contagem_top5, orient='index', columns=['aparicoes_top5'
    .sort_values(by='aparicoes_top5', ascending=False)
    .reset_index()
```

```
    .rename(columns={'index': 'companycode'})
)

# Mostrar Top 5 empresas mais frequentes no Top 5
print("Empresas com mais aparições no Top 5 de score total por trimestre:")
print(df_top5_frequentes.head(5))
```

```
Empresas com mais aparições no Top 5 de score total por trimestre:
  companycode  aparicoes_top5
0       AKMGY              36
1       KOZAA              35
2       IPEKE              32
3       FMIZP              30
4       ALGYO              23
```

In [82]:

```
'''
from ydata_profiling import ProfileReport

profile = ProfileReport(
    df_scored,
    title="Credit Default EDA (Minimal)",
    explorative=True,   # less visual complexity, faster
    minimal=False,
    progress_bar=True
)

profile.to_file("FINAL_EDA_MODEL_V2.html")
print(" EDA report generated successfully: FINAL_EDA_MODEL.html")

'''
```

Out[82]:

```
'\nfrom ydata_profiling import ProfileReport\n\nprofile = ProfileReport(\n    df_s
cored,\n    title="Credit Default EDA (Minimal)",\n    explorative=True,   # less
visual complexity, faster\n    minimal=False,        \n    progress_bar=True\n)\n
\nprofile.to_file("FINAL_EDA_MODEL_V2.html")\nprint(" EDA report generated success
fully: FINAL_EDA_MODEL.html")\n\n'
```

In [83]:

```
df_model = df_scored.copy()
```

In [84]:

```
df_model=df_model.drop(columns=[
'liquidez_corrente_score',
 'liquidez_seca_score',
 'endividamento_total_score',
 'divida_patrimonio_score',
 'margem_bruta_score',
 'margem_operacional_score',
 'margem_ebitda_score',
 'margem_liquida_score',
 'roa_score',
 'roe_score',
 'fco_divida_score',
 'fcf_divida_score',
 'cobertura_juros_score',
 'ebitda_divida_score',
 'giro_ativos_score',
 'ciclo_estoques_score',
```

```
 'ciclo_recebiveis_score',
 'ciclo_pagamentos_score',
 'liquidez_media',
 'alavancagem_media',
 'rentabilidade_media',
 'retornos_media',
 'caixa_media',
 'eficiencia_media'],axis=1)
```

In [85]:
```
df_corr = df_model.copy()
df_corr = df_corr.drop(columns=['companycode', 'ano', 'periodo'])
```

In [86]:
```
# Calculate correlation matrix
corr_matrix = df_corr.corr()
```

In [87]:
```
corrs=corr_matrix.loc['score_total'].drop('score_total').sort_values(ascending=Fals
print(corrs)
```

```
roa                                                     0.384311
liquidez_corrente                                       0.223667
liquidez_seca                                           0.222524
margem_bruta                                            0.124955
giro_ativos                                             0.103740
lucro_prejuízo_líquido_do_período                       0.075824
lucro_periodo                                           0.074820
fluxo_de_caixa_livre                                    0.052917
ebit                                                    0.047604
ebitda                                                  0.044814
fluxo_de_caixa_líquido_das_atividades_operacionais      0.039955
data                                                    0.037253
ebitda_divida                                           0.027605
margem_ebitda                                           0.023033
lucro_bruto                                             0.019589
margem_liquida                                          0.018681
ciclo_pagamentos                                        0.015692
fco_divida                                              0.014775
receita_de_vendas                                       0.013373
margem_operacional                                      0.012307
amortization                                            0.011959
ciclo_estoques                                          0.010750
ciclo_estoques_dias                                     0.010750
roe                                                     0.008936
despesas_financeiras                                    0.007570
despesas_gerais_e_administrativas                       0.005644
despesas_de_amortização                                 0.005487
fcf_divida                                              0.002391
patrimônio_líquido                                     -0.002065
divida_patrimonio                                      -0.009400
cogs                                                   -0.009674
ativos_circulantes                                     -0.013091
fluxo_de_caixa_das_atividades_de_investimento          -0.014060
total_de_ativos                                        -0.014623
total_do_passivo_e_patrimônico_líquido                 -0.014623
passivos_não_circulantes                               -0.014803
ativos_não_circulantes                                 -0.015923
passivos_circulantes                                   -0.017922
contas_a_receber                                       -0.023036
contas_a_pagar                                         -0.023137
ciclo_recebiveis                                       -0.024163
cobertura_juros                                        -0.026371
dívidas_financeiras                                    -0.030630
estoques                                               -0.032475
fluxo_de_caixa_das_atividades_de_financiamento         -0.048864
endividamento_total                                    -0.335434
Name: score_total, dtype: float64
```

In [88]:

```
import phik
from phik import resources, report
phi_k_corr = df_corr.phik_matrix()
phi_k_corr
```

```
interval columns not set, guessing: ['ativos_circulantes', 'ativos_não_circulantes',
'total_de_ativos', 'passivos_circulantes', 'passivos_não_circulantes', 'total_do_pas
sivo_e_patrimônico_líquido', 'patrimônio_líquido', 'receita_de_vendas', 'lucro_brut
o', 'ebit', 'lucro_periodo', 'lucro_prejuízo_líquido_do_período', 'despesas_financei
ras', 'despesas_gerais_e_administrativas', 'cogs', 'fluxo_de_caixa_líquido_das_ativi
dades_operacionais', 'fluxo_de_caixa_livre', 'fluxo_de_caixa_das_atividades_de_finan
ciamento', 'fluxo_de_caixa_das_atividades_de_investimento', 'estoques', 'contas_a_re
ceber', 'contas_a_pagar', 'dívidas_financeiras', 'despesas_de_amortização', 'amortiz
ation', 'ebitda', 'liquidez_corrente', 'liquidez_seca', 'endividamento_total', 'divi
da_patrimonio', 'margem_bruta', 'margem_operacional', 'margem_liquida', 'margem_ebit
da', 'roa', 'roe', 'fco_divida', 'fcf_divida', 'cobertura_juros', 'ebitda_divida',
'giro_ativos', 'ciclo_estoques', 'ciclo_recebiveis', 'ciclo_pagamentos', 'ciclo_esto
ques_dias', 'score_total']
```

Out[88]:

	ativos_circulantes	ativos_não_circulantes
ativos_circulantes	1.000000	0.956728
ativos_não_circulantes	0.956728	1.000000
total_de_ativos	0.991791	0.968741
passivos_circulantes	0.985686	0.958251
passivos_não_circulantes	0.933780	0.946245
total_do_passivo_e_patrimônico_líquido	0.991791	0.968741
patrimônio_líquido	0.917932	0.952957
receita_de_vendas	0.752920	0.788066
lucro_bruto	0.811524	0.799390
ebit	0.761388	0.791097
lucro_periodo	0.684239	0.763486
lucro_prejuízo_líquido_do_período	0.622230	0.736890
despesas_financeiras	0.815172	0.821762
despesas_gerais_e_administrativas	0.873145	0.847769
cogs	0.729475	0.766106
fluxo_de_caixa_líquido_das_atividades_operacionais	0.797820	0.814425
fluxo_de_caixa_livre	0.732452	0.753007
fluxo_de_caixa_das_atividades_de_financiamento	0.811528	0.867359
fluxo_de_caixa_das_atividades_de_investimento	0.793057	0.820691
estoques	0.919769	0.901758
contas_a_receber	0.902214	0.901103
contas_a_pagar	0.806920	0.756841
dívidas_financeiras	0.874953	0.917824
despesas_de_amortização	0.000000	0.000000
amortization	0.807293	0.873330
ebitda	0.728707	0.798715
data	0.059845	0.154924
liquidez_corrente	0.000000	0.000000
liquidez_seca	0.000000	0.000000
endividamento_total	0.000000	0.000000

	ativos_circulantes	ativos_não_circulantes
divida_patrimonio	0.000000	0.000000
margem_bruta	0.047980	0.040627
margem_operacional	0.000000	0.000000
margem_liquida	0.000000	0.000000
margem_ebitda	0.000000	0.000000
roa	0.000000	0.000000
roe	0.000000	0.000000
fco_divida	0.000000	0.000000
fcf_divida	0.000000	0.000000
cobertura_juros	0.000000	0.000000
ebitda_divida	0.000000	0.000000
giro_ativos	0.000000	0.000000
ciclo_estoques	0.000000	0.000000
ciclo_recebiveis	0.000000	0.000000
ciclo_pagamentos	0.000000	0.000000
ciclo_estoques_dias	0.000000	0.000000
score_total	0.000000	0.000000

47 rows × 47 columns

In [89]:
```
phik_corrs=phi_k_corr.loc['score_total'].drop('score_total').sort_values(ascending=
phik_corrs
```

Out[89]:

```
margem_bruta                                          0.209311
data                                                  0.206547
liquidez_seca                                         0.181178
liquidez_corrente                                     0.180622
roa                                                   0.121704
giro_ativos                                           0.118563
endividamento_total                                   0.097812
lucro_prejuízo_líquido_do_período                     0.081618
ebitda_divida                                         0.066451
fcf_divida                                            0.062589
cobertura_juros                                       0.049844
roe                                                   0.040582
lucro_periodo                                         0.034232
ebitda                                                0.033225
ciclo_recebiveis                                      0.025782
fluxo_de_caixa_líquido_das_atividades_operacionais    0.022786
fco_divida                                            0.014912
ciclo_estoques                                        0.006424
ciclo_estoques_dias                                   0.006424
despesas_financeiras                                  0.000000
lucro_bruto                                           0.000000
ebit                                                  0.000000
ativos_não_circulantes                                0.000000
ativos_circulantes                                    0.000000
passivos_circulantes                                  0.000000
total_de_ativos                                       0.000000
receita_de_vendas                                     0.000000
patrimônio_líquido                                    0.000000
passivos_não_circulantes                              0.000000
total_do_passivo_e_patrimônico_líquido                0.000000
despesas_gerais_e_administrativas                     0.000000
dívidas_financeiras                                   0.000000
despesas_de_amortização                               0.000000
fluxo_de_caixa_das_atividades_de_financiamento        0.000000
fluxo_de_caixa_das_atividades_de_investimento         0.000000
estoques                                              0.000000
contas_a_receber                                      0.000000
contas_a_pagar                                        0.000000
cogs                                                  0.000000
fluxo_de_caixa_livre                                  0.000000
amortization                                          0.000000
margem_liquida                                        0.000000
margem_ebitda                                         0.000000
divida_patrimonio                                     0.000000
margem_operacional                                    0.000000
ciclo_pagamentos                                      0.000000
Name: score_total, dtype: float64
```

In [90]:

```
df_model.columns.tolist()
```

Out[90]:
```
['companycode',
 'ano',
 'periodo',
 'ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'ebit',
 'lucro_periodo',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'cogs',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortization',
 'ebitda',
 'data',
 'liquidez_corrente',
 'liquidez_seca',
 'endividamento_total',
 'divida_patrimonio',
 'margem_bruta',
 'margem_operacional',
 'margem_liquida',
 'margem_ebitda',
 'roa',
 'roe',
 'fco_divida',
 'fcf_divida',
 'cobertura_juros',
 'ebitda_divida',
 'giro_ativos',
 'ciclo_estoques',
 'ciclo_recebiveis',
 'ciclo_pagamentos',
 'ciclo_estoques_dias',
 'score_total']
```

In [91]:
```
df_model.to_csv('C:/Users/Lucas/Documents/usp/TCC-CD-USP/archives/df_model_V3.csv',
```

In [92]:
```
import matplotlib.pyplot as plt
import seaborn as sns
import pandas as pd
import numpy as np

# Configuração de estilo para gráficos acadêmicos
sns.set_theme(style="whitegrid", context="paper", font_scale=1.2)
plt.rcParams['figure.dpi'] = 150

# --- PASSO 1: Garantir que as colunas das categorias existem ---
# Baseado na tua descrição e no pyeda.py, estas parecem ser as colunas principais.
# Se 'ciclos_media' não existir no df_scored, calculamos a média dos scores de cicl

cols_ciclos = ['ciclo_estoques_score', 'ciclo_recebiveis_score', 'ciclo_pagamentos_
# Verifica se as colunas de ciclos existem antes de calcular
if set(cols_ciclos).issubset(df_scored.columns) and 'ciclos_media' not in df_scored
    df_scored['ciclos_media'] = df_scored[cols_ciclos].mean(axis=1)

# Lista das categorias para análise (nomes das colunas no df_scored)
categorias_cols = [
    'liquidez_media',
    'alavancagem_media',
    'rentabilidade_media',
    'retornos_media',
    'eficiencia_media',
    'ciclos_media' # Certifique-se que esta coluna existe ou foi criada acima
]

# Nomes bonitos para os eixos dos gráficos
nomes_categorias = [
    'Liquidez', 'Alavancagem', 'Rentabilidade',
    'Retornos', 'Eficiência Op.', 'Ciclos Op.'
]
```

In [93]:
```
# --- GRÁFICO 1: Distribuição do Score Total ---
plt.figure(figsize=(10, 6))

# Histograma com linha de densidade (KDE)
sns.histplot(df_scored['score_total'], kde=True, bins=30, color='#2c3e50', alpha=0.

# Adicionando linhas de média e mediana
media_total = df_scored['score_total'].mean()
mediana_total = df_scored['score_total'].median()

plt.axvline(media_total, color='red', linestyle='--', linewidth=1.5, label=f'Média:
plt.axvline(mediana_total, color='green', linestyle='-', linewidth=1.5, label=f'Med

plt.title('Distribuição do Score Total de Crédito (2008-2024)', fontsize=14, pad=15
plt.xlabel('Score Total (0 a 5)')
plt.ylabel('Frequência')
plt.legend()
plt.tight_layout()

# Salvar
```

```
plt.savefig('distribuicao_score_total.png')
plt.show()
```

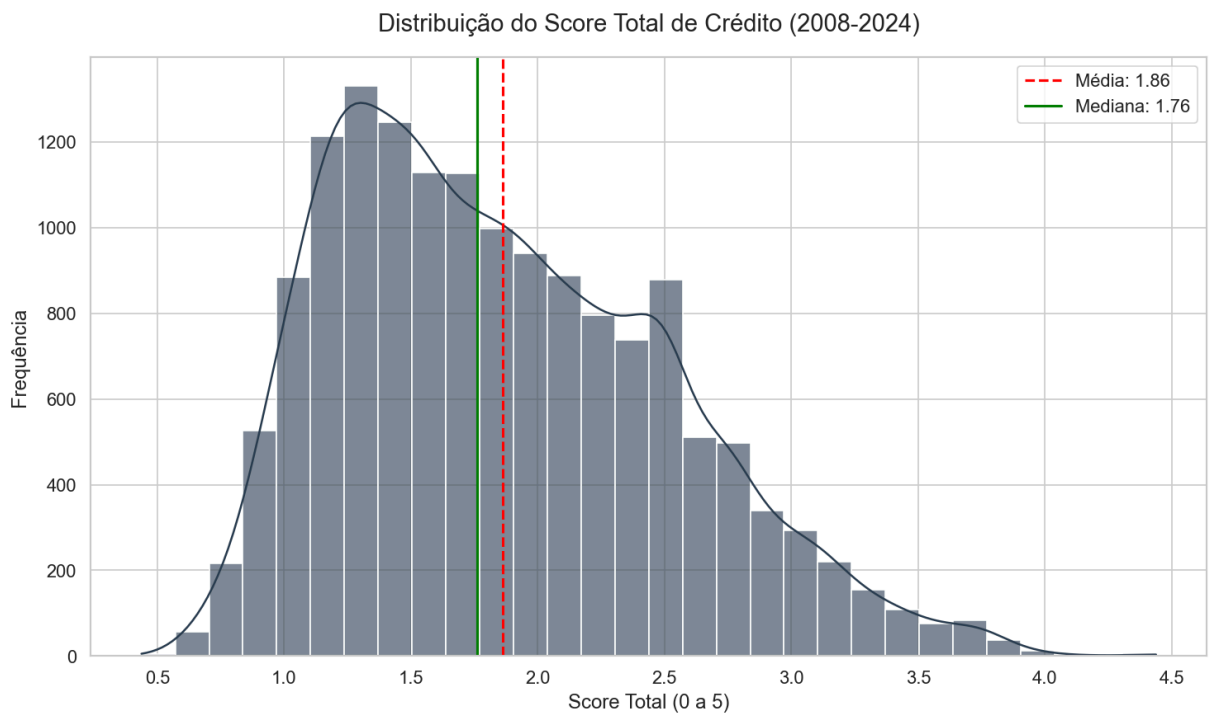

In [94]:
```
# --- GRÁFICO 2: Distribuição dos Scores por Categoria (Boxplot) ---
plt.figure(figsize=(12, 7))

# Preparar dados para o formato 'longo' que o Seaborn prefere
df_melted = df_scored[categorias_cols].melt(var_name='Categoria', value_name='Score

# Mapear os nomes das colunas para nomes legíveis
mapa_nomes = dict(zip(categorias_cols, nomes_categorias))
df_melted['Categoria'] = df_melted['Categoria'].map(mapa_nomes)

# Criar o Boxplot
sns.boxplot(x='Categoria', y='Score', data=df_melted, palette='viridis')

plt.title('Distribuição de Scores por Categoria Analisada', fontsize=14, pad=15)
plt.xlabel('') # Remove o label X pois as categorias já explicam
plt.ylabel('Score (0 a 5)')
plt.ylim(-0.2, 5.2) # Margem para ver tudo

plt.tight_layout()
plt.savefig('boxplot_categorias.png')
plt.show()
```

```
C:\Users\Lucas\AppData\Local\Temp\ipykernel_14520\3439553846.py:12: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.1
4.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.boxplot(x='Categoria', y='Score', data=df_melted, palette='viridis')
```

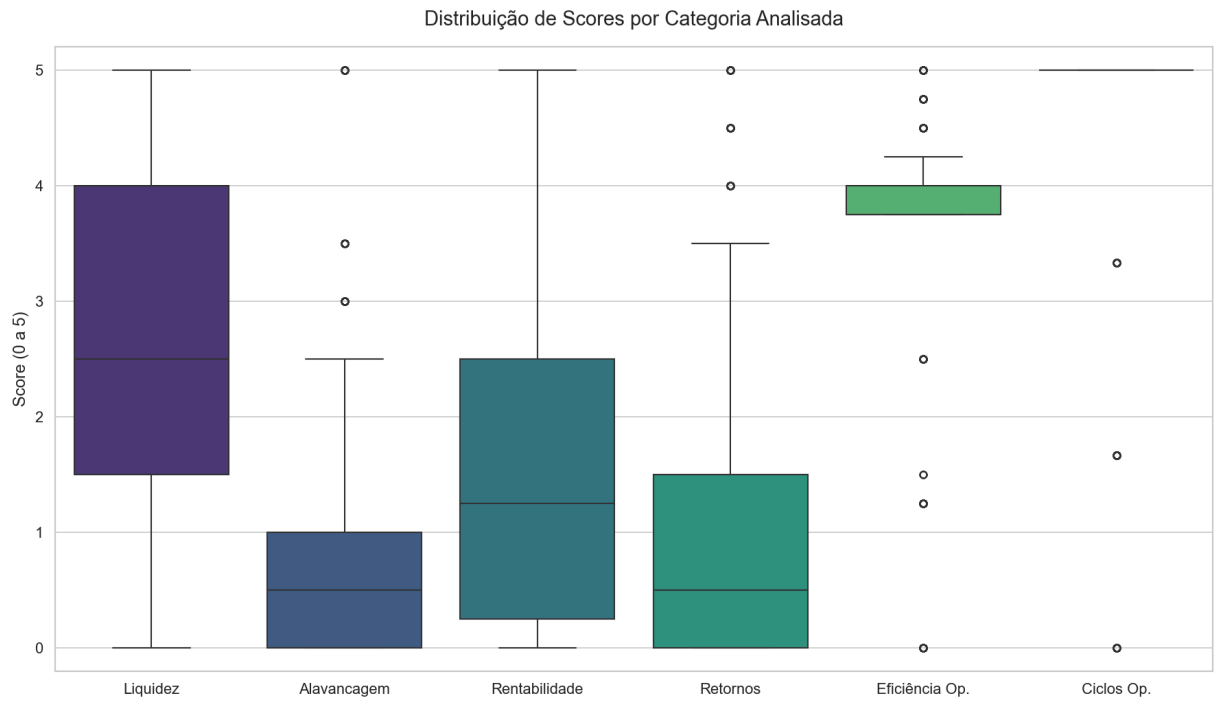

In [95]:

```
import matplotlib.pyplot as plt
import seaborn as sns

# Configuração do tamanho e estilo
plt.figure(figsize=(12, 7))
sns.set_theme(style="whitegrid", font_scale=1.1)

# Criar o Violin Plot
ax = sns.violinplot(
    x='Categoria',
    y='Score',
    data=df_melted,
    palette='viridis',
    inner='quartile',
    cut=0
)

plt.title('Distribuição de Scores por Categoria: Violin Plot', fontsize=16, pad=20)
plt.ylabel('Score (0 a 5)', fontsize=12)
plt.xlabel('Categoria Analisada', fontsize=12)
plt.ylim(-0.5, 5.5)
plt.annotate('Concentração de\nnotas máximas',
             xy=(5, 5), xytext=(5, 3.5),
             arrowprops=dict(facecolor='black', shrink=0.05),
             horizontalalignment='center')

plt.tight_layout()


plt.show()
```

```
C:\Users\Lucas\AppData\Local\Temp\ipykernel_14520\2880634793.py:9: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.1
4.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  ax = sns.violinplot(
```

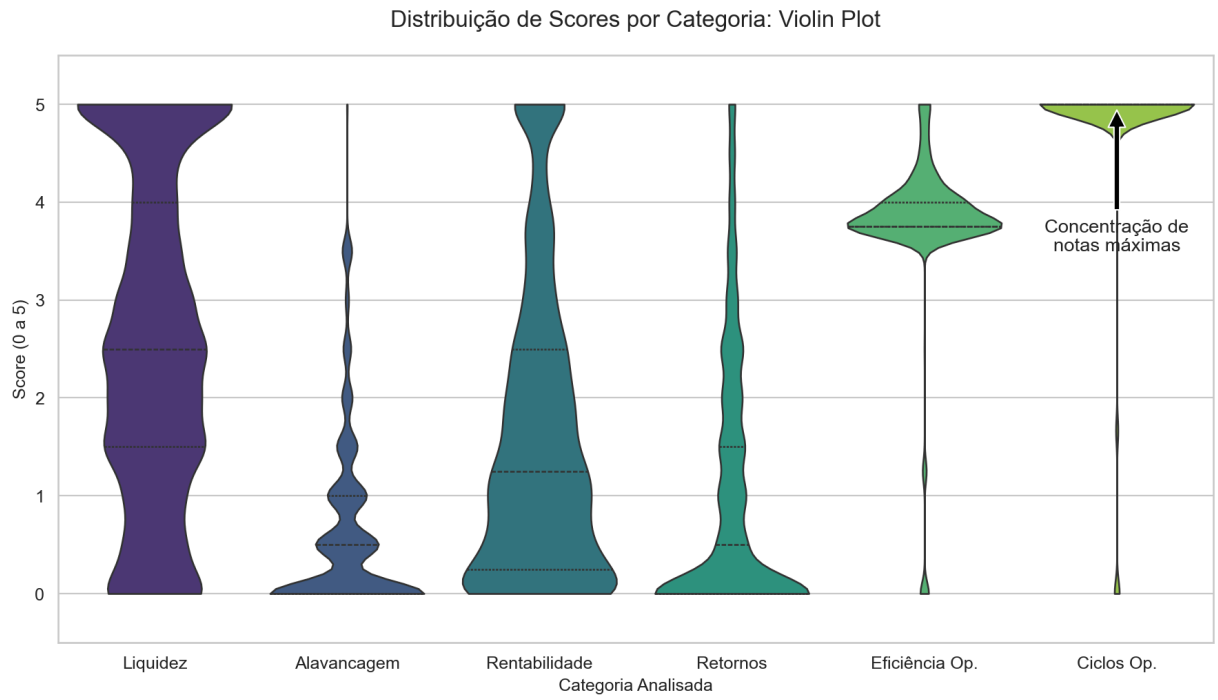

In [96]:
```
plt.figure(figsize=(12, 7))

# Usar Violin Plot mostra a densidade (a "barriga" do violino mostrará onde tem mai
sns.violinplot(x='Categoria', y='Score', data=df_melted, palette='viridis', inner='

plt.title('Distribuição de Scores (Violin Plot)', fontsize=14)
plt.ylabel('Score (0 a 5)')
plt.ylim(-0.2, 5.5)
plt.savefig('violin_plot.png')
plt.show()
```

```
C:\Users\Lucas\AppData\Local\Temp\ipykernel_14520\2566801182.py:4: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.1
4.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.violinplot(x='Categoria', y='Score', data=df_melted, palette='viridis', inner
='quartile')
```

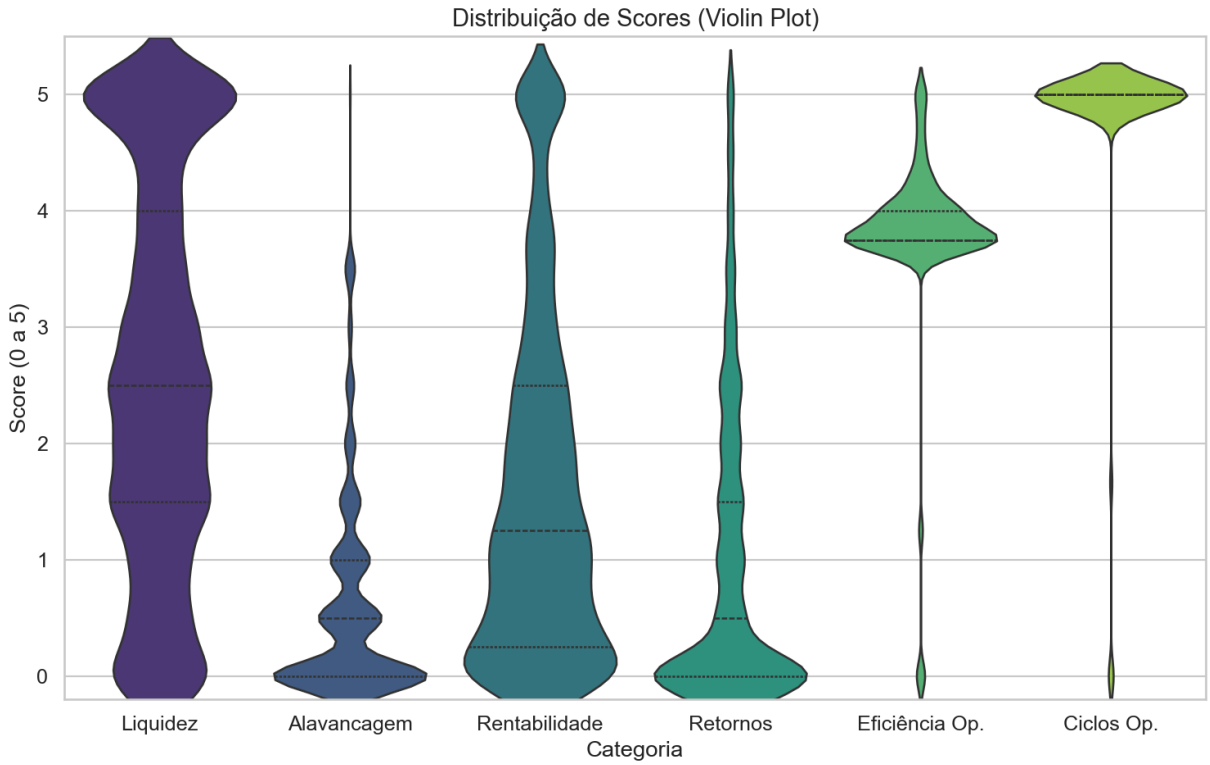

In [97]:
```
# Verificar a contagem de notas na coluna de Ciclos
print("Distribuição das notas de Ciclos Operacionais:")
print(df_scored['ciclos_media'].value_counts().sort_index(ascending=False))

# Estatísticas descritivas
print("\nEstatísticas:")
print(df_scored['ciclos_media'].describe())
```

```
Distribuição das notas de Ciclos Operacionais:
ciclos_media
5.000000    14623
3.333333       18
1.666667      204
0.000000      467
Name: count, dtype: int64

Estatísticas:
count    15312.000000
mean         4.801136
std          0.935030
min          0.000000
25%          5.000000
50%          5.000000
75%          5.000000
max          5.000000
Name: ciclos_media, dtype: float64
```

In [98]:
```
# --- GRÁFICO 3: Perfil Médio das Empresas (Radar Chart) ---

# Calcular as médias de cada categoria
medias_categorias = df_scored[categorias_cols].mean().values
```

```python
# Preparar ângulos para o radar
num_vars = len(categorias_cols)
angles = np.linspace(0, 2 * np.pi, num_vars, endpoint=False).tolist()
angles += angles[:1] # Fechar o ciclo
medias_categorias = np.concatenate((medias_categorias, [medias_categorias[0]])) # F

# Plotar
fig, ax = plt.subplots(figsize=(8, 8), subplot_kw=dict(polar=True))
ax.fill(angles, medias_categorias, color='blue', alpha=0.25)
ax.plot(angles, medias_categorias, color='blue', linewidth=2)

# Ajustar labels
ax.set_yticklabels([])
ax.set_xticks(angles[:-1])
ax.set_xticklabels(nomes_categorias, fontsize=11)

plt.title('Perfil Médio de Crédito das Empresas Analisadas', y=1.05, fontsize=14)
plt.tight_layout()
plt.savefig('radar_chart_perfil_medio.png')
plt.show()
```

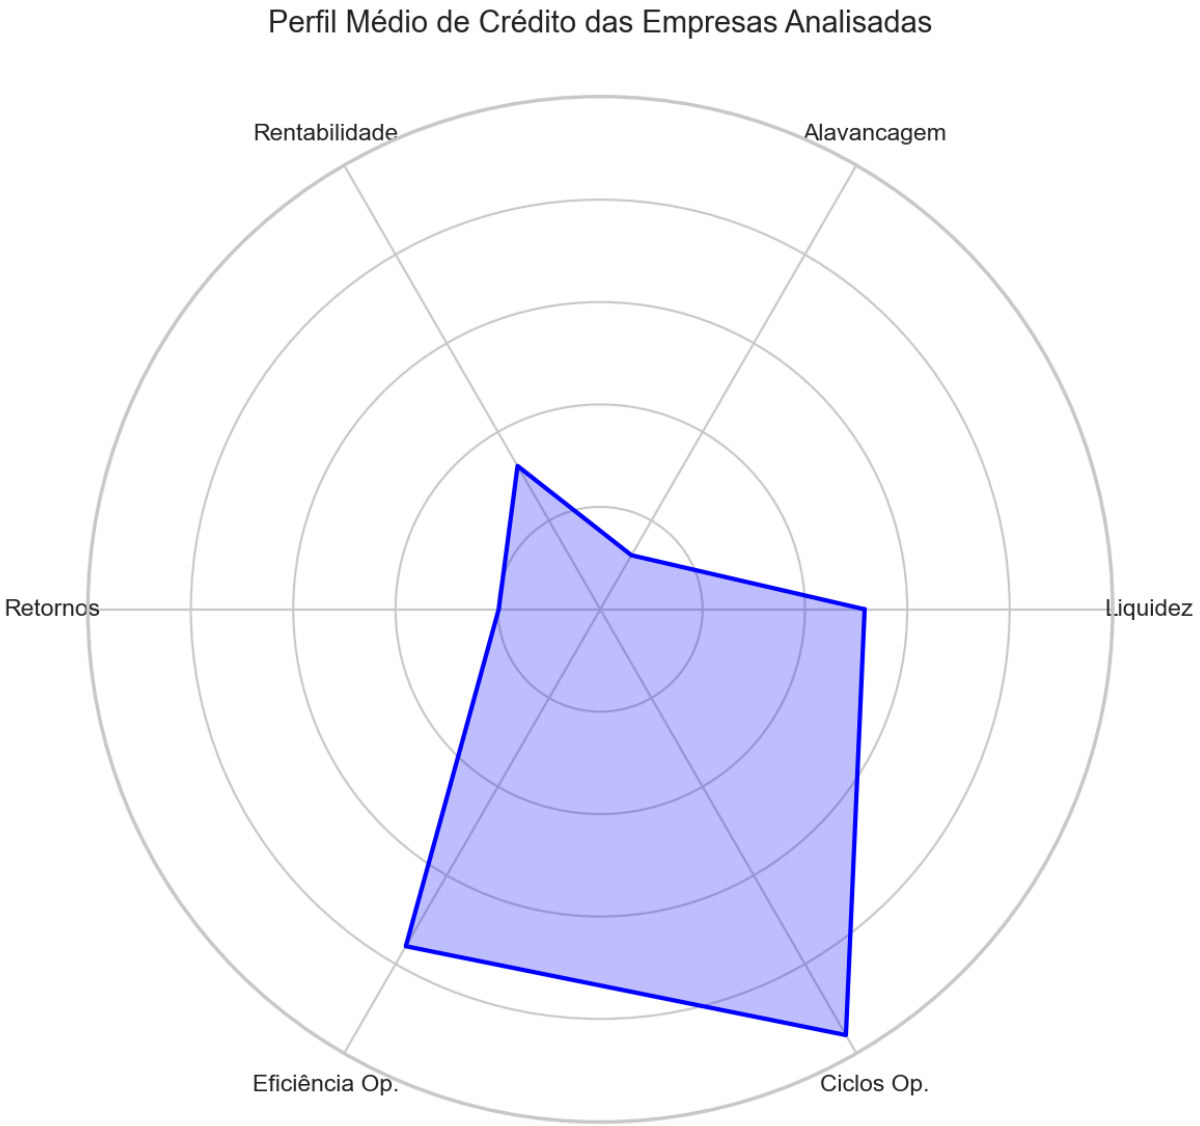

In [99]:
```
df_model.columns.tolist()
```

Out[99]:
```
['companycode',
 'ano',
 'periodo',
 'ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'ebit',
 'lucro_periodo',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'cogs',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortization',
 'ebitda',
 'data',
 'liquidez_corrente',
 'liquidez_seca',
 'endividamento_total',
 'divida_patrimonio',
 'margem_bruta',
 'margem_operacional',
 'margem_liquida',
 'margem_ebitda',
 'roa',
 'roe',
 'fco_divida',
 'fcf_divida',
 'cobertura_juros',
 'ebitda_divida',
 'giro_ativos',
 'ciclo_estoques',
 'ciclo_recebiveis',
 'ciclo_pagamentos',
 'ciclo_estoques_dias',
 'score_total']
```

In [100…
```
import matplotlib.pyplot as plt
import seaborn as sns
```

```python
import numpy as np

cols_correlacao = [
    'score_total',
    'liquidez_media',
    'alavancagem_media',
    'rentabilidade_media',
    'retornos_media',
    'eficiencia_media',
    'ciclos_media'
]

mapa_nomes_corr = {
    'score_total': 'Score Total',
    'liquidez_media': 'Liquidez',
    'alavancagem_media': 'Alavancagem',
    'rentabilidade_media': 'Rentabilidade',
    'retornos_media': 'Retornos',
    'eficiencia_media': 'Eficiência Op.',
    'ciclos_media': 'Ciclos Op.'
}

# Criar um DataFrame menor apenas para correlação
df_corr_plot = df_scored[cols_correlacao].rename(columns=mapa_nomes_corr).corr()

# --- PASSO 2: Gerar o Gráfico ---
plt.figure(figsize=(10, 8))
sns.set_theme(style="white") # Fundo branco fica melhor para matrizes

# Criar uma máscara para esconder o triângulo superior (informação repetida)
mask = np.triu(np.ones_like(df_corr_plot, dtype=bool))

# Desenhar o Heatmap
heatmap = sns.heatmap(
    df_corr_plot,
    mask=mask,
    annot=True,           # Escrever os números nas caixas
    fmt=".2f",            # Duas casas decimais
    cmap='RdBu_r',        # Escala de cor: Vermelho (negativo) a Azul (positivo)
    vmin=-1, vmax=1,      # Limites da cor
    center=0,
    square=True,          # Forçar quadrados perfeitos
    linewidths=.5,        # Linhas brancas entre os quadrados
    cbar_kws={"shrink": .8, "label": "Coeficiente de Correlação (Pearson)"}
)

plt.title('Matriz de Correlação de Pearson: Dimensões de Crédito', fontsize=14, pad
plt.xticks(rotation=45, ha='right') # Rotação para ler melhor
plt.yticks(rotation=0)
plt.tight_layout()

# Salvar
plt.savefig('matriz_correlacao_credito.png', dpi=300)
plt.show()
```

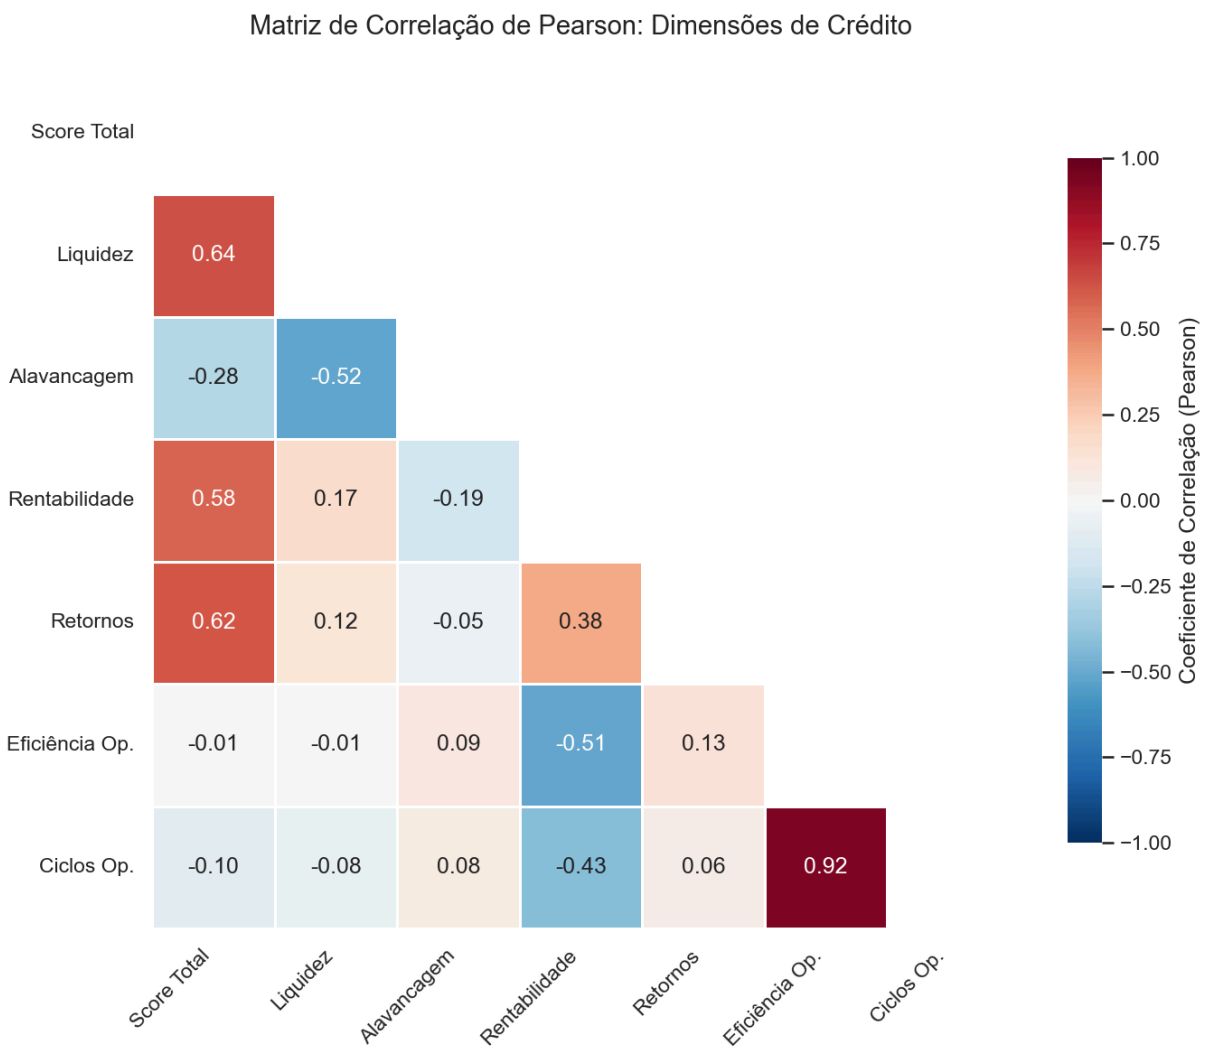

In [101…

```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# --- PASSO 1: Selecionar e Renomear Colunas ---
cols_correlacao = [
    'score_total',
    'liquidez_media',
    'alavancagem_media',
    'rentabilidade_media',
    'retornos_media',
    'eficiencia_media',
    'ciclos_media',
    'liquidez_corrente',
    'liquidez_seca',
    'endividamento_total',
    'divida_patrimonio',
    'margem_bruta',
    'margem_operacional',
    'margem_liquida',
    'margem_ebitda',
    'roa',
    'roe',
    'fco_divida',
```

```
    'fcf_divida',
    'cobertura_juros',
    'ebitda_divida',
    'giro_ativos',
    'ciclo_estoques',
    'ciclo_recebiveis',
    'ciclo_pagamentos',
]

# Dicionário para deixar os nomes bonitos no gráfico
mapa_nomes_corr = {
    'score_total': 'Score Total',
    'liquidez_media': 'Liquidez',
    'alavancagem_media': 'Alavancagem',
    'rentabilidade_media': 'Rentabilidade',
    'retornos_media': 'Retornos',
    'eficiencia_media': 'Eficiência Op.',
    'ciclos_media': 'Ciclos Op.',
    'liquidez_corrente':'Liquidez Corrente',
    'liquidez_seca': 'Liquidez Seca',
    'endividamento_total':'Endividamento Total',
    'divida_patrimonio':'Divida Patrimonio',
    'margem_bruta':'Margem Bruta',
    'margem_operacional':'Margem Operacional',
    'margem_liquida':'Margem Liquida',
    'margem_ebitda':'Margem Ebitda',
    'roa':'ROA',
    'roe':'ROE',
    'fco_divida':'Fluxo Caixa Operacional / Dívidas',
    'fcf_divida':'Fluxo de Caixa Livre / Dívidas',
    'cobertura_juros':'Cobertura de Juros',
    'ebitda_divida':'EBITDA / Dívidas',
    'giro_ativos':'Giro de Ativos',
    'ciclo_estoques':'Ciclo de Estoques',
    'ciclo_recebiveis':'Ciclo de Recebíveis',
    'ciclo_pagamentos':'Ciclo de Pagamentos'
}
df_corr_plot = df_scored[cols_correlacao].rename(columns=mapa_nomes_corr).corr(meth

# --- PLOTAGEM ---

plt.figure(figsize=(16, 12))
sns.set_theme(style="white")

mask = np.triu(np.ones_like(df_corr_plot, dtype=bool))

heatmap = sns.heatmap(
    df_corr_plot,
    mask=mask,
    annot=True,
    fmt=".2f",
    cmap='RdBu_r',
    vmin=-1, vmax=1,
    center=0,
    square=True,
    linewidths=.5,
```

```
    cbar_kws={"shrink": .8, "label": "Correlação de Spearman (Ranking)"} # Label at
)

plt.title('Matriz de Correlação de Spearman: Indicadores Brutos vs. Score', fontsiz
plt.xticks(rotation=45, ha='right')
plt.yticks(rotation=0)
plt.tight_layout()

# Salvar
plt.savefig('matriz_spearman_completa.png', dpi=300)
plt.show()
```

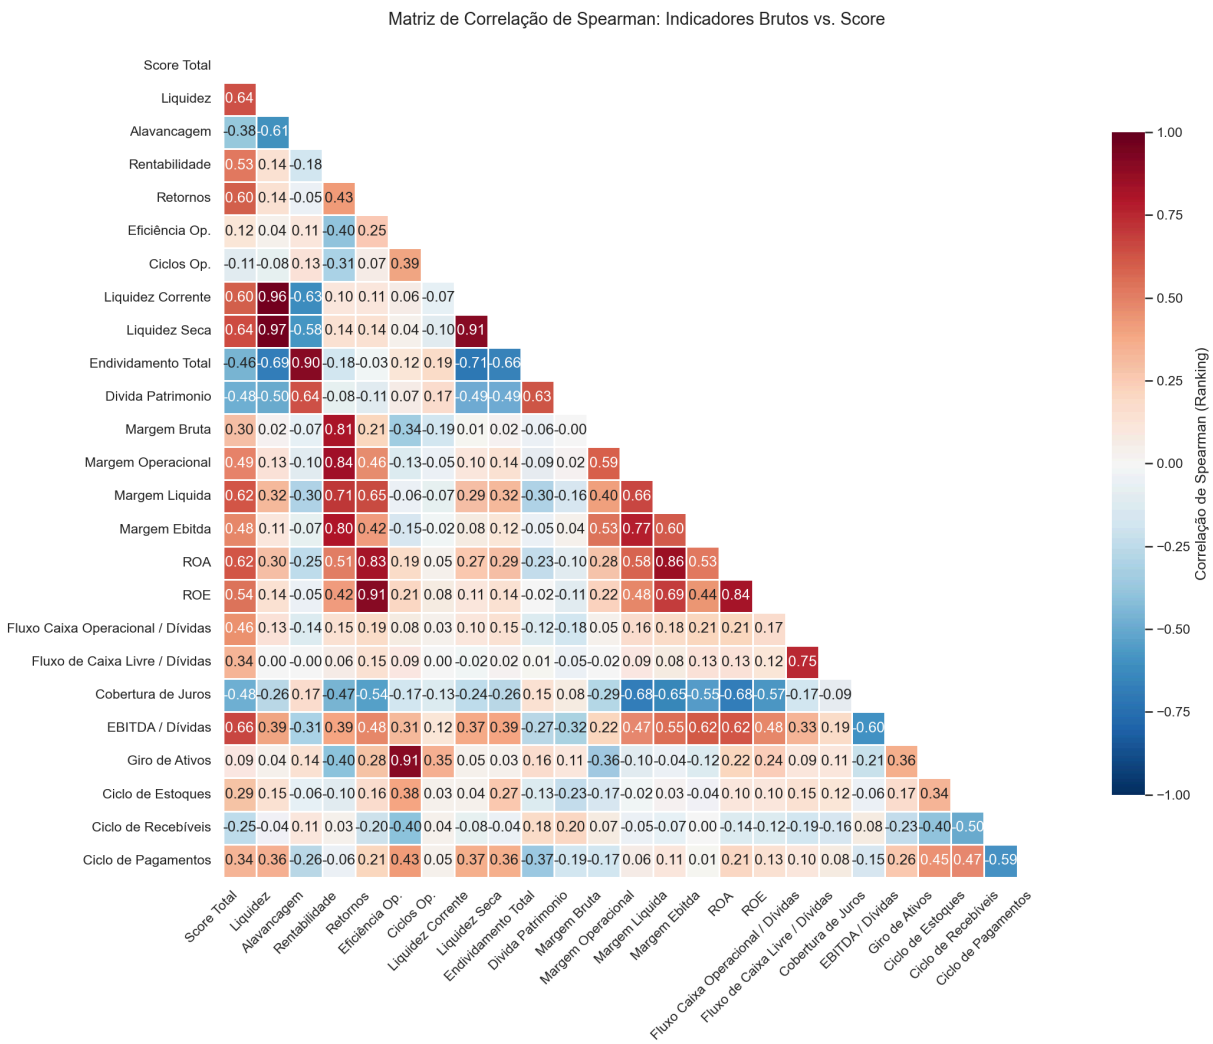

In [102…

```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
import phik  # Certifica-te que está instalado

# --- PASSO 1: Selecionar Colunas (Mesmas da anterior) ---
cols_correlacao = [
    'score_total',
    'liquidez_media',
    'alavancagem_media',
    'rentabilidade_media',
    'retornos_media',
```

```
    'eficiencia_media',
    'ciclos_media'
]

mapa_nomes_corr = {
    'score_total': 'Score Total',
    'liquidez_media': 'Liquidez',
    'alavancagem_media': 'Alavancagem',
    'rentabilidade_media': 'Rentabilidade',
    'retornos_media': 'Retornos',
    'eficiencia_media': 'Eficiência Op.',
    'ciclos_media': 'Ciclos Op.'
}

# Calcular a matriz Phi_K
# O interval_cols=[] diz ao phik para tentar adivinhar o que é numérico
df_phik_calc = df_scored[cols_correlacao].rename(columns=mapa_nomes_corr)
matrix_phik = df_phik_calc.phik_matrix()

# --- PASSO 2: Gerar o Heatmap ---
plt.figure(figsize=(10, 8))
sns.set_theme(style="white")

# Máscara para esconder a parte de cima (igual à de Pearson)
mask = np.triu(np.ones_like(matrix_phik, dtype=bool))

# Plotar
heatmap = sns.heatmap(
    matrix_phik,
    mask=mask,
    annot=True,
    fmt=".2f",
    cmap='Blues',     # Phi_K é sempre positivo (0 a 1), então usamos uma cor só (e
    vmin=0, vmax=1,   # Limites de 0 a 1
    square=True,
    linewidths=.5,
    cbar_kws={"shrink": .8, "label": "Coeficiente Phi_K (Dependência)"}
)

plt.title('Matriz de Correlação Phi_K: Dependência Não-Linear', fontsize=14, pad=20
plt.xticks(rotation=45, ha='right')
plt.yticks(rotation=0)
plt.tight_layout()

# Salvar
plt.savefig('matriz_phik_credito.png', dpi=300)
plt.show()
```

```
interval columns not set, guessing: ['Score Total', 'Liquidez', 'Alavancagem', 'Rent
abilidade', 'Retornos', 'Eficiência Op.', 'Ciclos Op.']
```

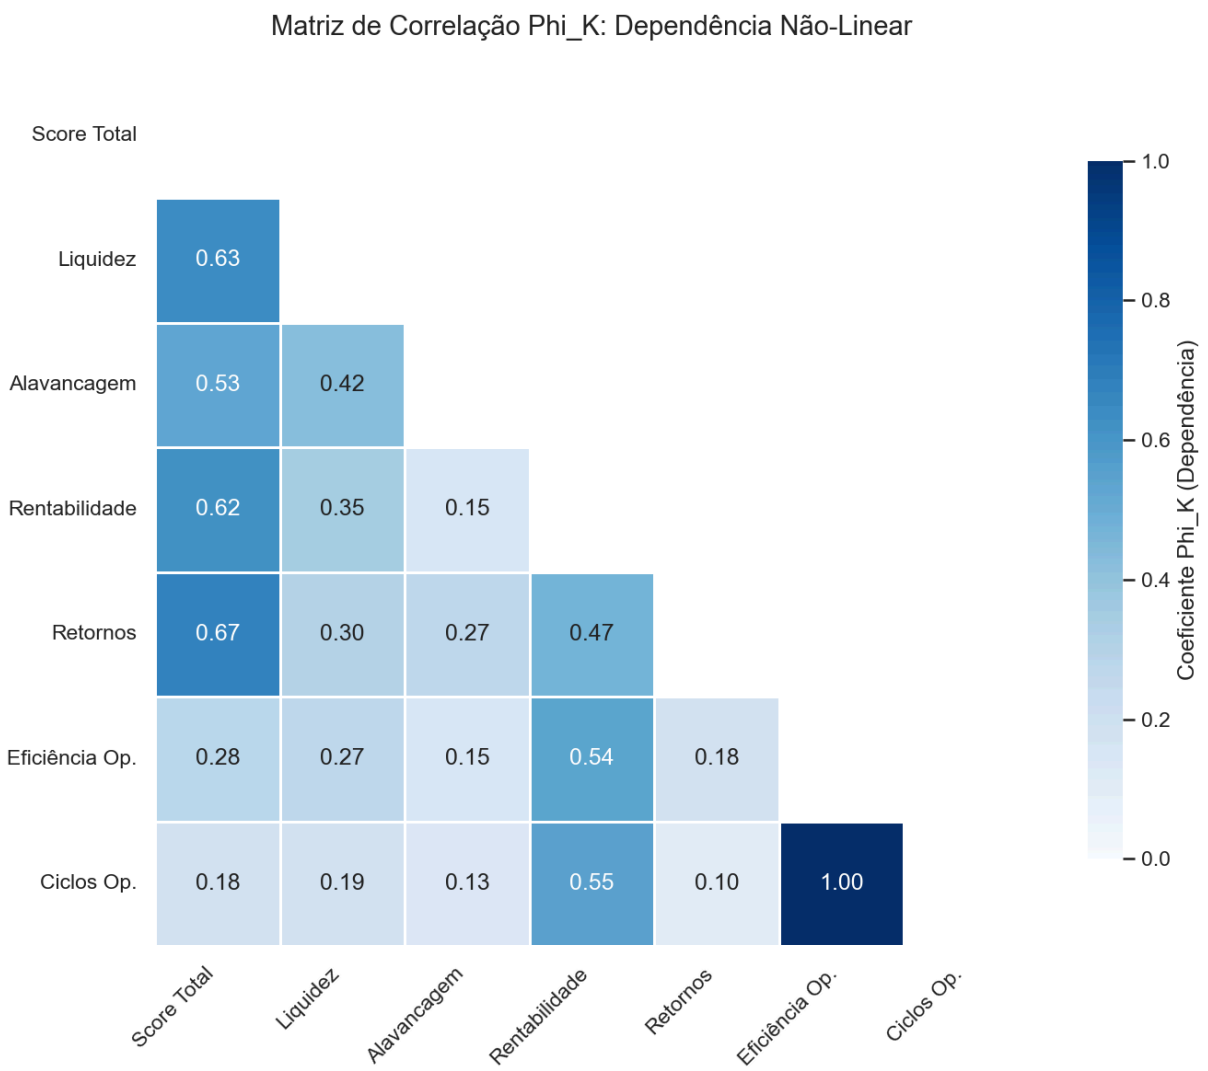

In [103…

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Criar um ranking baseado na média histórica do Score Total
ranking_historico = df_scored.groupby('companycode')['score_total'].mean().sort_val

# 2. Identificar os extremos
melhor_empresa = ranking_historico.index[0]   # A primeira da lista
pior_empresa = ranking_historico.index[-1]    # A última da lista

# Garantir que não selecionamos a própria THYAO como melhor/pior (para não duplicar
if melhor_empresa == 'THYAO':
    melhor_empresa = ranking_historico.index[1]
if pior_empresa == 'THYAO':
    pior_empresa = ranking_historico.index[-2]

print(f"✈️ Empresa Foco: THYAO")
print(f"🏆 Melhor Desempenho (Benchmark Positivo): {melhor_empresa} (Média: {ranki
print(f"⚠️ Pior Desempenho (Benchmark Negativo): {pior_empresa} (Média: {ranking_h

# 3. Filtrar o DataFrame apenas para essas 3 empresas
empresas_selecionadas = ['THYAO', melhor_empresa, pior_empresa]
```

```
df_comparacao = df_scored[df_scored['companycode'].isin(empresas_selecionadas)].cop

# Definir uma ordem fixa para as cores nos gráficos
ordem_empresas = [melhor_empresa, 'THYAO', pior_empresa]
paleta_cores = {melhor_empresa: 'green', 'THYAO': 'blue', pior_empresa: 'red'}
```

```
🎯 Empresa Foco: THYAO
🏆 Melhor Desempenho (Benchmark Positivo): AKMGY (Média: 3.25)
⚠️ Pior Desempenho (Benchmark Negativo): BURCE (Média: 1.02)
```

In [104…

```
plt.figure(figsize=(14, 7))

sns.lineplot(
    data=df_comparacao,
    x='data',
    y='score_total',
    hue='companycode',
    palette=paleta_cores,
    hue_order=ordem_empresas,
    linewidth=2.5
)

plt.title('Trajetória de Crédito: THYAO vs. Melhor e Pior do Mercado', fontsize=16)
plt.ylabel('Score Total (0 a 5)', fontsize=12)
plt.xlabel('Ano', fontsize=12)
plt.grid(True, linestyle='--', alpha=0.7)
plt.legend(title='Empresa', loc='upper right')

# Adicionar faixas de classificação (opcional, mas visualmente útil)
plt.axhspan(4, 5, color='green', alpha=0.05, label='Excelência')
plt.axhspan(0, 2, color='red', alpha=0.05, label='Risco Elevado')

plt.tight_layout()
plt.show()
```

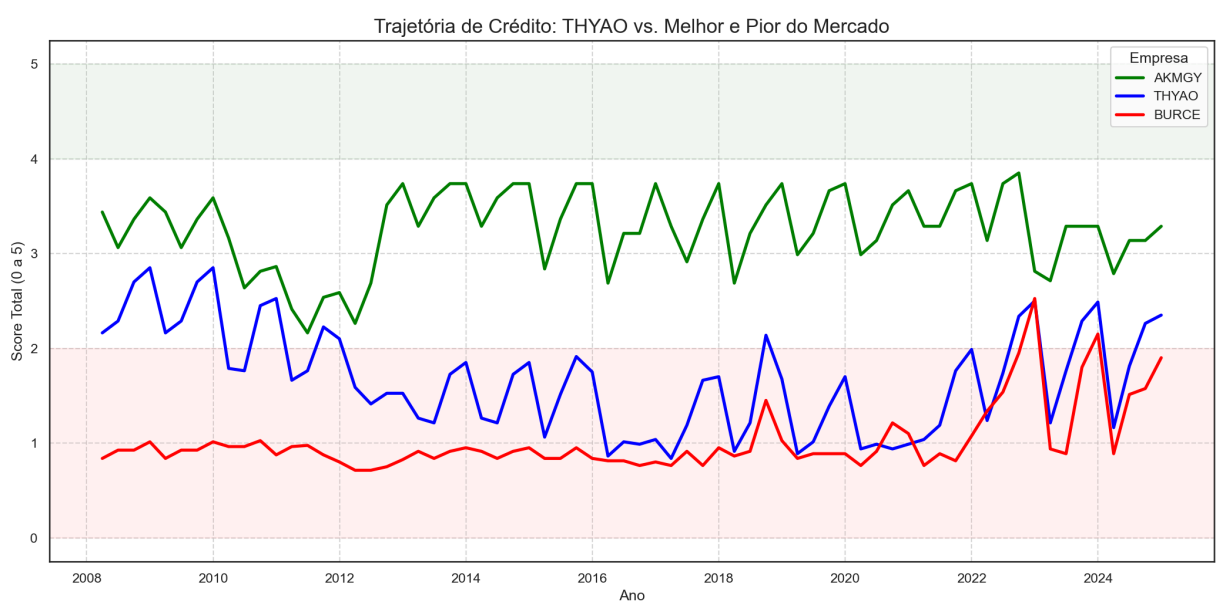

In [105…

```
# Selecionar as colunas de médias das categorias
cols_categorias = ['liquidez_media', 'alavancagem_media', 'rentabilidade_media', 'r
nomes_amigaveis = ['Liquidez', 'Alavancagem (Nota)', 'Rentabilidade', 'Retornos']
```

```
# Preparar figura com subplots (2x2)
fig, axes = plt.subplots(2, 2, figsize=(15, 10), sharex=True)
axes = axes.flatten() # Transformar matriz 2x2 em lista linear para facilitar o loo

for i, col in enumerate(cols_categorias):
    sns.lineplot(
        data=df_comparacao,
        x='data',
        y=col,
        hue='companycode',
        palette=paleta_cores,
        hue_order=ordem_empresas,
        ax=axes[i],
        legend=False # Remove legendas individuais para não poluir
    )

    axes[i].set_title(nomes_amigaveis[i], fontsize=12, fontweight='bold')
    axes[i].set_ylabel('Nota (0-5)')
    axes[i].set_xlabel('')
    axes[i].grid(True, alpha=0.5)

# Adicionar uma legenda única para toda a figura
handles, labels = axes[0].get_legend_handles_labels()
fig.legend(handles, labels, loc='upper center', ncol=3, fontsize=12, bbox_to_anchor

plt.suptitle('Comparativo de Fundamentos Financeiros (2008-2023)', y=1.08, fontsize
plt.tight_layout()
plt.show()
```

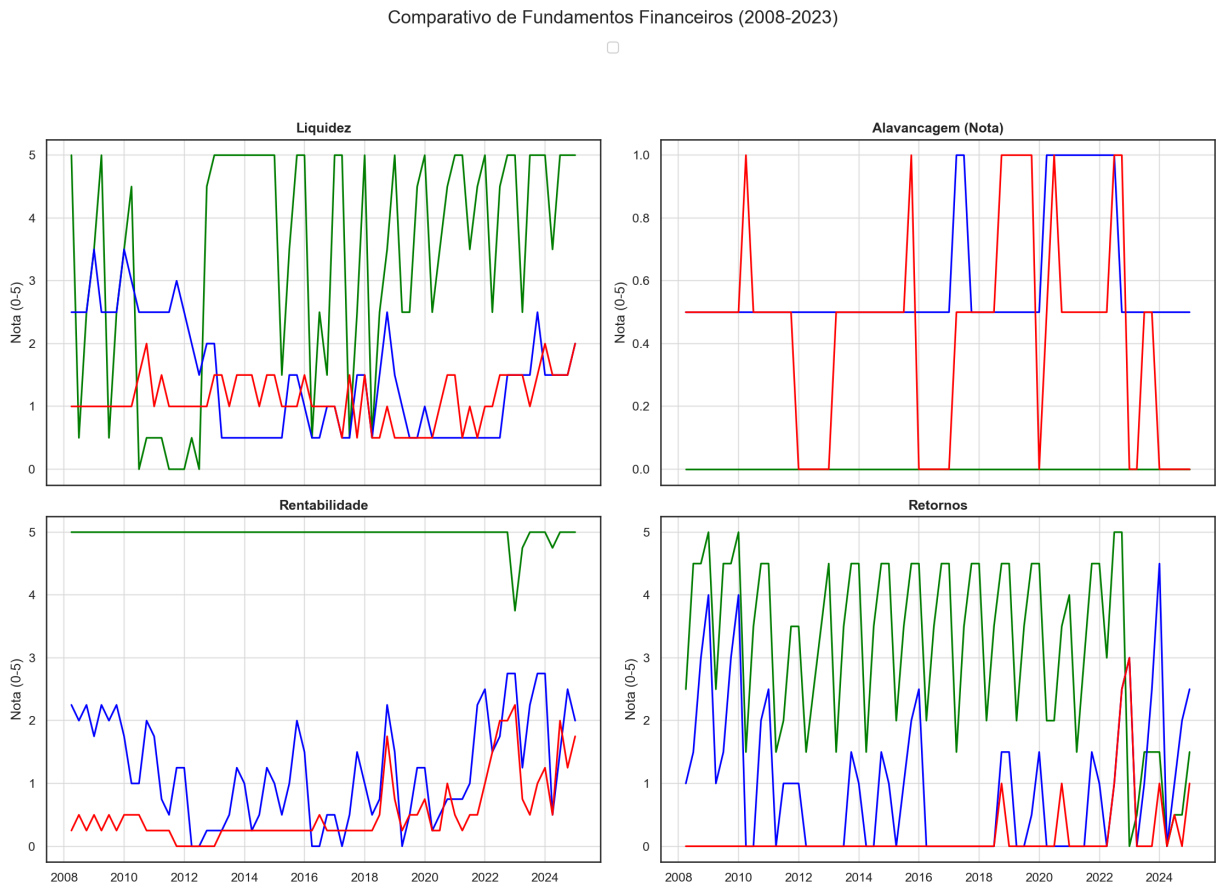

In [106…

```
df_scored
```

Out[106…

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
3828	ADEL	2008	6_Meses	8.860061e+07	1.609915e+07	1.046998e-
7656	ADEL	2008	9_Meses	9.400968e+07	1.555129e+07	1.095610e-
11484	ADEL	2008	Anual	4.558265e+07	1.517075e+07	6.075340e-
1	ADEL	2009	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
...	...	...	...	...	...	
15310	ZOREN	2023	Anual	2.862619e+10	1.136030e+11	1.422292e-
3827	ZOREN	2024	3_Meses	1.561239e+10	8.488922e+10	1.005016e-
7655	ZOREN	2024	6_Meses	1.434187e+10	9.238784e+10	1.067297e-
11483	ZOREN	2024	9_Meses	1.539392e+10	9.982602e+10	1.152199e-
15311	ZOREN	2024	Anual	1.341005e+10	1.053747e+11	1.187847e-

15312 rows × 75 columns