In [1]:
```
import pandas as pd
from dotenv import load_dotenv
import os
load_dotenv()
DF_PATH = os.getenv('DF_MODEL')
df = pd.read_csv(DF_PATH)
df.head()
```

Out[1]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ativos
0	ADEL	2008	3_Meses	82082356.0	16000553.0	98082909.0
1	ADEL	2008	6_Meses	88600612.0	16099148.0	104699760.0
2	ADEL	2008	9_Meses	94009683.0	15551293.0	109560976.0
3	ADEL	2008	Anual	45582654.0	15170747.0	60753401.0
4	ADEL	2009	3_Meses	82082356.0	16000553.0	98082909.0

5 rows × 50 columns

In [2]:
```
df.isnull().sum()
```

Out[2]:

```
companycode                                              0
ano                                                      0
periodo                                                  0
ativos_circulantes                                       0
ativos_não_circulantes                                   0
total_de_ativos                                          0
passivos_circulantes                                     0
passivos_não_circulantes                                 0
total_do_passivo_e_patrimônico_líquido                   0
patrimônio_líquido                                       0
receita_de_vendas                                        0
lucro_bruto                                              0
ebit                                                     0
lucro_periodo                                            0
lucro_prejuízo_líquido_do_período                        0
despesas_financeiras                                     0
despesas_gerais_e_administrativas                        0
cogs                                                     0
fluxo_de_caixa_líquido_das_atividades_operacionais       0
fluxo_de_caixa_livre                                     0
fluxo_de_caixa_das_atividades_de_financiamento           0
fluxo_de_caixa_das_atividades_de_investimento            0
estoques                                                 0
contas_a_receber                                         0
contas_a_pagar                                           0
dívidas_financeiras                                      0
despesas_de_amortização                                  0
amortization                                             0
ebitda                                                   0
data                                                     0
liquidez_corrente                                       27
liquidez_seca                                           27
endividamento_total                                     27
divida_patrimonio                                       27
margem_bruta                                           465
margem_operacional                                     465
margem_liquida                                         465
margem_ebitda                                          465
roa                                                     27
roe                                                     27
fco_divida                                            2366
fcf_divida                                            2366
cobertura_juros                                        952
ebitda_divida                                         2366
giro_ativos                                             27
ciclo_estoques                                         671
ciclo_recebiveis                                       465
ciclo_pagamentos                                       671
ciclo_estoques_dias                                    671
score_total                                              0
dtype: int64
```

In [3]:

```python
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LinearRegression
```

```
from sklearn.pipeline import Pipeline
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import matplotlib.pyplot as plt
from sklearn.preprocessing import RobustScaler
from sklearn.impute import SimpleImputer
from sklearn.ensemble import RandomForestRegressor
```

In [4]:
```
# Features e target
X = df.drop(columns=['score_total','companycode','ano','periodo','data'])
y = df['score_total']
```

In [5]:
```
# Train-test split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_sta
```

In [6]:
```
X.columns.to_list()
```

Out[6]:
```
['ativos_circulantes',
 'ativos_não_circulantes',
 'total_de_ativos',
 'passivos_circulantes',
 'passivos_não_circulantes',
 'total_do_passivo_e_patrimônico_líquido',
 'patrimônio_líquido',
 'receita_de_vendas',
 'lucro_bruto',
 'ebit',
 'lucro_periodo',
 'lucro_prejuízo_líquido_do_período',
 'despesas_financeiras',
 'despesas_gerais_e_administrativas',
 'cogs',
 'fluxo_de_caixa_líquido_das_atividades_operacionais',
 'fluxo_de_caixa_livre',
 'fluxo_de_caixa_das_atividades_de_financiamento',
 'fluxo_de_caixa_das_atividades_de_investimento',
 'estoques',
 'contas_a_receber',
 'contas_a_pagar',
 'dívidas_financeiras',
 'despesas_de_amortização',
 'amortization',
 'ebitda',
 'liquidez_corrente',
 'liquidez_seca',
 'endividamento_total',
 'divida_patrimonio',
 'margem_bruta',
 'margem_operacional',
 'margem_liquida',
 'margem_ebitda',
 'roa',
 'roe',
 'fco_divida',
 'fcf_divida',
 'cobertura_juros',
 'ebitda_divida',
 'giro_ativos',
 'ciclo_estoques',
 'ciclo_recebiveis',
 'ciclo_pagamentos',
 'ciclo_estoques_dias']
```

In [7]:
```python
# Build da pipeline de Regressão Linear
pipeline = Pipeline([
    ('imputer', SimpleImputer(strategy='constant', fill_value=0)),
    ('scaler', StandardScaler()),
    ('regressor', LinearRegression())
])
```

In [8]:
```python
# Fit model
print('Treinando o modelo')
```

```
pipeline.fit(X_train, y_train)
```

Treinando o modelo

Out[8]:

```
▸ Pipeline
  ▸ SimpleImputer
  ▸ StandardScaler
  ▸ LinearRegression
```

In [9]:

```
# Predição
y_pred = pipeline.predict(X_test)
```

In [10]:

```
# Evaluation metrics
mae = mean_absolute_error(y_test, y_pred)
mse = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
mape = np.mean(np.abs((y_test - y_pred) / y_test)) * 100
r2 = r2_score(y_test, y_pred)
```

In [11]:

```
# Results summary
metrics = {
    'MAE': mae,
    'MSE': mse,
    'RMSE': rmse,
    'MAPE': mape,
    'R²': r2
}
```

In [12]:

```
# Display results
metrics_df = pd.DataFrame([metrics])
metrics_df
```

Out[12]:

	MAE	MSE	RMSE	MAPE	R^2
0	0.439913	0.308645	0.555558	27.494058	0.289063

In [13]:

```
# Resíduos
Resíduos = y_test - y_pred
```

In [14]:

```
# Plot Resíduos vs index
plt.figure(figsize=(12, 6))
plt.scatter(range(len(Resíduos)), Resíduos, alpha=0.7)
plt.axhline(0, color='red', linestyle='--')
plt.title('Resíduos vs Index')
plt.xlabel('Index')
plt.ylabel('Resíduos')
plt.show()
```

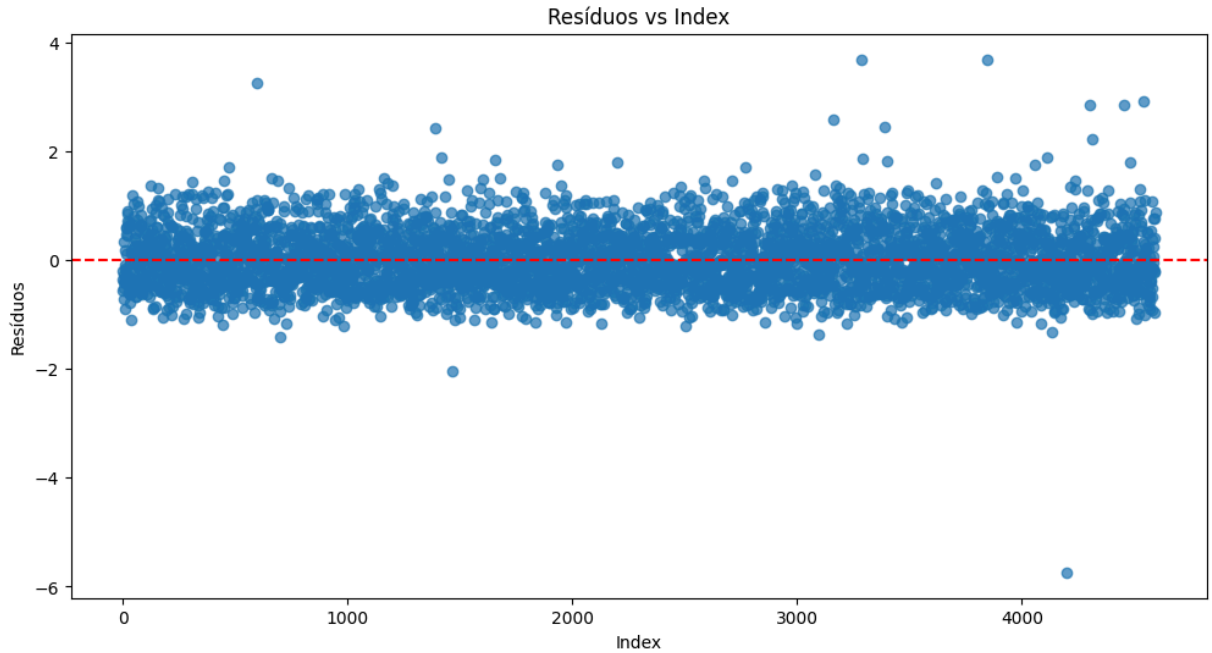

In [15]:
```
# Resíduos vs estimated response values
plt.figure(figsize=(12, 6))
plt.scatter(y_pred, Resíduos, alpha=0.7)
plt.axhline(0, color='red', linestyle='--')
plt.title('Resíduos vs Estimated Response Values')
plt.xlabel('Estimated Values')
plt.ylabel('Resíduos')
plt.show()
```

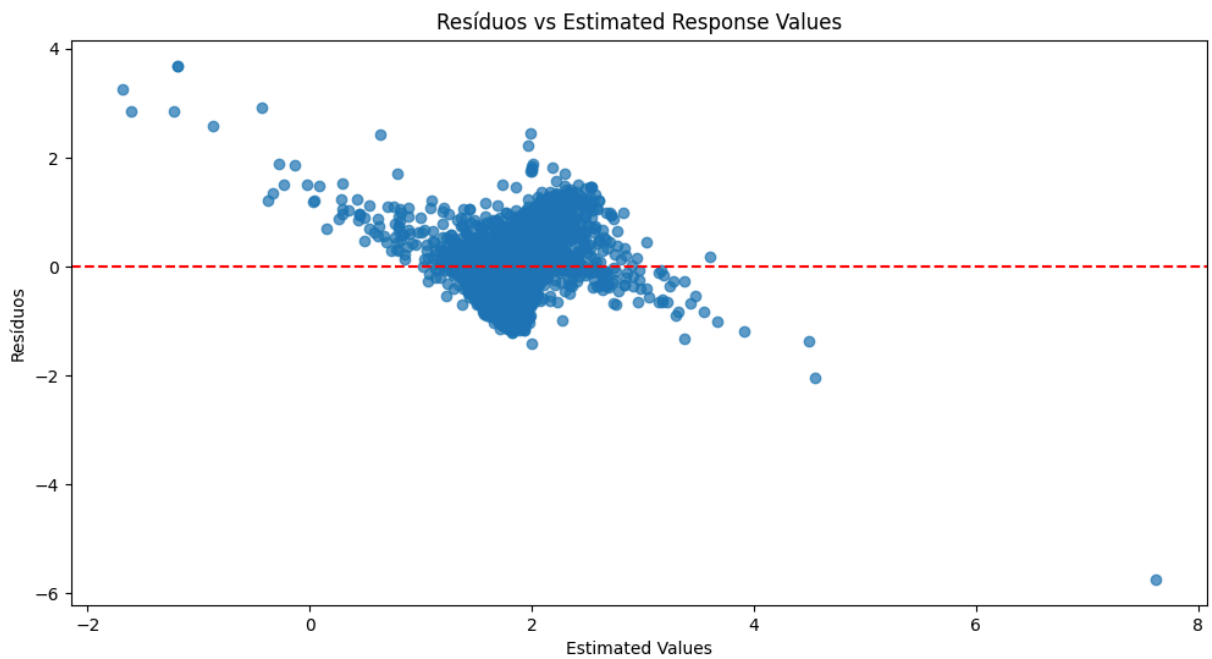

In [16]:
```
# Resíduos vs observations (actual values)
plt.figure(figsize=(12, 6))
plt.scatter(y_test, Resíduos, alpha=0.7)
plt.axhline(0, color='red', linestyle='--')
plt.title('Resíduos vs Observed Values')
plt.xlabel('Observed Values')
```

```
plt.ylabel('Resíduos')
plt.show()
```

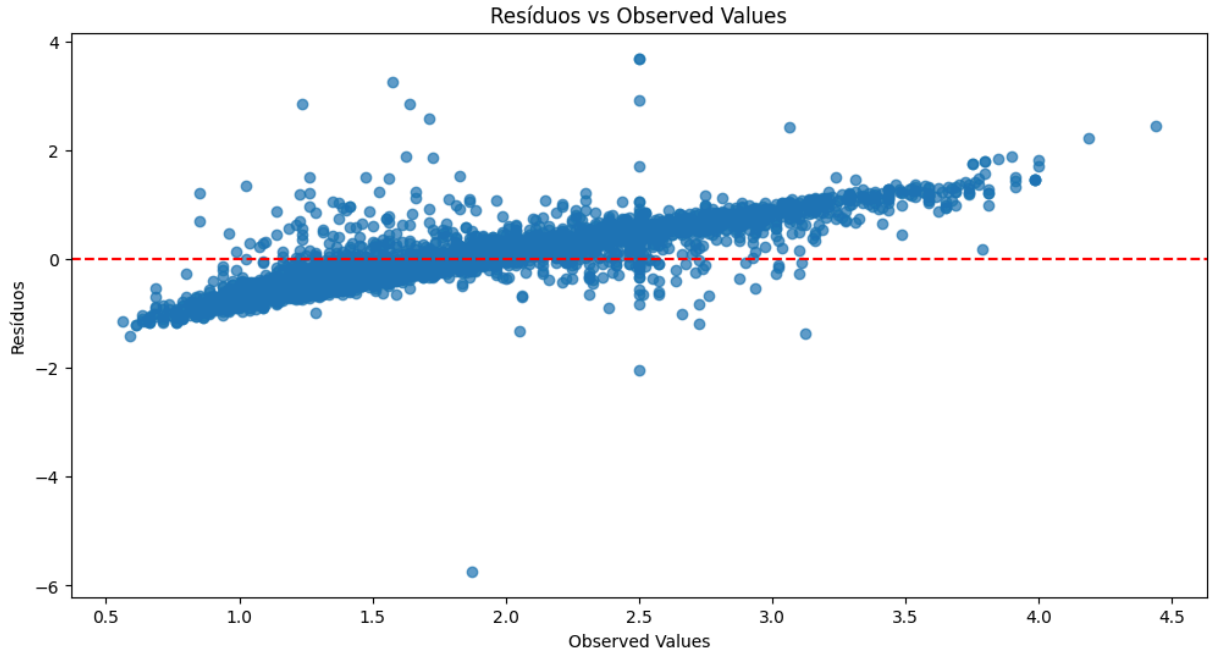

In [17]:
```
# Resíduos vs predicted values
plt.figure(figsize=(12, 6))
plt.scatter(y_pred, Resíduos, alpha=0.7)
plt.axhline(0, color='red', linestyle='--')
plt.title('Resíduos vs Predicted Values')
plt.xlabel('Predicted Values')
plt.ylabel('Resíduos')
plt.show()
```

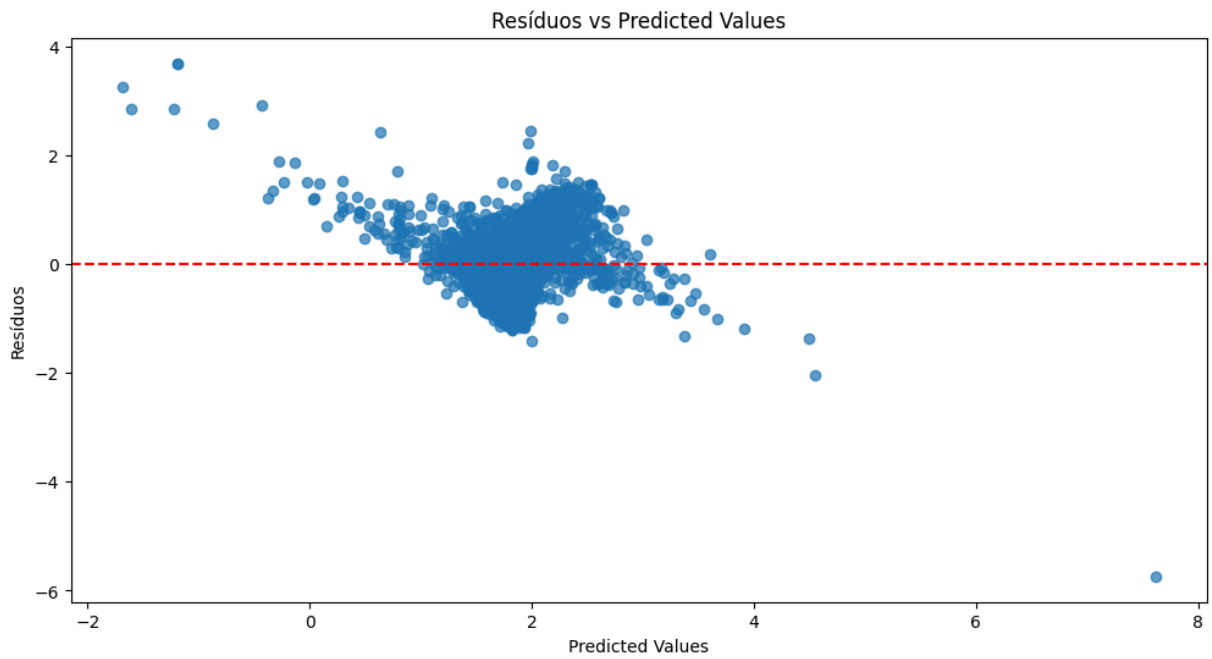

In [18]:
```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np
```

```python
def plot_best_residuals(y_pred, residuals):
    """
    Plota os dois gráficos de resíduos mais importantes lado a lado.

    Parâmetros:
    y_pred (array): Valores previstos pelo modelo.
    residuals (array): Resíduos (y_test - y_pred).
    """

    # Cria uma figura com 2 subgráficos (lado a lado)
    fig, axes = plt.subplots(1, 2, figsize=(16, 6))

    # --- Gráfico 1: Resíduos vs Predicted Values ---
    sns.scatterplot(x=y_pred, y=residuals, ax=axes[0], alpha=0.6)
    axes[0].axhline(y=0, color='r', linestyle='--', linewidth=2) # Linha zero
    axes[0].set_title('Regressão Linear Resíduos vs. Valores Previstos (Homocedasti
    axes[0].set_xlabel('Valores Previstos')
    axes[0].set_ylabel('Resíduos')

    # --- Gráfico 2: Resíduos vs Index ---
    # Criamos um índice sequencial (0, 1, 2, ...)
    index = np.arange(len(residuals))

    sns.scatterplot(x=index, y=residuals, ax=axes[1], alpha=0.6)
    axes[1].axhline(y=0, color='r', linestyle='--', linewidth=2) # Linha zero
    axes[1].set_title('Regressão Linear Resíduos vs. Index (Independência)')
    axes[1].set_xlabel('Index (Ordem dos Dados)')
    axes[1].set_ylabel('Resíduos')

    plt.tight_layout()
    plt.show()

# --- Exemplo de Uso (Simulação) ---
# Nota: No teu código real, usa as tuas variáveis y_pred e residuos reais.
if __name__ == "__main__":
    # Dados fictícios apenas para testar a função
    np.random.seed(42)
    y_pred_demo = np.random.rand(500) * 10
    # Simulando um erro que aumenta com o valor (heterocedasticidade)
    residuos_demo = np.random.normal(0, y_pred_demo * 0.5, 500)

    plot_best_residuals(y_pred, Resíduos)
```

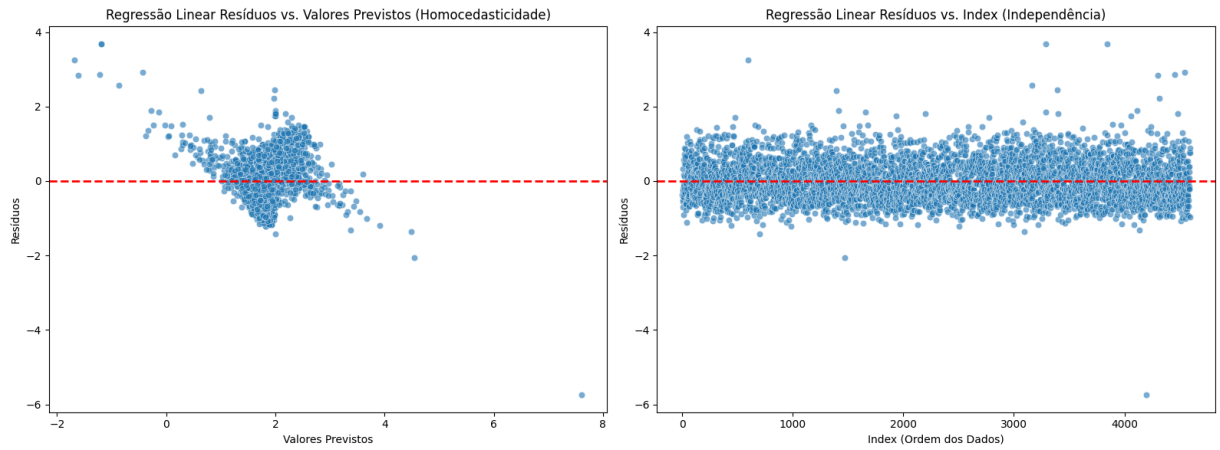

In [19]:
```
# PIPELINE 2: Regressor Random Forest
pipeline_rf = Pipeline([
    ('imputer', SimpleImputer(strategy='constant', fill_value=0)),
    ('scaler', StandardScaler()),
    ('regressor', RandomForestRegressor(n_estimators=100, random_state=42, n_jobs=-
])
```

In [20]:
```
print("\nTreinando o modelo Random Forest Regressor...")
pipeline_rf.fit(X_train, y_train)
```

```
Treinando o modelo Random Forest Regressor...
```

Out[20]:

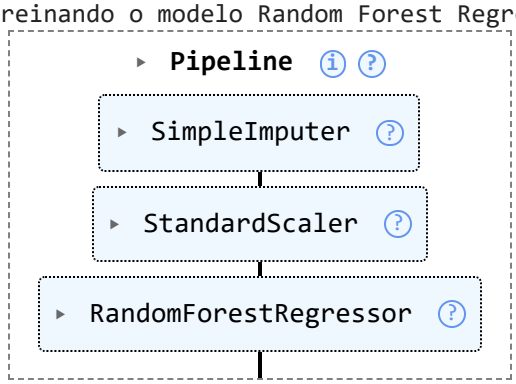

In [21]:
```
# 2. Previsões e Métricas (Random Forest)
y_pred_rf = pipeline_rf.predict(X_test)
metrics_rf = {
    'Modelo': 'Random Forest',
    'MAE': mean_absolute_error(y_test, y_pred_rf),
    'MSE': mean_squared_error(y_test, y_pred_rf),
    'RMSE': np.sqrt(mean_squared_error(y_test, y_pred_rf)),
    'MAPE (%)': np.mean(np.abs((y_test - y_pred_rf) / (y_test + 1e-6))) * 100,
    'R²': r2_score(y_test, y_pred_rf)
}
metrics_rf_df= pd.DataFrame([metrics_rf])
metrics_rf_df
```

Out[21]:

	Modelo	MAE	MSE	RMSE	MAPE (%)	R^2
0	Random Forest	0.068781	0.00986	0.099299	4.022904	0.977288

In [22]:
```
# Resíduos para Random Forest
Resíduos_rf = y_test - y_pred_rf

# Plot Resíduos vs index para Random Forest
plt.figure(figsize=(12, 6))
plt.scatter(range(len(Resíduos_rf)), Resíduos_rf, alpha=0.7)
plt.axhline(0, color='red', linestyle='--')
plt.title('Resíduos vs Index (Random Forest)')
plt.xlabel('Index')
plt.ylabel('Resíduos')
plt.savefig('residuosIndex.png', dpi=300)
plt.show()
```

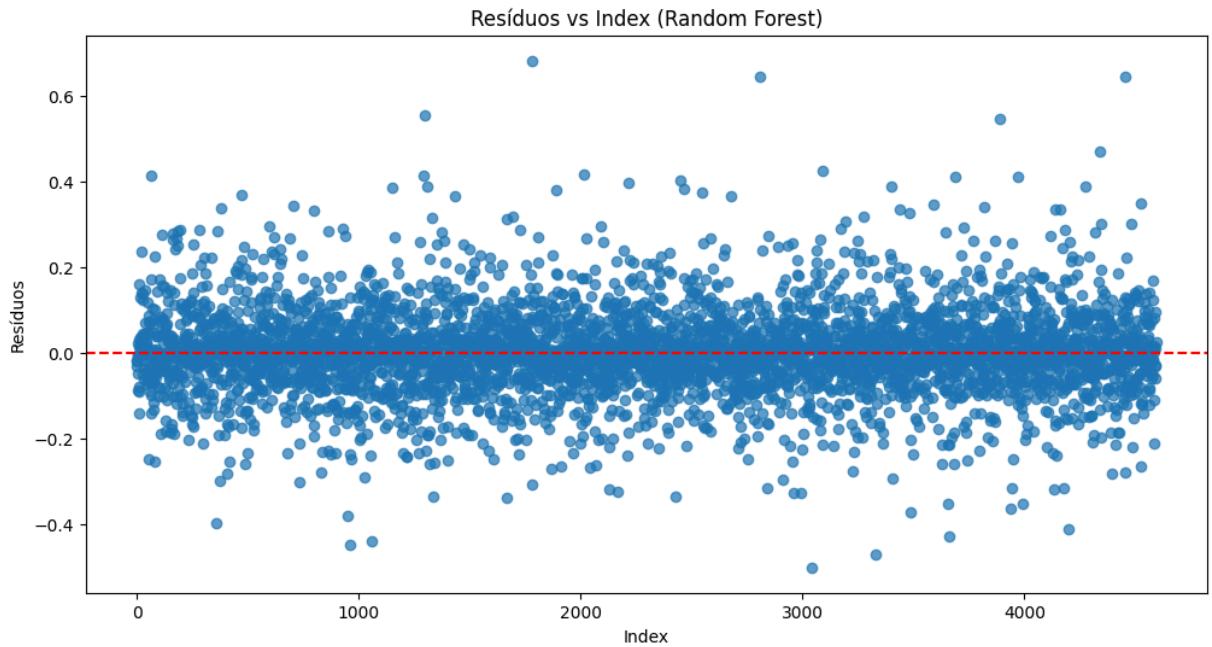

In [23]:
```
# Resíduos vs estimated response values para Random Forest
plt.figure(figsize=(12, 6))
plt.scatter(y_pred_rf, Resíduos_rf, alpha=0.7)
plt.axhline(0, color='red', linestyle='--')
plt.title('Resíduos vs Estimated Response Values (Random Forest)')
plt.xlabel('Estimated Values')
plt.ylabel('Resíduos')
plt.show()
```

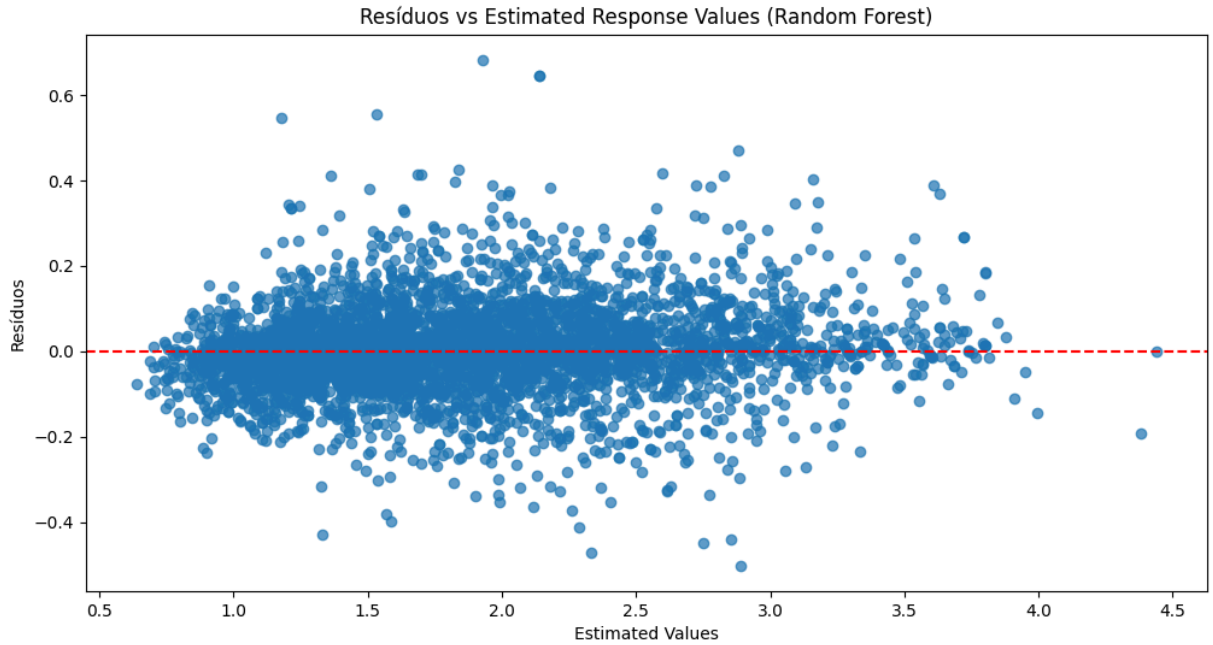

In [24]:
```
# Resíduos vs observations (actual values) para Random Forest
plt.figure(figsize=(12, 6))
plt.scatter(y_test, Resíduos_rf, alpha=0.7)
plt.axhline(0, color='red', linestyle='--')
plt.title('Resíduos vs Observed Values (Random Forest)')
plt.xlabel('Observed Values')
plt.ylabel('Resíduos')
plt.show()
```

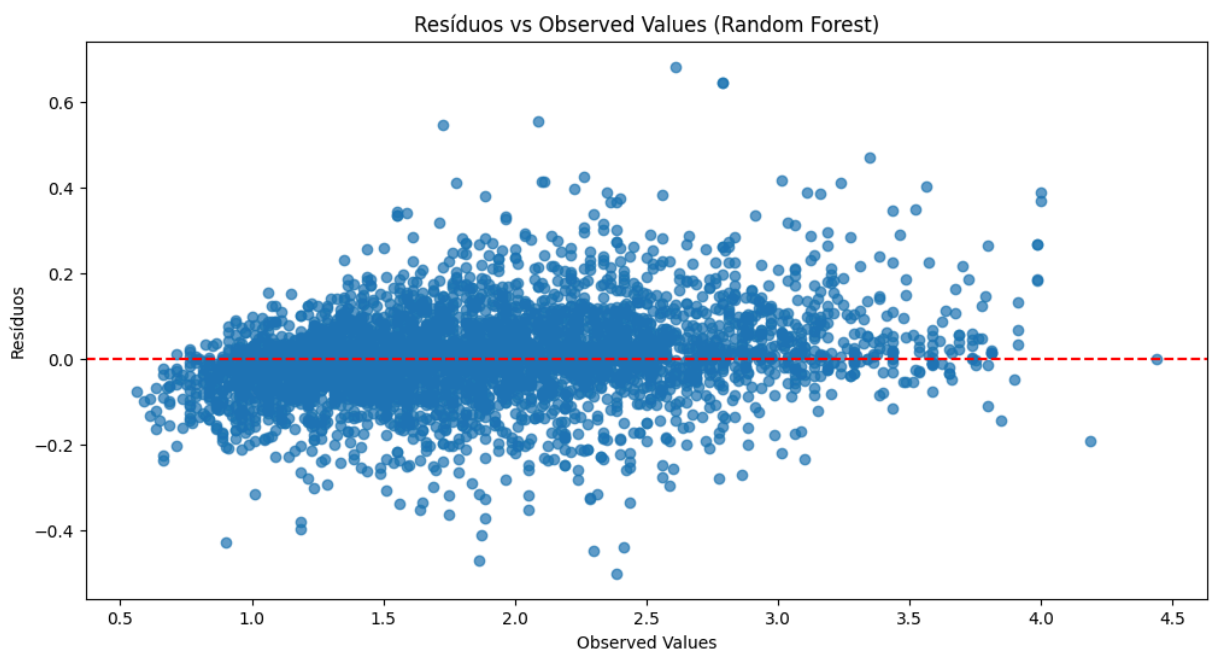

In [25]:
```
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

def plot_best_residuals(y_pred, residuals):
    """
```

```
    Plota os dois gráficos de resíduos mais importantes lado a lado.

    Parâmetros:
    y_pred (array): Valores previstos pelo modelo.
    residuals (array): Resíduos (y_test - y_pred).
    """

    # Cria uma figura com 2 subgráficos (lado a lado)
    fig, axes = plt.subplots(1, 2, figsize=(16, 6))

    # --- Gráfico 1: Resíduos vs Predicted Values ---
    sns.scatterplot(x=y_pred, y=residuals, ax=axes[0], alpha=0.6)
    axes[0].axhline(y=0, color='r', linestyle='--', linewidth=2) # Linha zero
    axes[0].set_title('Random Forest Resíduos vs. Valores Previstos (Homocedasticid
    axes[0].set_xlabel('Valores Previstos')
    axes[0].set_ylabel('Resíduos')

    # --- Gráfico 2: Resíduos vs Index ---
    # Criamos um índice sequencial (0, 1, 2, ...)
    index = np.arange(len(residuals))

    sns.scatterplot(x=index, y=residuals, ax=axes[1], alpha=0.6)
    axes[1].axhline(y=0, color='r', linestyle='--', linewidth=2) # Linha zero
    axes[1].set_title('Random Forest Resíduos vs. Index (Independência)')
    axes[1].set_xlabel('Index (Ordem dos Dados)')
    axes[1].set_ylabel('Resíduos')

    plt.tight_layout()
    plt.show()

# --- Exemplo de Uso (Simulação) ---
# Nota: No teu código real, usa as tuas variáveis y_pred e residuos reais.
if __name__ == "__main__":

    plot_best_residuals(y_pred_rf, Resíduos_rf)
```

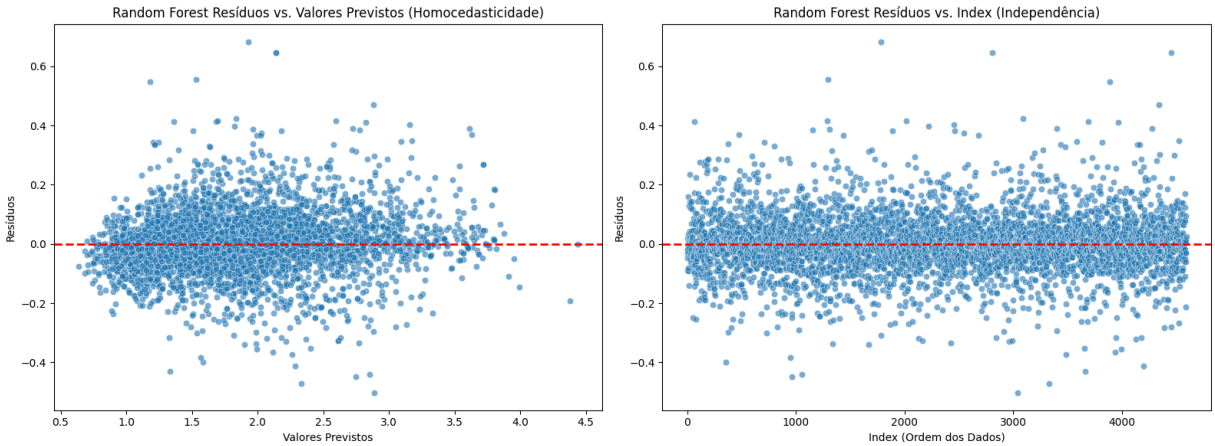

In [26]:
```
from sklearn.model_selection import KFold, cross_val_score
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, make_scorer
import numpy as np
```

In [27]:
```
# Definir modelo
model = RandomForestRegressor(random_state=42)
```

In [28]:
```
# Definir KFold
kfold = KFold(n_splits=5, shuffle=True, random_state=42)
kfold
```

Out[28]:
```
KFold(n_splits=5, random_state=42, shuffle=True)
```

In [29]:
```
# Definir métrica de avaliação
#mae_scorer = make_scorer(mean_absolute_error)
```

In [30]:
```
# Aplicar validação cruzada
#mae_scores = cross_val_score(model, X, y, cv=kfold, scoring=mae_scorer)
```

In [31]:
```
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
```

In [32]:
```
# Listas para armazenar métricas
mae_list, mse_list, rmse_list, mape_list, r2_list = [], [], [], [], []

# Loop pelos folds
for train_index, val_index in kfold.split(X):
    X_train_fold, X_val_fold = X.iloc[train_index], X.iloc[val_index]
    y_train_fold, y_val_fold = y.iloc[train_index], y.iloc[val_index]

    model = RandomForestRegressor(random_state=42)
    model.fit(X_train_fold, y_train_fold)
    y_pred = model.predict(X_val_fold)

    # Calcular métricas
    mae = mean_absolute_error(y_val_fold, y_pred)
    mse = mean_squared_error(y_val_fold, y_pred)
    rmse = np.sqrt(mse)
    mape = np.mean(np.abs((y_val_fold - y_pred) / y_val_fold)) * 100
    r2 = r2_score(y_val_fold, y_pred)

    # Armazenar
    mae_list.append(mae)
    mse_list.append(mse)
    rmse_list.append(rmse)
    mape_list.append(mape)
    r2_list.append(r2)

# Resultados Médios
print("Validação Cruzada (K-Fold = 5):")
print(f"MAE médio: {np.mean(mae_list):.4f}")
print(f"MSE médio: {np.mean(mse_list):.4f}")
print(f"RMSE médio: {np.mean(rmse_list):.4f}")
print(f"MAPE médio (%): {np.mean(mape_list):.4f}")
print(f"R² médio: {np.mean(r2_list):.4f}")
```

```
Validação Cruzada (K-Fold = 5):
MAE médio: 0.0665
MSE médio: 0.0093
RMSE médio: 0.0963
MAPE médio (%): 3.9222
R² médio: 0.9787
```

In [33]:
```python
# Separar último ano como teste (ex: 2024)
df_train = df[df['data'] < '2024-01-01']
df_test  = df[df['data'] >= '2024-01-01']
```

In [34]:
```python
# Features e target corretos
feat = df_train.drop(columns=['score_total','companycode','ano','periodo','data']).
```

In [35]:
```python
X_train = df_train[feat]
y_train = df_train['score_total']
```

In [36]:
```python
X_test = df_test[feat]
y_test = df_test['score_total']
```

In [37]:
```python
model = RandomForestRegressor(random_state=42)
model.fit(X_train, y_train)
```

Out[37]:

▾ RandomForestRegressor

▸ Parameters

In [38]:
```python
# Prever
y_pred = model.predict(X_test)

# Avaliação
mae  = mean_absolute_error(y_test, y_pred)
mse  = mean_squared_error(y_test, y_pred)
rmse = np.sqrt(mse)
r2   = r2_score(y_test, y_pred)
mape = np.mean(np.abs((y_test - y_pred) / y_test)) * 100

print("\nValidação Temporal (Holdout - Teste em 2024):")
print(f"MAE: {mae:.4f}")
print(f"MSE: {mse:.4f}")
print(f"RMSE: {rmse:.4f}")
print(f"MAPE: {mape:.4f}")
print(f"R²: {r2:.4f}")
```

```
Validação Temporal (Holdout - Teste em 2024):
MAE: 0.0864
MSE: 0.0134
RMSE: 0.1156
MAPE: 5.6557
R²: 0.9659
```

In [39]:
```python
import matplotlib.pyplot as plt
import seaborn as sns
```

In [40]:
```
# Previsão
y_pred = model.predict(X_test)

# Gráfico
plt.figure(figsize=(8, 6))
sns.scatterplot(x=y_test, y=y_pred, alpha=0.6)
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], '--r')
plt.xlabel('Valor Real')
plt.ylabel('Valor Previsto')
plt.title('📊 Score Total: Real vs Previsto (2024)')
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
C:\Users\Lucas\AppData\Local\Temp\ipykernel_13744\4266613111.py:12: UserWarning: Gly
ph 128202 (\N{BAR CHART}) missing from font(s) DejaVu Sans.
  plt.tight_layout()
C:\Users\Lucas\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.13_qbz5n2kfr
a8p0\LocalCache\local-packages\Python313\site-packages\IPython\core\pylabtools.py:17
0: UserWarning: Glyph 128202 (\N{BAR CHART}) missing from font(s) DejaVu Sans.
  fig.canvas.print_figure(bytes_io, **kw)
```

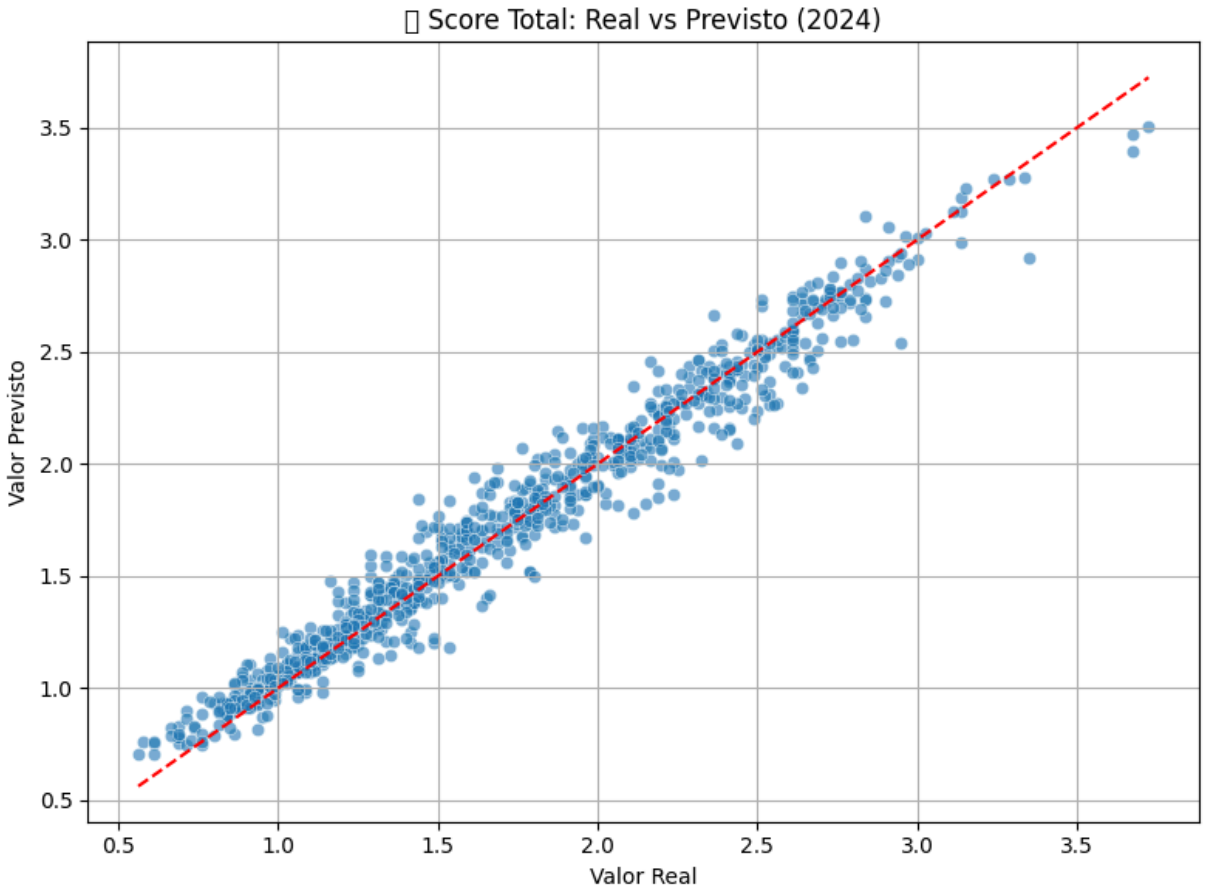

In [41]:
```
import pandas as pd

# Importância
importances = model.feature_importances_
feat_importance = pd.Series(importances, index=feat).sort_values(ascending=False)
```

```
# Gráfico
plt.figure(figsize=(10, 8))
sns.barplot(x=feat_importance.values[:15], y=feat_importance.index[:15])
plt.title('15 Features Mais Importantes no Modelo')
plt.xlabel('Importância')
plt.ylabel('Variável')
plt.tight_layout()
plt.show()
```

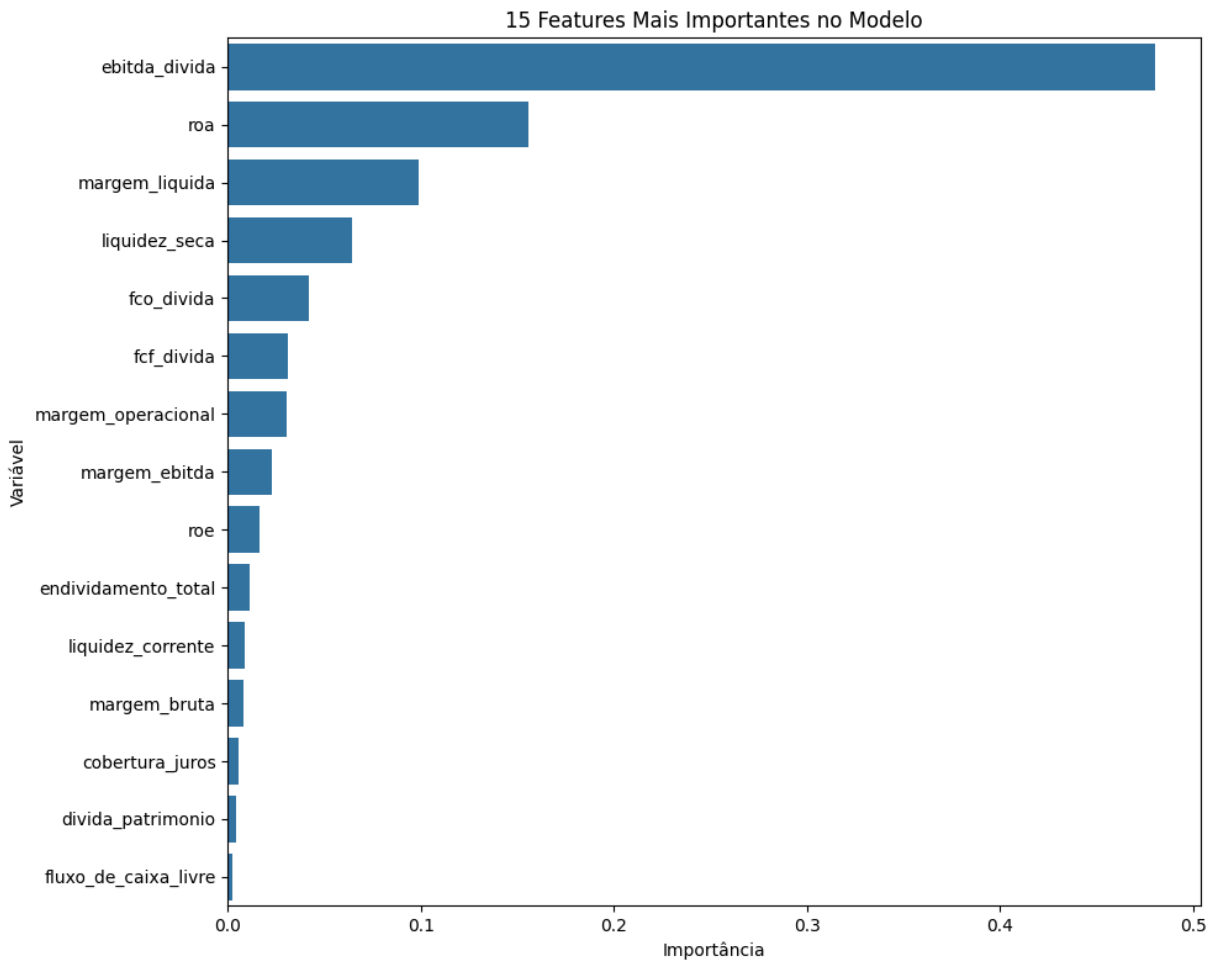

In [42]:

```
# Adiciona erro absoluto à base de teste
df_test = df_test.copy()
df_test['y_pred'] = y_pred
df_test['erro_absoluto'] = abs(df_test['score_total'] - df_test['y_pred'])

# Agrupamento por empresa
erro_por_empresa = df_test.groupby('companycode')['erro_absoluto'].mean().sort_valu

# Gráfico
plt.figure(figsize=(12, 6))
erro_por_empresa.head(15).plot(kind='barh', color='coral')
plt.xlabel('Erro Absoluto Médio')
plt.title('Erro Médio por Empresa (Top 15)')
plt.gca().invert_yaxis()
plt.tight_layout()
plt.show()
```

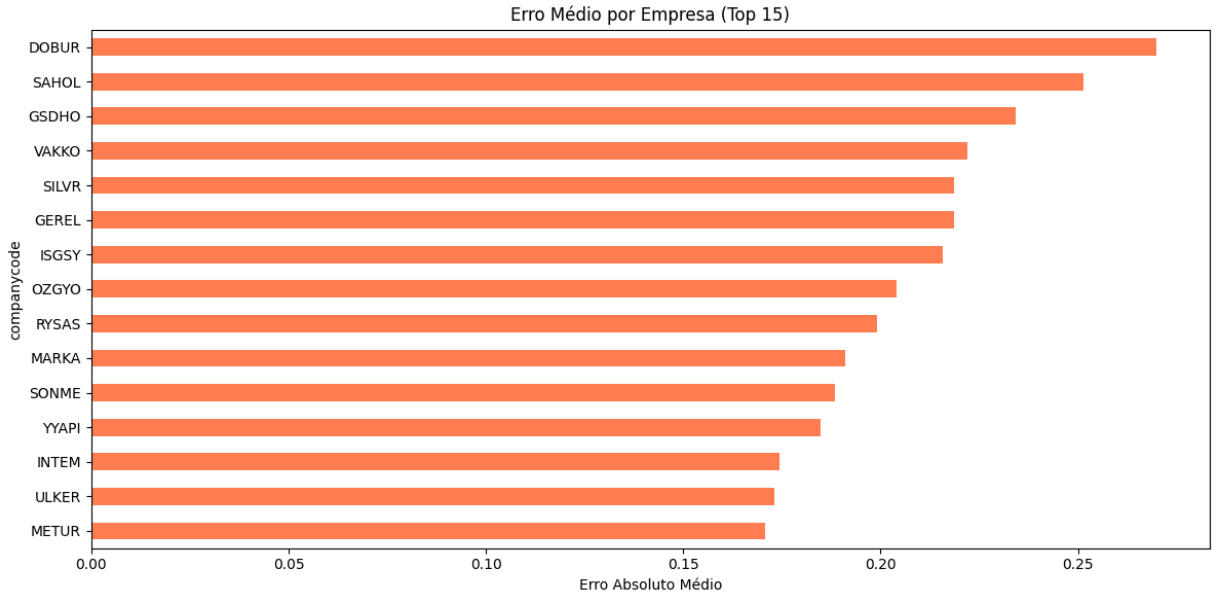

In [43]:
```python
import shap

# Criar explainer SHAP (para modelos baseados em árvore)
explainer = shap.TreeExplainer(model)

# Calcular valores SHAP (pode demorar para muitos dados)
shap_values = explainer.shap_values(X_test)
```

```
C:\Users\Lucas\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.13_qbz5n2kfra8p0\LocalCache\local-packages\Python313\site-packages\tqdm\auto.py:21: TqdmWarning: IProgress not found. Please update jupyter and ipywidgets. See https://ipywidgets.readthedocs.io/en/stable/user_install.html
  from .autonotebook import tqdm as notebook_tqdm
```

In [ ]:
```python
# Sumário global: impacto médio de cada variável
shap.summary_plot(shap_values, X_test, plot_type="bar")
```

```
C:\Users\Lucas\AppData\Local\Temp\ipykernel_13744\381616194.py:2: FutureWarning: The NumPy global RNG was seeded by calling `np.random.seed`. In a future version this function will no longer use the global RNG. Pass `rng` explicitly to opt-in to the new behaviour and silence this warning.
  shap.summary_plot(shap_values, X_test, plot_type="bar")
```

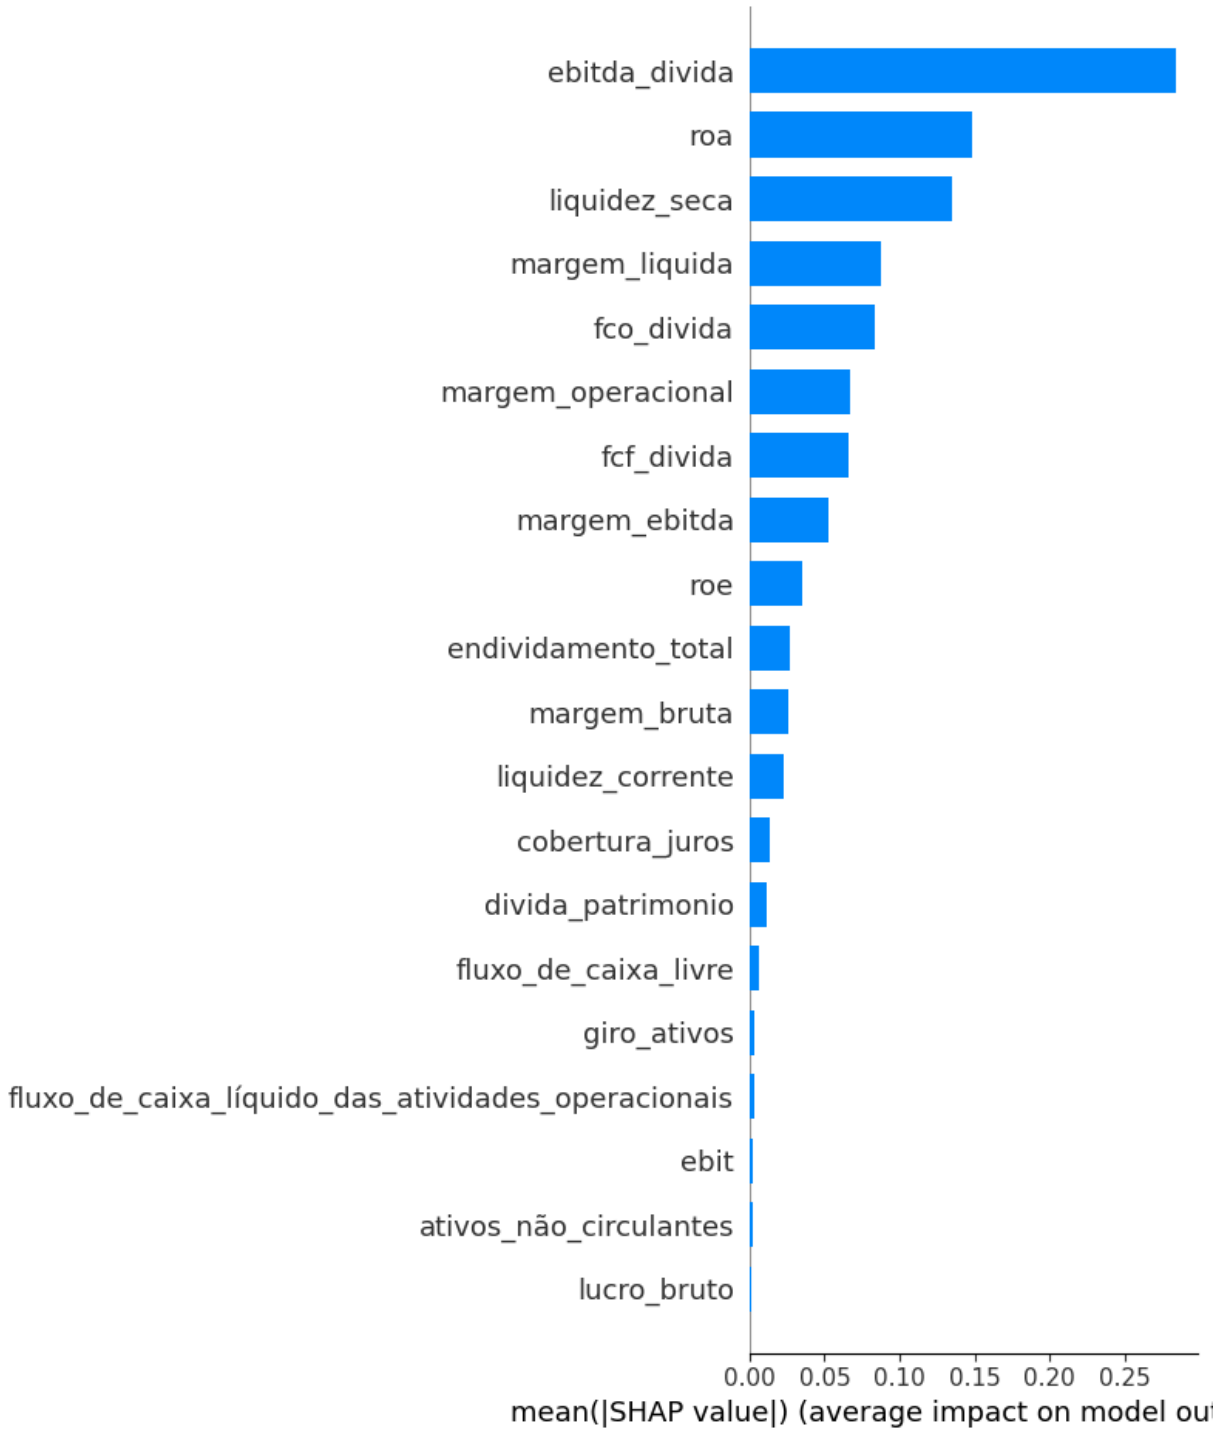

In [45]:
```
# Mostra como cada feature afeta o output (positivo ou negativo)
shap.summary_plot(shap_values, X_test)
```

```
C:\Users\Lucas\AppData\Local\Temp\ipykernel_13744\2310202683.py:2: FutureWarning: Th
e NumPy global RNG was seeded by calling `np.random.seed`. In a future version this
function will no longer use the global RNG. Pass `rng` explicitly to opt-in to the n
ew behaviour and silence this warning.
  shap.summary_plot(shap_values, X_test)
```

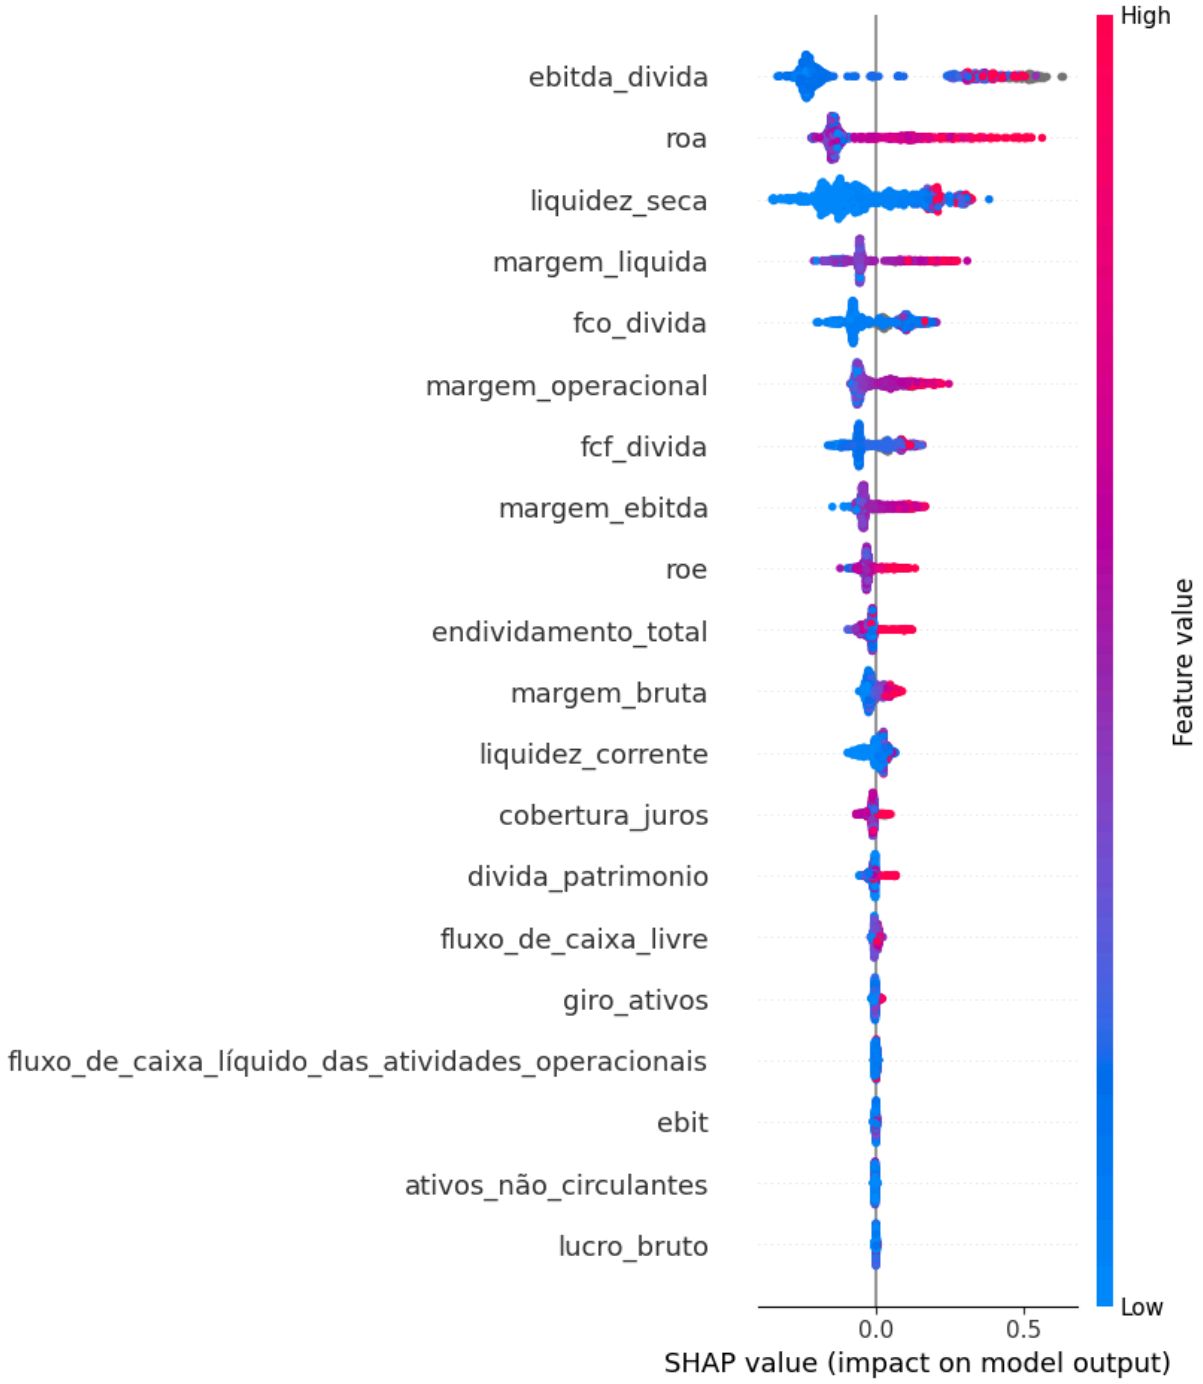

In [46]:
```
# Exemplo: primeira empresa do conjunto de teste
#idx = 3 # ou use um index específico

# Força da contribuição de cada feature para o score
#shap.plots.waterfall(explainer(X_test.iloc[idx]))
```

In [47]:
```
#Isso mostra exatamente por que aquela empresa recebeu aquele score — quais indicad
```

In [48]:
```
# Filtrar apenas THYAO
df_thyao_real = df[df['companycode'] == 'THYAO'].copy()
df_thyao_real['data'] = pd.to_datetime(df_thyao_real['data'])

# Ordenar cronologicamente para evitar linhas riscando o gráfico
```

```
df_thyao = df_thyao_real.sort_values('data')

# Prever usando o modelo treinado (usando todas as colunas de features já conhecida
X_thyao = df_thyao_real.drop(columns=['score_total', 'companycode', 'ano', 'periodo
y_thyao_pred = model.predict(X_thyao)

# Adicionar coluna de previsão ao DataFrame
df_thyao_real['score_predito'] = y_thyao_pred

# Plotar
plt.figure(figsize=(14, 6))
plt.plot(df_thyao_real['data'], df_thyao_real['score_total'], label='Real', color='
plt.plot(df_thyao_real['data'], df_thyao_real['score_predito'], label='Previsto', c

plt.title('Comparação: Score Total Real vs Previsto - THYAO')
plt.xlabel('Ano')
plt.ylabel('Score Total (0 a 5)')
plt.legend()
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()
```

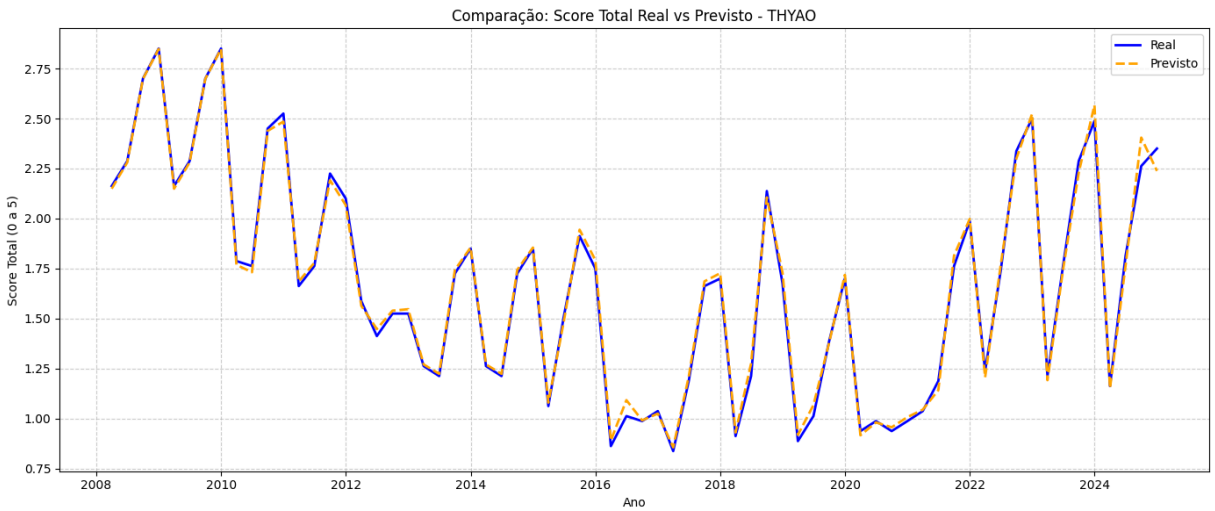

In [49]:

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# 1. Criar um ranking baseado na média histórica do Score Total
ranking_historico = df.groupby('companycode')['score_total'].mean().sort_values(asc

# 2. Identificar os extremos
melhor_empresa = ranking_historico.index[0]   # A primeira da lista
pior_empresa = ranking_historico.index[-1]    # A última da lista

# Garantir que não selecionamos a própria THYAO como melhor/pior (para não duplicar
if melhor_empresa == 'THYAO':
    melhor_empresa = ranking_historico.index[1]
if pior_empresa == 'THYAO':
    pior_empresa = ranking_historico.index[-2]

print(f"✈️ Empresa Foco: THYAO")
```

```
print(f"🏆 Melhor Desempenho (Benchmark Positivo): {melhor_empresa} (Média: {rankin
print(f"⚠️ Pior Desempenho (Benchmark Negativo): {pior_empresa} (Média: {ranking_h

# 3. Filtrar o DataFrame apenas para essas 3 empresas
empresas_selecionadas = ['THYAO', melhor_empresa, pior_empresa]
df_comparacao = df[df['companycode'].isin(empresas_selecionadas)].copy()

# Definir uma ordem fixa para as cores nos gráficos
ordem_empresas = [melhor_empresa, 'THYAO', pior_empresa]
paleta_cores = {melhor_empresa: 'green', 'THYAO': 'blue', pior_empresa: 'red'}
```

```
✈️ Empresa Foco: THYAO
🏆 Melhor Desempenho (Benchmark Positivo): AKMGY (Média: 3.25)
⚠️ Pior Desempenho (Benchmark Negativo): BURCE (Média: 1.02)
```

In [53]:

```
# Criar uma cópia do DataFrame original
df_sem_thyao = df[df['companycode'] != 'THYAO'].copy()

# Verificar que THYAO foi removido
print("THYAO removido?", 'THYAO' in df_sem_thyao['companycode'].unique())
```

```
THYAO removido? False
```

In [54]:

```
df_sem_thyao
```

Out[54]:

	companycode	ano	periodo	ativos_circulantes	ativos_não_circulantes	total_de_ati
0	ADEL	2008	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
1	ADEL	2008	6_Meses	8.860061e+07	1.609915e+07	1.046998e-
2	ADEL	2008	9_Meses	9.400968e+07	1.555129e+07	1.095610e-
3	ADEL	2008	Anual	4.558265e+07	1.517075e+07	6.075340e-
4	ADEL	2009	3_Meses	8.208236e+07	1.600055e+07	9.808291e-
...	...	...	...	...	...	
15307	ZOREN	2023	Anual	2.862619e+10	1.136030e+11	1.422292e-
15308	ZOREN	2024	3_Meses	1.561239e+10	8.488922e+10	1.005016e-
15309	ZOREN	2024	6_Meses	1.434187e+10	9.238784e+10	1.067297e-
15310	ZOREN	2024	9_Meses	1.539392e+10	9.982602e+10	1.152199e-
15311	ZOREN	2024	Anual	1.341005e+10	1.053747e+11	1.187847e-

15244 rows × 50 columns

In [64]:

```
# Separar treino e teste com base em data (2023 como holdout)
df_train = df_sem_thyao[df_sem_thyao['data'] < '2024-01-01']
df_test  = df_sem_thyao[df_sem_thyao['data'] >= '2024-01-01']

# Definir colunas de features
feat = df_train.drop(columns=['score_total', 'companycode', 'ano', 'periodo', 'data
```

```python
# Criar conjuntos
X_train = df_train[feat]
y_train = df_train['score_total']
X_test  = df_test[feat]
y_test  = df_test['score_total']

# Treinar modelo
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_absolute_error, mean_squared_error, r2_score
import numpy as np

model_holdout = RandomForestRegressor(random_state=42)
model_holdout.fit(X_train, y_train)

# Avaliar
y_pred = model_holdout.predict(X_test)
mae  = mean_absolute_error(y_test, y_pred)
mse  = mean_squared_error(y_test, y_pred)
mape = np.mean(np.abs((y_test - y_pred) / y_test)) * 100
rmse = np.sqrt(mse)
r2   = r2_score(y_test, y_pred)

print("Holdout - Validação com Empresas (exceto THYAO):")
print(f"MAE: {mae:.4f}, RMSE: {rmse:.4f}, R²: {r2:.4f},MAPE:{mape:.4f}")
```

```
Holdout - Validação com Empresas (exceto THYAO):
MAE: 0.0885, RMSE: 0.1172, R²: 0.9651,MAPE:5.8129
```

In [62]:

```python
# Prever THYAO com modelo que nunca a viu
df_thyao = df[df['companycode'] == 'THYAO'].copy()
X_thyao = df_thyao[feat]
df_thyao['score_predito'] = model_holdout.predict(X_thyao)
```

In [63]:

```python
plt.figure(figsize=(14, 6))
# Se ainda não foi convertido no início do script, convertemos agora
df_thyao['data'] = pd.to_datetime(df_thyao['data'])

# Ordenar cronologicamente para evitar linhas riscando o gráfico
df_thyao = df_thyao.sort_values('data')

plt.plot(df_thyao['data'], df_thyao['score_total'], label='Real', color='blue', lin
plt.plot(df_thyao['data'], df_thyao['score_predito'], label='Previsto', color='oran
plt.title('Comparação: Score Total Real vs Previsto - THYAO (Modelo sem ver THYAO)'
plt.xlabel('Ano')
plt.ylabel('Score Total (0 a 5)')
plt.legend()
plt.grid(True, linestyle='--', alpha=0.6)
plt.tight_layout()
plt.show()
```

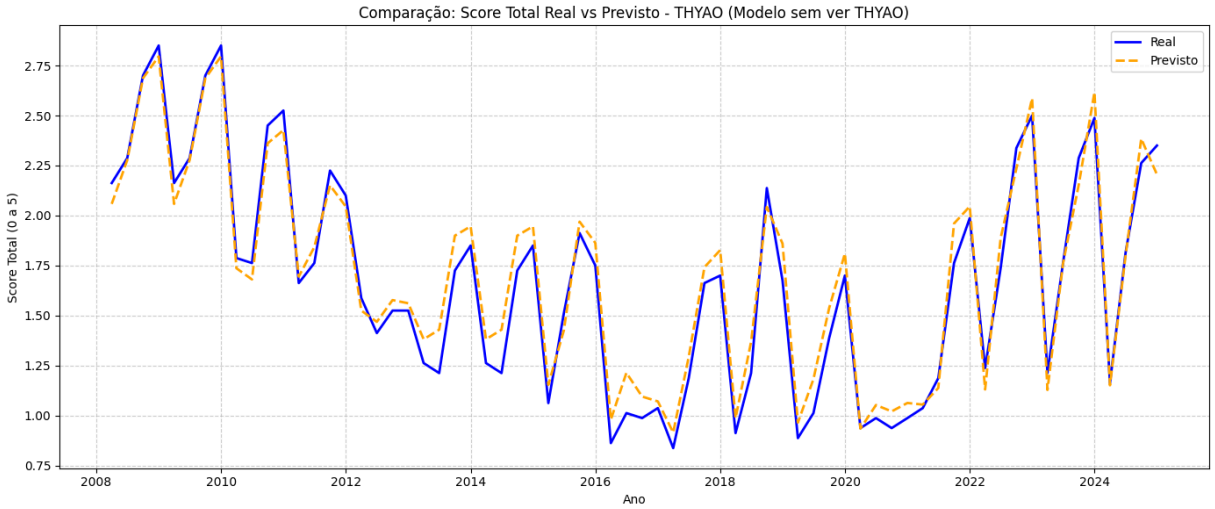

In [58]:

```
# Selecionar empresas extremas
ranking = df.groupby('companycode')['score_total'].mean().sort_values(ascending=Fal
melhor_empresa = ranking.index[0] if ranking.index[0] != 'THYAO' else ranking.index
pior_empresa = ranking.index[-1] if ranking.index[-1] != 'THYAO' else ranking.index

# Dados reais das outras duas empresas
df_extremos = df[df['companycode'].isin([melhor_empresa, pior_empresa])].copy()

# Substituir dados reais de THYAO pelo previsto
df_thyao_prev = df_thyao[['data', 'score_predito']].copy()
df_thyao_prev['companycode'] = 'THYAO'
df_thyao_prev.rename(columns={'score_predito': 'score_total'}, inplace=True)

# Combinar os três
df_final = pd.concat([df_extremos, df_thyao_prev], ignore_index=True)
# Se ainda não foi convertido no início do script, convertemos agora
df_final['data'] = pd.to_datetime(df_final['data'])

# Ordenar cronologicamente para evitar linhas riscando o gráfico
df_final = df_final.sort_values('data')

# Plotar
plt.figure(figsize=(14, 7))
sns.lineplot(
    data=df_final,
    x='data',
    y='score_total',
    hue='companycode',
    palette={melhor_empresa: 'green', 'THYAO': 'blue', pior_empresa: 'red'},
    hue_order=[melhor_empresa, 'THYAO', pior_empresa],
    linewidth=2.5
)
plt.title('THYAO Previsto vs Benchmark Positivo e Negativo')
plt.axhspan(4, 5, color='green', alpha=0.05)
plt.axhspan(0, 2, color='red', alpha=0.05)
plt.grid(True, linestyle='--', alpha=0.7)
plt.ylabel('Score Total (0 a 5)')
plt.xlabel('Ano')
```

```
plt.tight_layout()
plt.show()
```

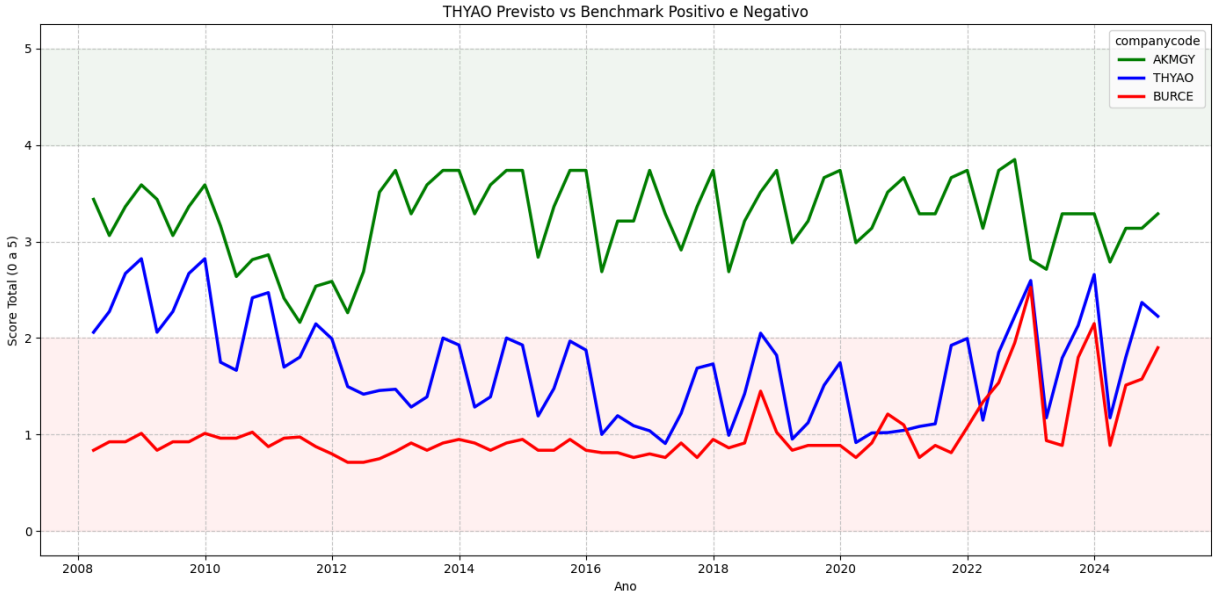

In [59]:
```
# Selecionar empresas extremas
ranking = df.groupby('companycode')['score_total'].mean().sort_values(ascending=Fal
melhor_empresa = ranking.index[0] if ranking.index[0] != 'THYAO' else ranking.index
pior_empresa = ranking.index[-1] if ranking.index[-1] != 'THYAO' else ranking.index

# Dados reais das outras duas empresas
df_extremos = df[df['companycode'].isin([melhor_empresa, pior_empresa])].copy()

# Substituir dados reais de THYAO pelo previsto
df_thyao_prev = df_thyao[['data', 'score_predito']].copy()
df_thyao_prev['companycode'] = 'THYAO'
df_thyao_prev.rename(columns={'score_predito': 'score_total'}, inplace=True)

# Combinar os três
df_final = pd.concat([df_extremos, df_thyao_prev], ignore_index=True)

# Se ainda não foi convertido no início do script, convertemos agora
df_final['data'] = pd.to_datetime(df_final['data'])

# Ordenar cronologicamente para evitar linhas riscando o gráfico
df_final = df_final.sort_values('data')

# Plotar
plt.figure(figsize=(14, 7))
sns.lineplot(
    data=df_final,
    x='data',
    y='score_total',
    hue='companycode',
    palette={melhor_empresa: 'green', 'THYAO': 'blue', pior_empresa: 'red'},
    hue_order=[melhor_empresa, 'THYAO', pior_empresa],
    linewidth=2.5
)
plt.title('THYAO Previsto vs Benchmark Positivo e Negativo')
```

```
plt.axhspan(4, 5, color='green', alpha=0.05)
plt.axhspan(0, 2, color='red', alpha=0.05)
plt.grid(True, linestyle='--', alpha=0.7)
plt.ylabel('Score Total (0 a 5)')
plt.xlabel('Ano')
plt.tight_layout()
plt.show()
```

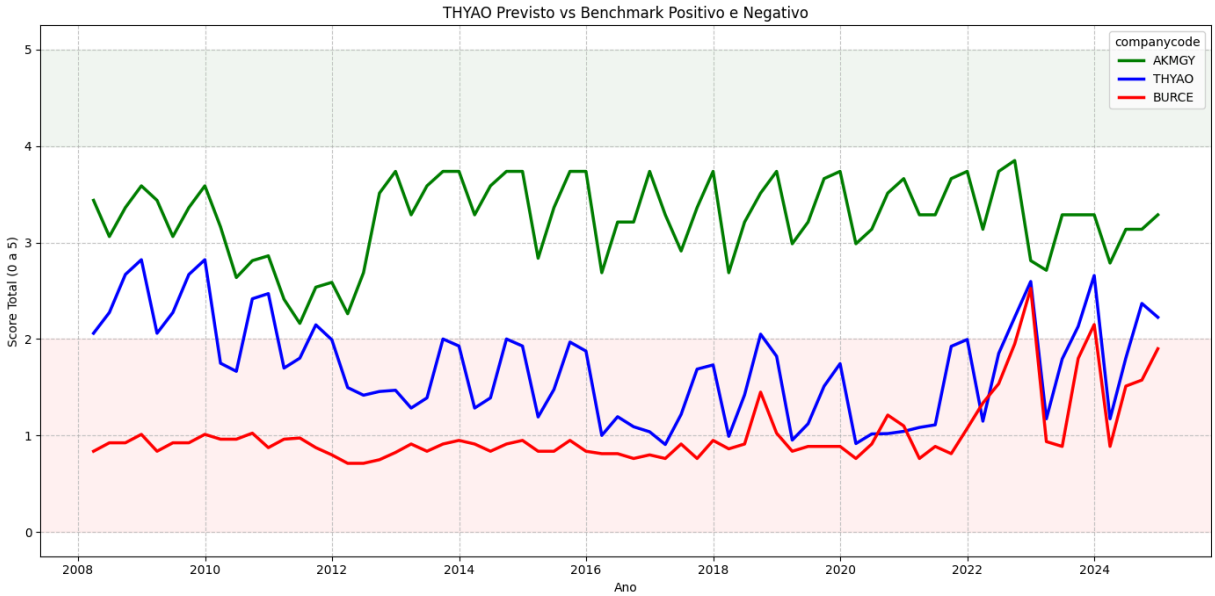

In [60]:
```
import matplotlib.pyplot as plt
import seaborn as sns
import matplotlib.dates as mdates  # <--- Importante para formatar datas

# ... (seu código de seleção de empresas e concatenação df_final mantém-se igual) .

# --- CORREÇÃO 1: Garantir que é datetime ---
# Se ainda não foi convertido no início do script, convertemos agora
df_final['data'] = pd.to_datetime(df_final['data'])

# Ordenar cronologicamente para evitar linhas riscando o gráfico
df_final = df_final.sort_values('data')

# --- PLOTAGEM ---
plt.figure(figsize=(14, 7))

sns.lineplot(
    data=df_final,
    x='data',
    y='score_total',
    hue='companycode',
    palette={melhor_empresa: 'green', 'THYAO': 'blue', pior_empresa: 'red'},
    hue_order=[melhor_empresa, 'THYAO', pior_empresa],
    linewidth=2.5
)

# --- CORREÇÃO 2: Formatar o Eixo X ---
ax = plt.gca() # Pega o eixo atual
```
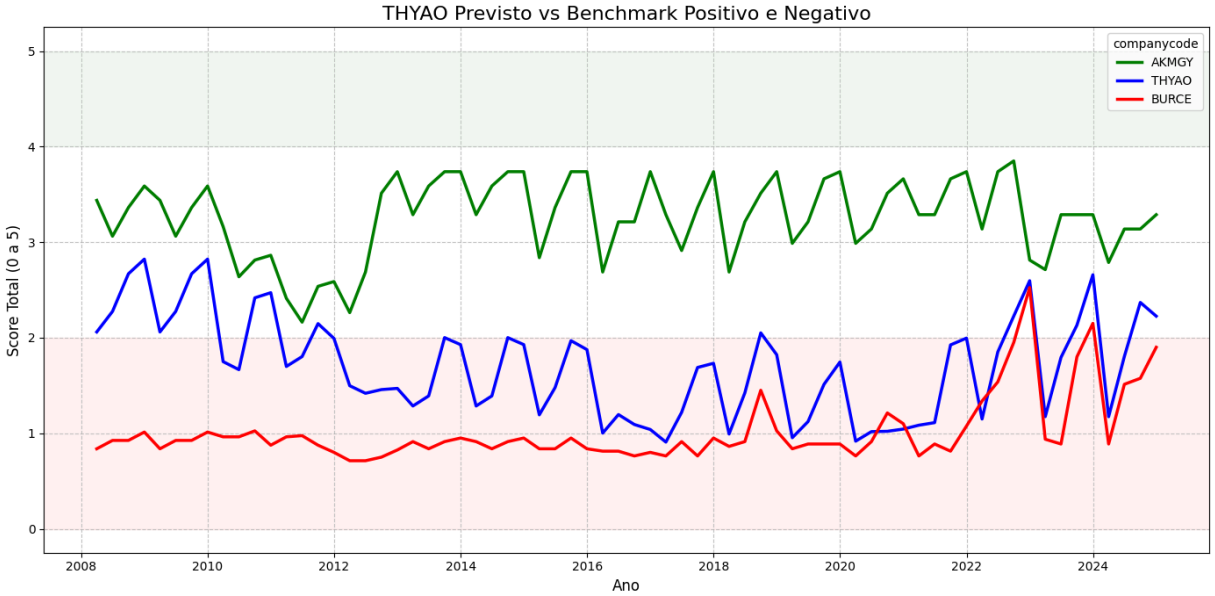
```python
# Define os intervalos principais (ex: a cada 2 anos)
ax.xaxis.set_major_locator(mdates.YearLocator(2))

# Define o formato do texto (Apenas o Ano)
ax.xaxis.set_major_formatter(mdates.DateFormatter('%Y'))

plt.title('THYAO Previsto vs Benchmark Positivo e Negativo', fontsize=16)
plt.axhspan(4, 5, color='green', alpha=0.05, label='Excelência') # Adicionei label
plt.axhspan(0, 2, color='red', alpha=0.05, label='Risco Elevado')

plt.ylabel('Score Total (0 a 5)', fontsize=12)
plt.xlabel('Ano', fontsize=12)

plt.grid(True, linestyle='--', alpha=0.7)
plt.tight_layout()
plt.show()
```